北京航空航天大学计算机学院

硕士学位论文中期检查报告

论文题目：　面向多源异构时序数据的系统异常检测技术研究

专　　业：　电子信息

研究方向：　智能化系统运维

研 究 生：　于郅豪

学　　号：　ZY2306322

指导教师：　高小鹏 教授

北京航空航天大学计算机学院

2025 年 6 月 30 日

目录

1 论文工作计划.....1
1.1 论文研究目标.....1
1.2 研究内容.....2
1.2.1 面向多源异构时序数据的异常检测框架设计.....3
1.2.2 基于多源异构时序数据特性的特征增强与提取技术研究.....5
1.2.3 基于门控机制的异构特征融合技术研究.....6
1.2.4 实验评估.....6
2 已完成的工作.....8
2.1 面向多源异构时序数据的异常检测框架设计.....8
2.2 基于多源异构时序数据特性的特征增强与提取技术研究.....9
2.2.1 日志（Log）数据的特征增强和提取技术.....9
2.2.2 调用链追踪（Trace）数据的特征增强和提取技术.....12
2.2.3 指标（Metric）数据的特征提取技术.....15
2.3 基于门控机制的异构特征融合技术研究.....17
2.3.1 设计目标.....17
2.3.2 方法结构与技术路径.....18
2.4 实验评估.....20
2.4.1 研究问题.....20
2.4.2 实验数据集.....21
2.4.3 实验基线模型.....22
2.4.4 评估指标.....23
2.4.5 实验结果与分析.....24
3 关键技术.....27
3.1 基于多源异构时序数据特性的特征提取技术.....27
3.2 基于门控机制的异构特征融合技术.....28
4 下一阶段工作计划.....30
4.1 存在的问题.....30
4.2 尚未完成的工作.....31

4.3 解决问题的技术思路或措施.....32
4.4 下一阶段计划.....34
5 主要参考文献.....35

1 论文工作计划

1.1 论文研究目标

本课题旨在聚焦于微服务系统的健康监控需求，研究设计一套创新性强、鲁棒性高的**多源异构时序数据异常检测框架**。核心理念是充分挖掘微服务系统三大关键诊断数据源——指标（Metric）、日志（Log）与调用链追踪（Trace）——各自的特性与它们之间潜在联系，通过**基于多源异构时序数据特性的特征增强和提取技术**与**基于门控机制的异构特征融合技术**，有效提升异常检测的准确性与覆盖广度。

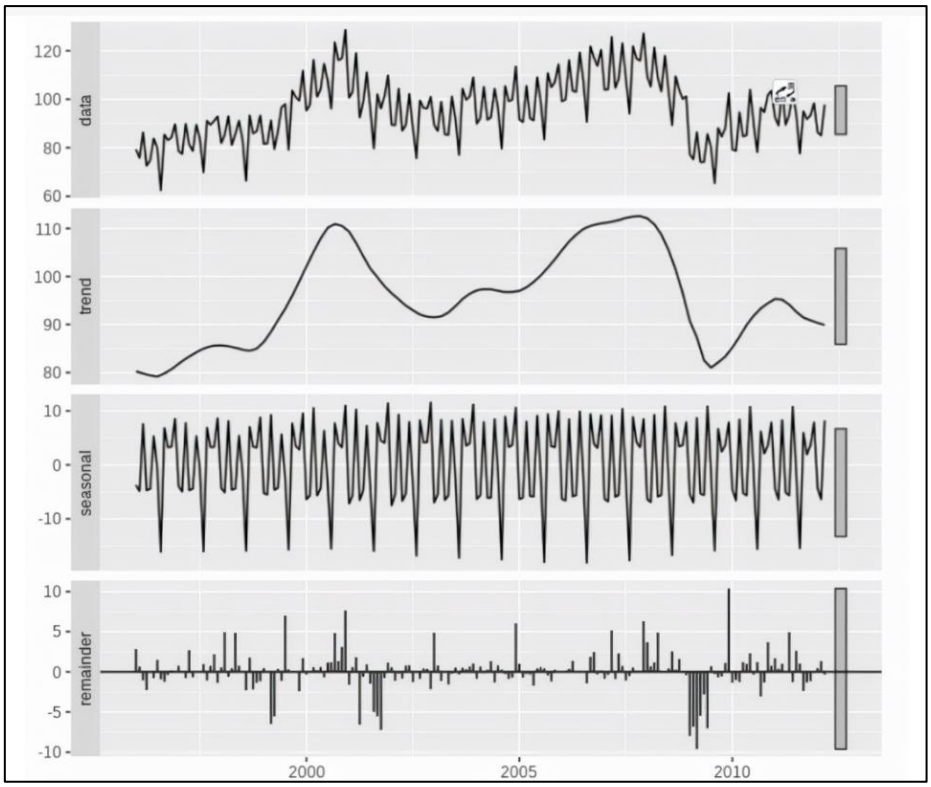

图 1 指标（Metric）数据

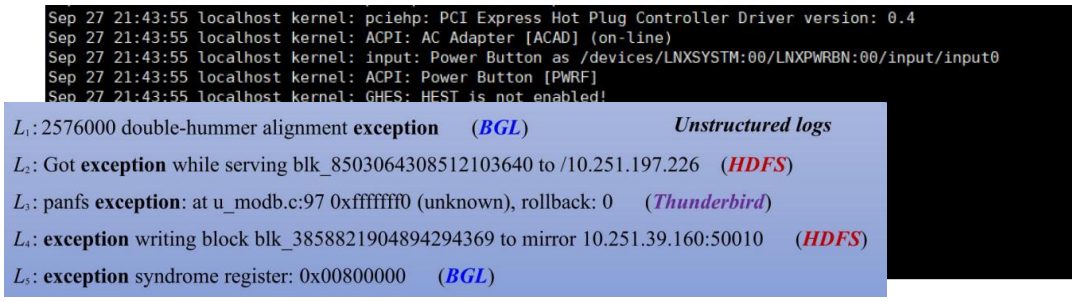

图 2 日志（Log）数据

```
38  "children": [
39    {
40      "info": {
41        "exception": "None",
42        "name": "wsgi",
43        "service": "public",
44        "started": 0,
45        "meta.raw_payload.wsgi-stop": {
46          "info": {
47            "host": "wally113"
48          },
49          "name": "wsgi-stop",
50          "service": "public",
51          "timestamp": "2019-11-19T23:24:41.637455",
52          "trace_id": "753d9c98-2fc1-485b-8b2b-5023fcd081ca",
53          "project": "keystone",
54          "parent_id": "0a376f0b-07f7-4b84-9c1e-af369990b11b",
55          "base_id": "0a376f0b-07f7-4b84-9c1e-af369990b11b"
56        },
57        "finished": 1,
58        "project": "keystone",
59        "host": "wally113",
60        "meta.raw_payload.wsgi-start": {
61          "info": {
62            "host": "wally113",
63            "request": {
64              "path": "/",
65              "scheme": "http",
66              "method": "GET",
67              "query": ""
68            }
69          },
```


图 3 调用链追踪（Trace）数据

具体而言，针对不同类型数据源的异构性与结构差异，本课题拟设计定制化**特征增强和特征提取技术**分别提取异构时序数据源的深层特征。之后，本课题将进一步研究如何建模这些异构时序数据源间复杂的动态协同关系。为此，我们设计了一个**基于门控机制的异构特征融合技术**，引导模型学习异构时序数据源间的动态协同关系与互补特征，采用动态加权机制融合多种增强路径，以形成更加判别性强的综合特征表示，最终用于异常检测任务。

通过这些创新研究，本课题期望能够实现对多源异构时序数据中潜在异常的高效、高精度检测，为相关领域提供更全面、更可靠的异常检测工具。

1.2 研究内容

在微服务架构广泛应用的背景下，系统运行状态由指标（Metric）、日志（Log）和调用链（Trace）三种异构时序数据多维描述，三者在表达能力上各具优势，但也存在强烈的结构异构性与语义互补性。因此，本课题围绕多源异

构时序数据各自的深度特征建模、多源异构时序数据之间动态协同关系的挖掘与特征融合这两个难点展开。本课题的核心研究内容主要包括以下 4 个部分。

第一，从系统工程的角度出发，设计并实现一个**面向多源异构时序数据的异常检测系统框架**，为多源异构时序数据异构数据的统一处理与融合建模提供基础结构支撑。

第二，针对三种异构数据源各自的内在表现形式与统计属性，分别对指标、日志、追踪数据展开**特征增强和提取技术研究**，深入挖掘数据的潜在信息，增强原始信息的表达能力，并对每种数据源进行高质量的特征表示。

第三，基于多源异构时序数据之间的动态协同关系与互补信息，深入探究一种**基于门控机制的异构特征融合技术**，在保持原模态特性的同时实现跨数据源信息的深度集成，旨在通过结合多源异构时序数据的互补信息，提升异常检测的准确性和鲁棒性。

第四，围绕模型效果的定量评估，构建完整**实验流程**与指标体系，并在真实数据集上对模型整体与关键模块的性能进行了充分验证与对比分析。

这 4 个研究内容相辅相成、紧密衔接，分别从**系统架构设计**、**多源异构时序数据特征增强和提取**、**跨数据源特征融合**，以及**实验验证**四个角度展开，形成端到端的异常检测方案，旨在推动多源异构时序数据异常检测领域的发展，并为相关实际问题的解决提供新的方法和思路。

1.2.1 面向多源异构时序数据的异常检测框架设计

在微服务系统的运行监控中，指标（Metric）、日志（Log）和调用链（Trace）被视为三类最核心的数据来源，三者从不同维度反映系统状态，具有天然的互补性[1]。

（1）**指标数据（Metric）**是对系统各组件运行状态的**连续量化描述**，通常包括 CPU 利用率、内存占用、磁盘 IO、负载均衡、网络吞吐等关键性能指标[2–4]。这类数据具有结构规整、采样频率高、变化灵敏等特点，能够实时反映系统资源使用状态和运行趋势，是异常检测中用于捕捉短期突变和性能退化的重要信号。此外，指标数据可作为系统健康度评估的基础，特别适合通过时序建模发现性能瓶颈与资源异常。

（2）**日志数据（Log）**则更侧重于**系统行为的语义表达与操作轨迹**的记录。日志通常以自然语言为主，记录了系统运行过程中的事件、错误、警告及其上下文信息[5]。经过模板提取与结构化处理后，日志序列可以转化为有意义的事件模式，用于揭示系统的工作流程与行为路径。当日志序列中出现异常事件、意外组合或频率突变时，往往意味着系统发生了潜在故障。此外，日志数据中的语义冗余和上下文线索也为异常定位与根因分析提供了宝贵支持。

（3）**调用链追踪数据（Trace）**聚焦于分布式**系统内部服务之间的调用结构与链路依赖**，记录了服务之间的请求路径、响应时延、调用频率等细粒度交互信息[6]。通过追踪数据可以重建请求的端到端流转过程，识别关键路径上的性能瓶颈、异常延迟或异常调用频次等问题。与指标数据的宏观性能监控互补，Trace 数据更适合捕捉微观结构中的潜在异常，如长链调用延迟、高频调用等。

综上，这三类数据从性能、行为、结构三个角度构建了一个立体的系统运行视图。仅依赖任意一种数据源往往难以全面刻画系统状态[7]，如指标反映不到具体的操作行为，日志难以量化故障影响范围，调用链追踪则可能遗漏静态组件异常。因此，三种异构时序数据源的联合建模才能全面捕捉异常的发生，能够提升异常检测的准确性和覆盖范围[1]。

正因如此，本课题强调多源异构时序数据异构数据的协同建模，以充分发挥其信息互补优势，需要构建一个合理的**多源异构时序数据异常检测框架**。如图 4，该系统框架包含 3 大核心技术：**基于多源异构时序数据特性的特征增强与提取技术**、**基于门控机制的异构特征融合技术**以及**基于动态加权的异常分类技术**。

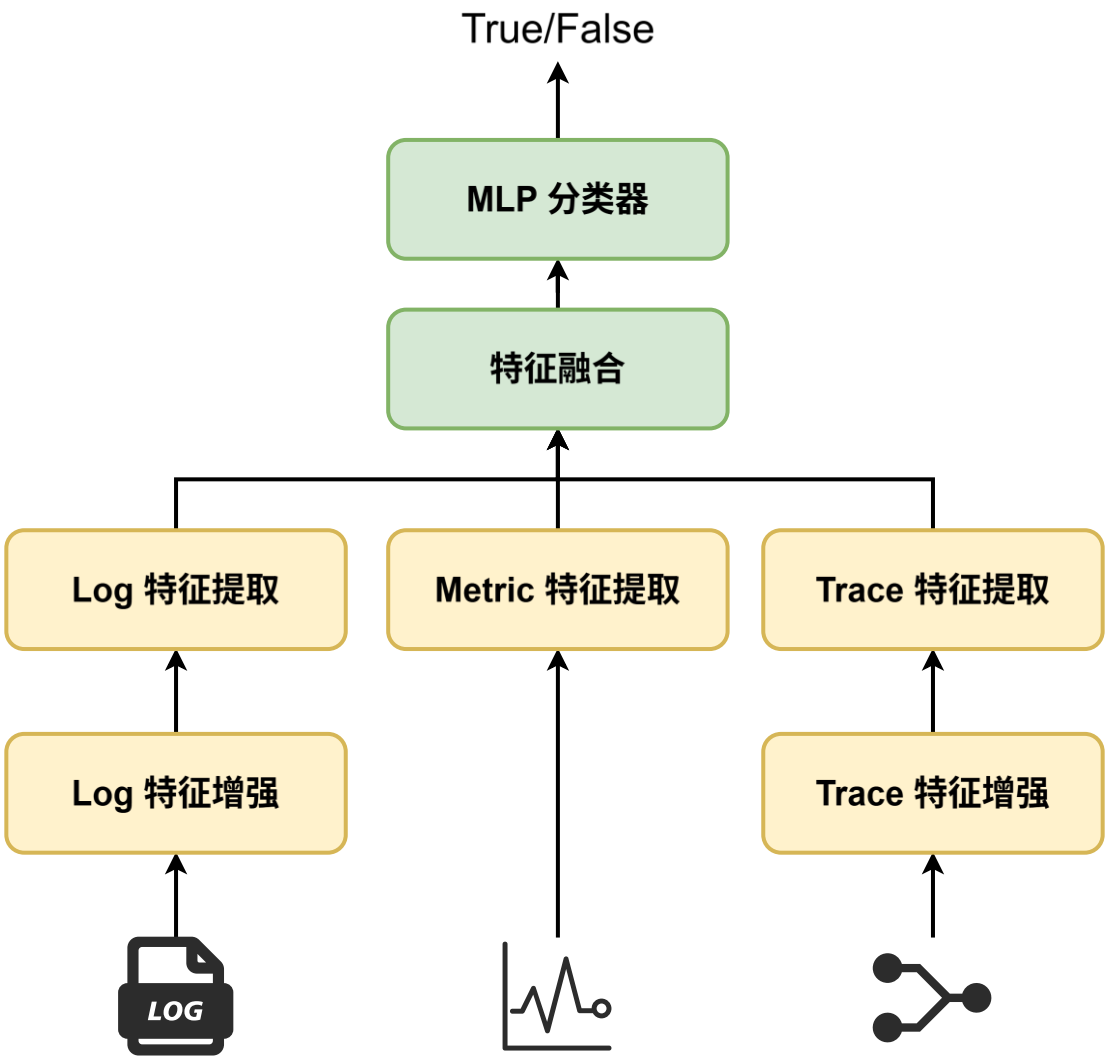

图 4 多源异构时序数据异常检测框架

1.2.2 基于多源异构时序数据特性的特征增强与提取技术研究

本小节围绕多源异构时序数据在原始信息表达能力有限、建模复杂度高等问题，聚焦两个核心技术挑战：（1）如何结合多源异构数据的结构差异与语义特性，开展有针对性的**特征增强**，提升其在信息维度上的表达能力；（2）如何设计高质量的**特征提取**方法，从增强后的数据中有效挖掘关键的时序表征，服务于后续的异常检测任务。

首先，**在特征增强阶段**，针对原始数据维度低、表达稀疏、信息冗余等问题，从数据的结构属性与语义属性出发，开展有针对性的特征增强工作。通过信息扩展与结构重构，引入更多具备判别价值的信息维度，将原始的低维稀疏特征转化为更具区分性的表示，为后续模型提供更强的先验支持。在本课题

中，metric、log、trace 三类数据在语义上彼此独立、在结构上差异显著，因而需分别定制其特征增强方法，以最大化各自的信息潜力。

其次，**在特征提取阶段**，面向已增强的数据表示，设计一系列结构差异化的深度编码器模块，以高质量挖掘各模态数据内部潜在的时间依赖性、空间结构性以及上下文语义关系[5, 8, 9]。编码器需具备较强的适应性与表达力，能够从异构数据中提取出稳定、判别性强的时序特征，为后续异常检测模型的建模提供坚实的数据支撑。

1.2.3 基于门控机制的异构特征融合技术研究

在微服务架构广泛应用的背景下，系统运行状态由指标（Metric）、日志（Log）和调用链追踪（Trace）三种异构时序数据多维描述，三者在表达能力上各具优势，但也存在强烈的结构异构性与语义互补性。因此为有效建模多源异构时序数据异构数据间动态协同关系，本课题拟提出一种**特征融合技术**，通过**门控融合单元**[10]动态学习各模态特征的权重分布，赋予模型自适应建模多源数据间语义贡献度的能力，提升融合表征的上下文适应性与异常判别能力，从而实现 metric、log 与 trace 特征的有效协同与加权整合。

具体而言，该机制将 metric、log 与 trace 特征输入门控融合层中，进行权重的自适应学习，之后进行加权融合，最终形成具有跨数据源表征能力的联合特征表示。这种设计兼顾了多源异构时序数据间信息的互补性和动态重要性调节能力，能够更充分地挖掘各数据源信息的协同价值，从而提升整体异常检测的判别能力。

1.2.4 实验评估

实验评估的主要目标是验证本文提出的多源异构时序数据异常检测框架的有效性，并探索以下内容：

（1）与当前主流的时序数据异常检测方法相比，本文提出的框架在多源异构时序数据异常检测任务中的**整体性能表现**如何；

（2）本文提出的**特征增强和提取技术**对于多源异构时序数据异常检测总体性能的提升作用；

（3）本文提出的**特征融合技术**对于多源异构时序数据异常检测总体性能的提升作用；

（4）不同模型框架的选择和参数的设置对总体异常检测性能的影响。

本文计划在公开数据集上进行实验评估，并与当前主流的时序数据异常检测方法在检测精度、召回率和 F1 得分等指标上进行对比。

2 已完成的工作

2.1 面向多源异构时序数据的异常检测框架设计

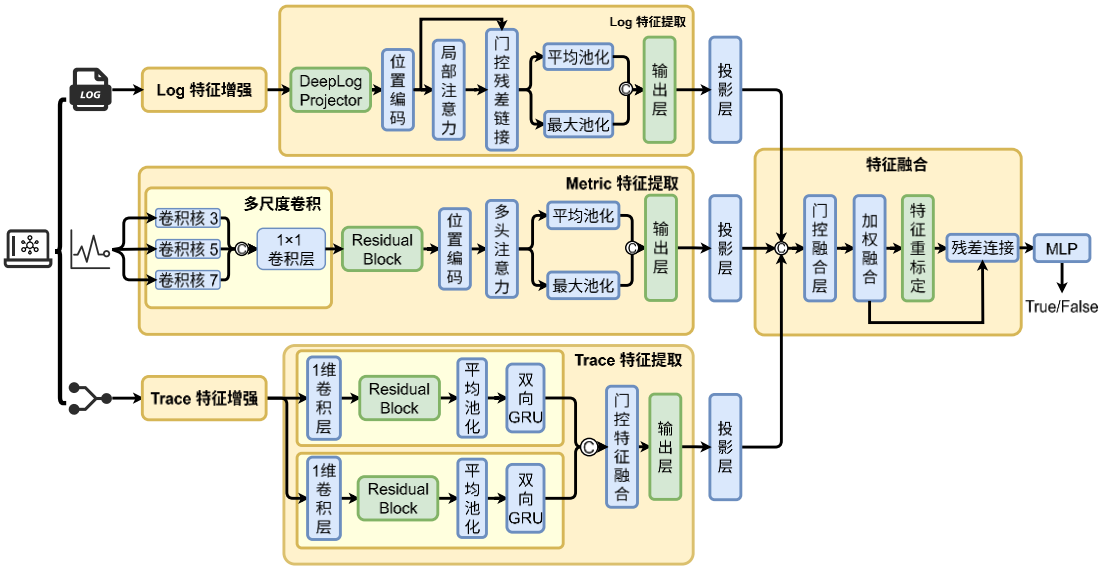

图 5 面向多源异构时序数据的异常检测框架

针对微服务系统中多源异构时序数据异常检测所面临的挑战，本文提出了一种面向多源异构时序数据的系统级异常检测框架。如图 5 所示，该框架以系统运行指标（Metric）、日志事件（Log）与调用链路追踪（Trace）三类数据为基础，构建了一个端到端的协同异常检测框架，致力于提升系统异常识别的准确性与鲁棒性。

在数据预处理阶段之后，结合各类数据源的结构特点与语义信息，进行定制化的**特征增强方法设计**，对原始数据进行信息扩展与结构增强，引入更多具备判别价值的信息维度，将原始的低维稀疏特征转化为更具区分性的表示。随后，分别针对三类异构时序数据设计了定制化的**特征提取技术**，独立提取三类异构时序数据中的关键特征。之后，为了实现特征空间的一致性，框架通过投影层将不同维度的特征映射至统一的特征空间，并进一步引入**基于门控机制的异构特征融合技术**，有效整合三类异构时序数据的特征，构建判别性更强的联合特征表示，最终输入分类器以完成异常检测任务。

本框架的主要创新点包括：

（1）构建了一种**面向多源异构时序数据的统一异常检测框架**，充分利用和融合微服务系统中指标、日志与调用链三类异构时序数据的信息潜力。

（2）针对多源异构时序数据的结构与语义差异，设计了差异化的**特征增强**方法，能够对原始数据进行有目的的信息扩展与结构增强，将原始低维、稀疏或表达能力有限的数据丰富化和增值化。

（3）针对多源异构时序数据的结构与语义差异，设计了定制化的**特征提取方法**，进一步挖掘多源异构时序数据内部各自的潜在时序依赖、特征交互与动态变化模式，实现对原始数据的高质量特征表示。

（4）提出了一个**基于门控机制的特征融合方法**，有效提升了异构特征融合的协同性与表达能力，增强了最终异常检测模型的泛化能力与判别性能。

2.2 基于多源异构时序数据特性的特征增强与提取技术研究

在特征增强方法的设计中，考虑到不同数据源的结构与语义差异，本文采用差异化的策略对日志（Log）和调用链路追踪（Trace）数据进行了结构化增强和信息挖掘，而对结构明确的指标（Metric）数据未进行额外特征增强处理。因为 Metric 数据本身为连续的数值型时序数据，能够直接反映系统各组件的运行状态，其数据结构清晰、语义明确定义[11]。因此，直接保留 Metric 的原始数据形式，依赖后续特征提取方法对其进行特征建模。

2.2.1 日志（Log）数据的特征增强和提取技术

（1） 日志（Log）数据的特征增强技术

Log 数据的特点分析。日志数据通常以半结构化的文本形式记录系统运行过程中的事件，其在异常检测中具有重要作用，但同时也存在以下挑战：

- **语义稀疏性：**日志内容往往以模板化形式呈现[12–15]，例如 "2021-07-01 10:54:22,639",INFO,0.0.0.4,c124e30fb40651dc,"now call service:redisservice1, inst:http://0.0.0.1:9386 as a downstream service"，其中的潜在异常信息被嵌入在格式化字符串中，导致语义信息稀疏且难以直接解析。
- **事件关联性：**系统异常往往不是孤立事件，而是多个日志事件以特定顺序或组合方式连续出现，如“鉴权失败 → API 访问异常 → 数据库锁表”等异常级联模式。

- **频次突变性**：异常发生时，某些日志模板（如错误类型）可能会在短时间内突发性增加，或出现日志分布的明显偏移，这些都是潜在的异常信号。

Log 数据的特征增强技术设计。针对上述特点，本小节设计了 Log 数据的特征增强技术，如图 6，将原始日志文本转换为结构化、易于建模的数值特征：

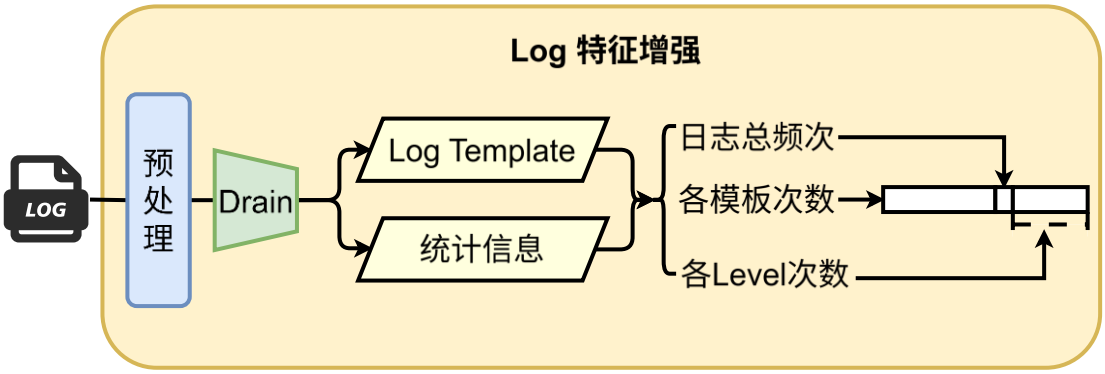

图 6 日志（Log）数据特征增强

- **模板提取与嵌入**：通过日志解析工具 Drain[16]提取日志模板，用标准化模板代替原始日志进行编码，降低语义稀疏性并便于后续建模[17]。
- **频次统计**：在固定时间窗口内，统计每个 Event Id 的出现频次，用于捕捉高频事件，尤其是错误类模板的异常增长行为。
- **模板比例关系**：计算各类模板之间的频率占比，监测比例关系的变化，以揭示异常条件下事件类型的分布失衡。
- **日志级别分布**：分别统计 INFO、ERROR 等日志等级的出现频次，评估当前时间段内系统运行的整体健康度。

通过上述策略，原始日志被转换为具有时序结构的高维特征向量，为后续异常检测提供了更具表达力的输入特征。

（2） 日志（Log）数据的特征提取技术

在日志异常检测任务中，日志模板统计向量作为输入特征，虽然携带着系统运行行为的重要语义信息，但其结构本身存在以下挑战：

- **高维稀疏性**[18]：日志模板种类通常在一个很大的量级，但在一个时间窗口内，仅会激活少量模板，导致日志模板统计向量极度稀疏。

- **隐式时序性**：日志事件之间通常存在弱顺序依赖，但日志模板本身缺乏显式的时间戳或顺序标识。
- **上下文依赖性**：系统异常往往表现为特定事件组合的协同模式，而非单一事件的孤立异常。

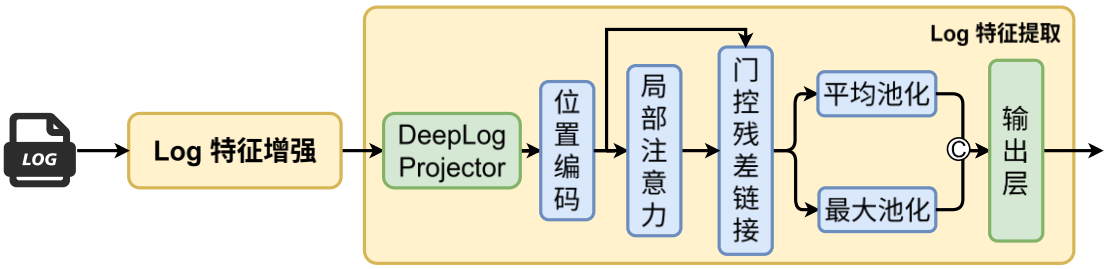

图 7 日志（Log）数据的特征提取

因此，基于以上特性，对于日志数据的特征提取技术需要提取事件分布中的语义信息；建模事件间的隐式上下文关系；将高维稀疏输入压缩为低维稠密表示；增强模型对异常事件模式的识别能力。对此，如图 7，本小节设计的特征提取技术，整体架构共分为四个阶段，分别是：

- 利用**深度投影网络**有效缓解高维稀疏问题；
- 通过**可学习位置编码**[19]与**局部注意力**[20]建模事件间上下文关系；
- 借助**门控残差连接**[21]来自适应融合原始与上下文特征；
- 使用**双池化策略**[22]强化异常模式捕捉能力。

深度特征投影（Deep Log Projector）。用于将高维稀疏的事件计数向量映射为低维嵌入表示，通过三级的逐层非线性变换完成语义压缩与特征抽取。首层将输入维度扩展为 $2 \times \text{embed_dim}$，缓解稀疏性影响，增强线性可分性；中间层维持扩展维度，保持特征表达空间；最后一层压缩回embed_dim，以匹配后续需求。

位置编码与多头局部注意力机制。日志模板时间序列缺乏明确时间戳，但其发生顺序蕴含系统行为的重要信息。该阶段通过引入**可学习的位置编码**和**局部注意力机制**，建模事件之间的上下文依赖。

- **可学习位置编码**

通过引入位置参数 $P \in R^{\mathbb{1} \times L \times D}$ 与特征相加：

$$X_{\text{pos}} = X + P$$

该机制替代传统正弦编码，更好适应日志事件的非等间隔、非均匀特性，同时捕捉隐式时序模式，发现事件发生顺序影响系统状态演化的规律。

- **局部注意力机制（Sparse Sliding Attention）**

在注意力权重的计算中，引入滑动窗口约束，限制每个位置仅与相邻 w 个事件进行交互。该机制在保持上下文建模能力的同时，将注意力复杂度由 $O(n^2)$ 降低为 $O(n \cdot w)$，更适用于长序列场景，且符合“**异常往往由邻近事件组合触发**”的实际模式。

门控残差特征融合。引入门控残差结构。门控信号可以自适应的学习保留历史模式或更新为上下文特征的比例，并且**残差结构**避免梯度消失问题，尤其适用于深层网络，同时保留原始计数特征的统计信息。该结构可以融合注意力输出与原始特征并自适应地控制信息流。

$$\text{Output} = \sigma(W_g \cdot X) \odot \text{Attn} + \left(1 - \sigma(W_g \cdot X)\right) \odot X$$

其中 $\sigma(\cdot)$ 为 Sigmoid 函数，W_g 为可训练的线性映射，$\odot$ 表示逐元素乘法。

双池化聚合与输出。最后，为综合考虑局部异常和全局状态，使用**双池化策略**（最大池化 + 平均池化）对时序输出进行压缩：

$$Y_{\text{pool}} = [\max(X);\ \text{mean}(X)]$$

随后，通过一层线性变换完成最终嵌入输出：

$$E = \text{LeakyReLU}\left(\text{LayerNorm}\left(W_{\text{proj}} \cdot Y_{\text{pool}}\right)\right)$$

2.2.2 调用链追踪（Trace）数据的特征增强和提取技术

（1） 调用链追踪（Trace）数据的特征增强技术

Trace 数据的特点分析。Trace 数据记录了微服务之间的调用链路信息，包含多维度指标，能够细致地描绘系统内部各模块的协作状态[23]。其主要特征包括：

- **多维指标性：**每一条调用链包含调用者标识、调用响应时延、返回状态码等多维信息，具有高度结构化特性。

- **频次与性能突变性**：在异常场景中，某些服务节点可能被频繁调用、调用延迟急剧上升，或大量请求返回错误状态码，均可作为潜在的异常指示。

Trace 数据的特征增强技术设计。针对上述特点，本小节设计了 Trace 数据的特征增强技术，如图 8，更有效挖掘 Trace 数据中的异常模式：

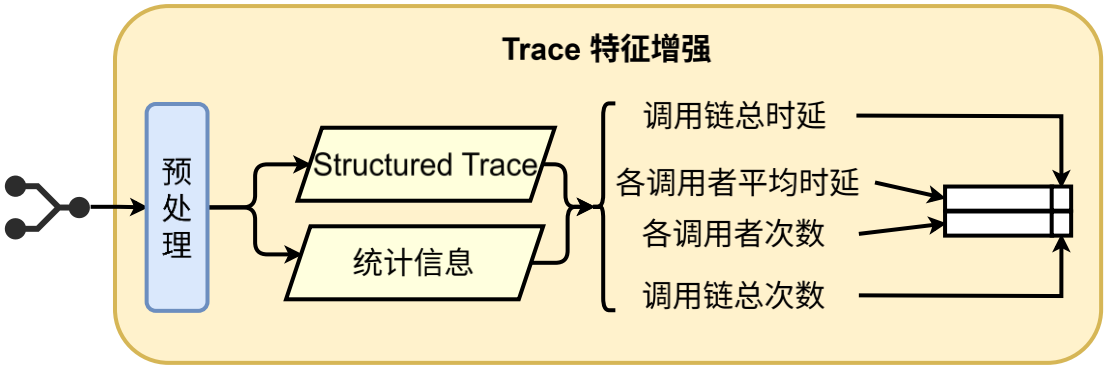

图 8 调用链追踪（Trace）数据的特征增强

- **调用者频次统计**：统计各服务节点作为调用方的出现频率，捕捉某些节点高频被调用的情况，揭示潜在的瓶颈或热点服务。
- **服务调用时延特征**：统计各调用方的平均/最大时延，监测调用延迟的突变情况，识别性能退化风险。
- **调用总次数与总时延**：衡量系统整体的调用活跃度与处理耗时，为异常判断提供全局性指标参考。

通过上述特征增强技术设计，Trace 数据被转化为可用于建模的结构化时序特征，增强了原始数据的可解释性与可判别性。

（2） 调用链追踪（Trace）数据的特征提取技术

调用链追踪（Trace）数据经过特征增强技术处理之后会提取出两个异构输入向量，分别是调用者的时延数据和调用次数两种类型。本小节设计了专用于调用链追踪输入向量的深度**特征提取技术**，旨在中提取出具有高质量的特征向量。其核心架构为**双分支神经网络**，每个分支独立处理一种类型的数据[24]，随后通过**门控机制**进行融合。如图 9，该特征提取技术通过如下技术路径应对调用链追踪数据的建模挑战：

- **残差**[21]**扩张**[25]**卷积**：实现局部与远程依赖的多尺度感知；
- **双向 GRU**[26, 27]：建模调用顺序与响应顺序的双向时序上下文建模；

- **门控融合机制**：对两分支实现自适应重要性加权融合。

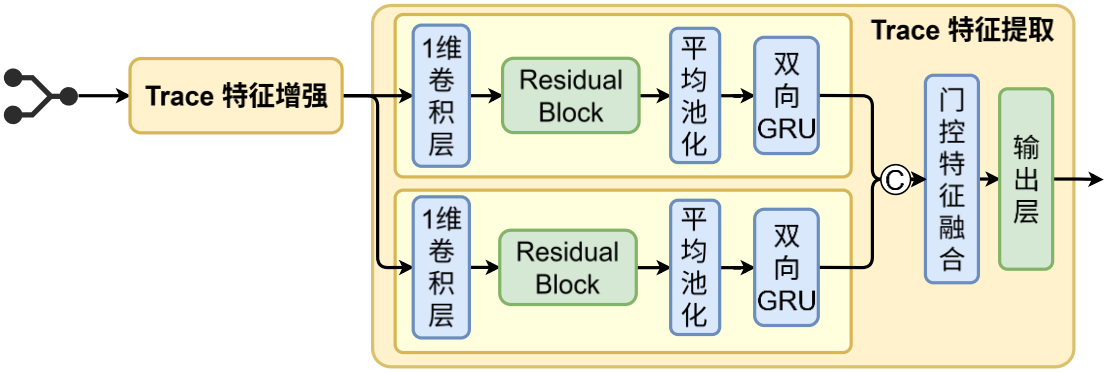

图 9 调用链追踪（Trace）数据的特征提取

层次化特征提取，残差扩张卷积。每个分支均通过一组卷积与残差结构进行特征提取。核心模块为带扩张率的残差块，其结构如下：

$$\mathrm{ResBlock}(x) = \mathrm{LeakyReLU}(F(x) + W_s x)$$

其中 $F(x)$ 表示卷积变换，W_s 为 1×1 卷积捷径映射。这种设计能在保持原始输入长度的前提下扩大感受野，有助于建模调用链中较远服务节点之间的依赖关系。

双向 GRU。对每一分支的卷积输出进行维度置换后输入至双向 GRU 网络：

$$h_t^{\rightarrow} = \mathrm{GRU}\,(x_t, h_{t-1}^{\rightarrow})$$
$$h_t^{\leftarrow} = \mathrm{GRU}\,(x_t, h_{t+1}^{\leftarrow})$$

最终从两个方向提取状态：前向最后一个状态：$h_{\mathrm{fw}} = h_T^{\rightarrow}$，反向第一个状态：$h_{\mathrm{bw}} = h_1^{\leftarrow}$。并拼接为该分支的特征：

$$e_{\mathrm{latency}} = [h_T^{\rightarrow}; h_1^{\leftarrow}] \in \mathbb{R}^{2H}$$
$$e_{\mathrm{count}} = [h_T^{\rightarrow}; h_1^{\leftarrow}] \in \mathbb{R}^{2H}$$

门控融合机制。融合层首先拼接两个分支的输出：

$$e_{\mathrm{concat}} = [e_{\mathrm{latency}}; e_{\mathrm{count}}] \in R^{4H}$$

然后通过一个门控网络生成融合权重：

$$\boldsymbol{g} = \mathrm{Softmax}\big(W_2 \cdot \mathrm{LeakyReLU}(W_1 \cdot e_{\mathrm{concat}})\big) \in R^{2}$$

融合后的表征为：

$$e_{\mathrm{fused}} = g_0 \cdot e_{\mathrm{latency}} + g_1 \cdot e_{\mathrm{count}}$$

其中 g_0, g_1 为门控向量中两个元素。

输出层。融合后的特征通过两层全连接映射为最终固定维度嵌入：

$$E = W_4 \cdot \mathrm{Dropout}\Big(\mathrm{BN}\big(\mathrm{LeakyReLU}(W_3 \cdot e_{\mathrm{fused}})\big)\Big)$$

该设计同时使用 BatchNorm[28]、Dropout 和非线性激活函数，有效避免过拟合与梯度饱和问题。

2.2.3 指标（Metric）数据的特征提取技术

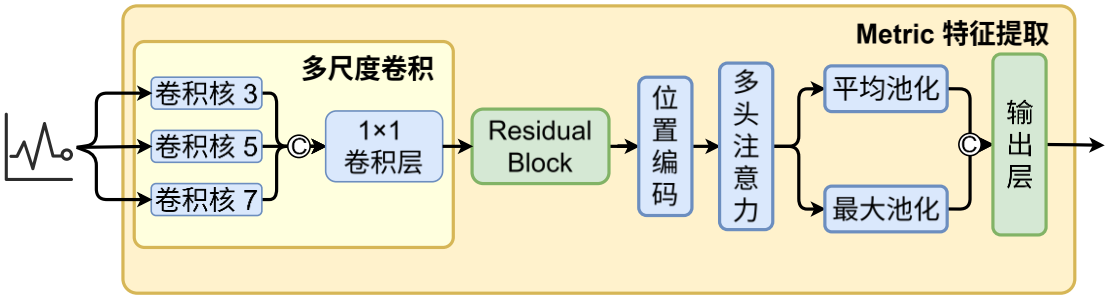

图 10 指标（Metric）数据的特征提取

如图 10，本小节设计了一种专用于多维指标时序数据建模的特征提取技术，以充分挖掘指标（Metric）类时序数据中的复杂模式与多尺度依赖关系。该技术以原始的连续数值型指标时序数据为输入，结合**多尺度卷积提取**[29]、**残差结构增强**[21]、**位置感知注意力机制**与**双池化聚合**策略，实现从局部模式到全局依赖的逐层特征提取过程，为后续的异常检测任务提供强判别性、高表达力的嵌入表示。

（1） 多尺度卷积

为捕捉指标数据在不同时间尺度上的局部模式，模型设计了三个并行的一维卷积分支，分别使用不同大小的卷积核（kernel size）进行特征提取。该结构可表示为：

- $\mathcal{F}_{short} = \mathrm{Conv}_3(X)$：捕捉**短期**特征；
- $\mathcal{F}_{mid} = \mathrm{Conv}_5(X)$：提取**中期**特征；
- $\mathcal{F}_{long} = \mathrm{Conv}_7(X)$：提取**长期**变化模式。

三个分支输出拼接形成多尺度特征张量：

$$Y_{\mathrm{multi}} = [\mathcal{F}_{short}; \mathcal{F}_{mid}; \mathcal{F}_{long}] \in \mathbb{R}^{B \times 3C \times L}$$

之后，为实现多尺度特征间的信息交互，同时压缩冗余通道维度，引入 1×1 卷积层进行跨通道融合，为后续残差块与注意力模块提供统一输入。

$$Y_{\text{fused}} = W_{\text{fusion}} \cdot Y_{\text{multi}}$$

其中$W_{\text{fusion}} \in \mathbb{R}^{2C\times 3C}$。

（2） 残差块 Residual Block

为了增强模型的非线性表达能力并缓解深层网络训练中的梯度消失问题，加入了标准的残差块结构：

$$\text{ResBlock}(X) = \sigma(\mathcal{W}_2(\sigma(\mathcal{W}_1(X))) + \mathcal{W}_{shortcut}(X))$$

（1）主路径$\sigma(\mathcal{W}_2(\sigma(\mathcal{W}_1(X)))$包含两个一维卷积层：

$$\mathcal{W}_1 = \text{Conv1d}(k = 3, \text{dilation} = 1)$$

$$\mathcal{W}_2 = \text{Conv1d}(k = 3, \text{dilation} = 1)$$

（2）捷径连接根据输入输出通道是否一致，采用 Identity 或 1×1 卷积

$$\mathcal{W}_{shortcut} = \begin{cases} \text{Identity} & \text{if } C_{in} = C_{out} \\ \text{Conv1d}(1\times 1) & \text{otherwise} \end{cases}$$

（3） 位置编码与多头注意力机制

为引入时序的全局依赖建模能力，在融合特征中加入位置编码，并引入多头自注意力机制：

- **位置编码注入：**

$$X_{\text{pos}} = X_{\text{in}} + P \text{where } P \in \mathbb{R}^{1\times L\times D}$$

- **多头自注意力机制：**

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

其中，$Q = K = V = X_{\text{pos}}$ （自注意力）

（4） 双池化聚合与输出

双池化指的**最大池化 + 平均池化**。最大池化能够捕捉**局部峰值**特征，识别突发型异常事件；平均池化能够保留**全局分布**趋势，捕捉持续性系统异常。

因此，双池化拼接后可兼顾整体分布与关键事件，融合局部显著性与全局上下文信息，最终通过线性投影进一步压缩并生成表征向量。

$$Y_{\text{pool}} = [max(Y_{\text{attn}}); mean(Y_{\text{attn}})]$$

在此基础上，通过双层前馈网络输出最终的嵌入向量：

$$E_{metric} = W_2\left(\sigma\left(\text{LayerNorm}\left(W_1\left(Y_{\text{pool}}\right)\right)\right)\right)$$

2.3 基于门控机制的异构特征融合技术研究

在多源异构时序数据的异常检测任务中，指标（Metric）、日志（Log）与调用链（Trace）三类数据在经历各自的特征增强与深度提取后，已形成具有语义表达能力的模态嵌入表示。然而，由于它们在数据分布、粒度结构与异常表达方式上的天然差异，直接拼接或简单融合往往难以充分发挥各模态间的互补潜力[30]，甚至可能引入噪声干扰。

为此，本文设计了一种**基于门控机制的异构特征融合技术**，通过引入**门控融合层**、**特征重标定结构**与**参数化残差连接机制**，动态学习各数据源在当前上下文中的语义贡献度，并增强融合表示的判别性与鲁棒性。该方法已集成至完整的异常检测框架中，并在多源异构数据场景下表现出良好的性能与适应性。

2.3.1 设计目标

该融合技术旨在实现以下三方面的关键功能：

（1）动态加权融合：基于当前输入上下文，自适应学习各数据源嵌入的重要性权重，实现信息层级的软选择；

（2）特征重标定[31]：通过维度注意力机制突出关键语义维度，有效抑制冗余或噪声特征；

（3）残差信息保留：引入参数化残差路径，在增强表示的同时保留原始融合信息的稳定性与完整性。

2.3.2 方法结构与技术路径

该融合方法整体结构如图 11 所示。输入为三个模态的嵌入表示 M_m, M_l, M_t，分别对应 metric、log 与 trace。经由门控融合路径处理后，得到最终融合表示 M_{final}，并输入至多层感知机[32]（MLP）进行二分类检测任务，输出异常标签。

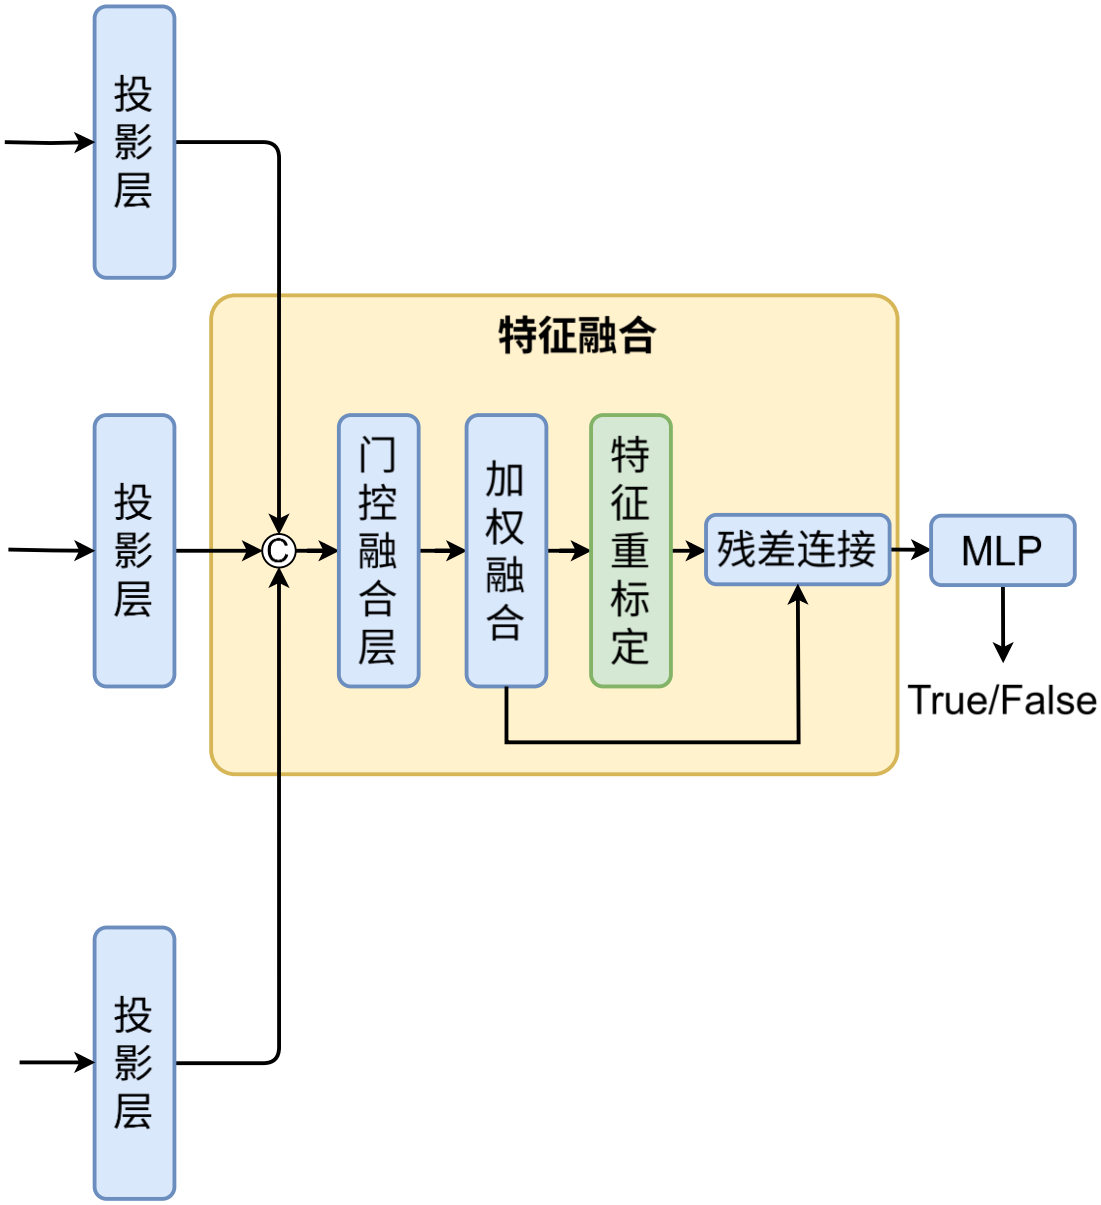

图 11 特征融合

（1） 门控融合层

首先对三类数据的嵌入表示特征维度上拼接得到联合上下文表示：

$$C = [M_m || M_l || M_t]$$

该拼接向量作为门控融合层的输入，提供跨模态的联合上下文信息，用于在门控融合层中动态计算权重 $\alpha = [\alpha_m, \alpha_l, \alpha_t]$，满足归一化约束$\sum_{i=1}^{3} \alpha_i = 1$

计算流程如下：

$$\mathbf{h}_g = \text{LayerNorm}\left(\text{LeakyReLU}\left(W_g^{(1)} \cdot \mathbf{C} + b_g^{(1)}\right)\right)$$

$$\boldsymbol{z} = W_g^{(2)} \cdot \mathbf{h}_g + b_g^{(2)}$$

$$\alpha_k = \frac{\exp(z_k)}{\sum_{j=1}^{3} \exp(z_j)} (k = 1,2,3)$$

其中 $W_g^{(1)} \in R^{3D \times D}$，$W_g^{(2)} \in R^{D \times 3}$。随后依据计算得到的权重 $\alpha_m, \alpha_l, \alpha_t$，进行嵌入加权求和，生成初步融合特征：

$$M_{\text{fused}} = \alpha_m \cdot M_m + \alpha_l \cdot M_l + \alpha_t \cdot M_t$$

该机制实现了模态级别的信息软选择，提升了融合表征对上下文的适应能力。

（2） 特征重标定（Feature Recalibration）

为进一步强化融合特征的语义表达能力，引入特征重标定机制，对各维度特征的重要性进行自适应建模。该模块通过**两层非线性变换**与 **Sigmoid 激活**，生成维度级别的注意力权重向量 $\mathbf{w}_{\text{enhance}} \in [0,1]^D$：

$$\mathbf{h}_e = \text{LayerNorm}\left(\text{LeakyReLU}\left(W_e^{(1)} \cdot M_{\text{fused}} + b_e^{(1)}\right)\right)$$

$$\mathbf{w}_{\text{enhance}} = \sigma\left(W_e^{(2)} \cdot \text{Dropout}(\mathbf{h}_e) + b_e^{(2)}\right)$$

该操作有效突出高价值特征维度，同时抑制噪声干扰，提升最终表征的判别能力。

（3） 参数化残差连接

为在增强表达的同时保持特征稳定性，融合过程中引入带可学习参数的残差结构，实现新旧信息的动态平衡：

$$M_{\text{final}} = \beta \cdot M_{\text{fused}} + (1 - \beta) \cdot M_{\text{fused}} \odot w_{\text{enhance}}$$

其中 $\beta \in [0,1]$ 为可学习权重参数，用于控制原始融合信息与重标定特征之间的比例。训练初期设 $\beta = 0.7$，鼓励模型优先利用稳定融合特征，后续通过反向传播自动优化至最优配置。

（4） 多层感知机分类器（MLP Classifier）

最终融合表示 M_{final} 被送入一个多层感知机（MLP）分类器，执行二分类异常检测任务。该分类器由三层线性映射组成，维度逐层缩减，辅以 LeakyReLU 激活函数、Batch Normalization 与 Dropout 正则化，结构如下：

- **第一层**：线性变换 $D \rightarrow D/2D, LeakyReLU, BatchNorm, Dropout$；
- **第二层**：线性变换 $D/2 \rightarrow D/4, LeakyReLU, BatchNorm, Dropout$；
- **第三层**：线性变换 $D/4 \rightarrow num_{classes}$，输出分类结果。

该分类器结构具备较强的非线性建模能力与泛化能力，能够对融合后的高维特征进行有效判别，从而完成对异常行为的识别。

2.4 实验评估

2.4.1 研究问题

为验证本文所提出的**多源异构时序数据异常检测框架**的有效性，研究工作将围绕以下四个核心问题展开，系统地评估该方法在实际应用中的可行性与优势。

（1）整体性能评估：本部分旨在全面评估所提出框架在**多源异构时序数据异常检测任务**中的表现。通过与当前主流的单一时序数据和多源异构时序数据异常检测方法进行对比实验，从检测准确率、鲁棒性与适用性等维度系统分析该框架的综合性能，验证其在真实复杂系统中的竞争力和实用性。

（2）特征增强和提取技术的作用：本文针对多源异构时序数据（包括指标数据、日志数据、调用链数据）的异质性特点设计并实现了专属的**特征增强和提取技术**。本研究将分析其在数据表示能力和异常感知能力方面的表现，评估其对下游检测性能的贡献，进而验证其合理性与有效性。

（3）特征融合技术的作用：本研究重点探讨所提出的**特征融合技术**在提升异常检测性能方面的作用。通过与传统的拼接、平均或注意力机制等融合方式

进行比较，评估本文融合技术是否能够更好地整合不同模态的信息，从而提供更加**全面、精准、稳定**的检测结果。

（4）框架优化探究：在现有框架基础上，进一步探索引入不同神经网络结构（如 Transformer、TCN、GNN 等）对检测性能的影响。具体将从以下几个方面展开分析：

- **特征增强和提取技术优化**：探讨替换不同卷积层、门控层或自注意力机制对特征提取质量的影响；
- **融合机制对比**：尝试引入更复杂的融合策略（如多头门控、模态注意力等）；
- **参数设置与模型调优**：分析关键参数（如 GRU 层数、嵌入维度、Dropout 率等）、Loss 函数等对模型性能的敏感性。

通过一系列设计对比实验，系统评估框架的**可调性、可扩展性与稳定性**，进一步验证其在多场景下的泛化能力。

2.4.2 实验数据集

为全面评估所提出的多源异构时序数据异常检测框架的有效性，本文选取了两个具有代表性的公开数据集，都涵盖了指标（metric）、日志（log）与调用链（trace）三种类型的时序数据，具备丰富的系统行为特征和真实故障注入记录，能够支持对模型准确性、鲁棒性和泛化能力的深入分析。

（1） 数据集 D1：Generic AIOps Atlas（GAIA）

第一个实验数据集（以下简称 D1）是 CloudWise 提供的通用 AIOps 数据集 Generic AIOps Atlas（GAIA）。该数据集来源于 CloudWise 内部的业务模拟系统 MicroSS，系统共由 10 个实例组成，能够模拟真实分布式系统中的运行状态和故障模式。GAIA 数据集的主要特点如下：

多源异构时序数据完整覆盖：在连续两周内，系统共采集了超过 70 万条监控指标、8700 万条日志以及 2800 万条调用链跟踪记录，涵盖了微服务系统运行过程中的各类观测信息。

真实故障注入机制：通过控制用户行为并模拟对系统的误操作，引入了若干典型异常场景，如 二维码生成失败、系统卡顿、文件无法访问、权限拒绝

等。所有异常注入均提供了详细记录，便于后续评估异常检测及故障定位性能。

系统全面性：MicroSS 中对业务系统的每一个实体和执行行为进行了全方位监控，涵盖日志、指标及调用链等多种类型的系统行为信息，为多源异构时序数据联合建模提供了理想基础。

该数据集具有极高的真实性和复杂性，广泛用于 AIOps 领域的异常检测、日志分析、根因定位等研究任务，是当前学术界具有代表性和挑战性的数据集之一。

（2） 数据集 D2：多源异构时序数据分布式系统公开数据集

第二个实验数据集（以下简称 D2）选自文献[25]中提出的 多源异构时序数据分布式系统数据集，该数据集同样包含指标、日志与跟踪三种模态，聚焦于分布式环境下的系统行为建模，具有如下特性：

节点覆盖性强：数据采集自 5 个不同的分布式节点，能够反映多节点间的状态差异和协同行为。

数据量充足：共包含 829,562 条日志数据 和 1,195,637 条监控指标，其中每个节点平均拥有约 239,127 个指标，提供了较为完整的系统运行视图。

2.4.3 实验基线模型

在实验评估中，将本文提出的方案与两个基于单一数据源的方法和一个基于多源异构时序数据的方法进行比较：

（1）AnoFusion[1]：一种**面向微服务系统的多模态故障检测方法**。该方法结合指标（Metrics）、日志（Logs）和调用链（Traces）三种异构模态数据的无监督故障检测框架。核心思想是利用**图神经网络**对多模态数据进行建模与时序建模，将每一时刻的多模态监控数据构建为**异构图**，采用 **GTN** 对多模态节点间关系进行建模，捕获模态间复杂依赖。

（2）SCWarn[33]：一个用于识别 **软件变更引发故障** 的自动化检测系统。基于 **多模态 LSTM** 构建时间序列模型，融合业务指标、机器指标与结构化日志；引入 **异常评分机制**，基于预测残差进行故障判定；

（3）**TranAD**[34]：一种基于 Deep Transformer 网络的多元时间序列数据异常检测模型。其通过**注意力机制**捕捉广泛的时间趋势，并利用**对抗式训练**过程增强对数据模式的识别能力。它引入了自我调节和模型无关元学习（MAML）等技术，实现了在有限数据下的高效训练和推理。

2.4.4 评估指标

为了全面评估异常检测方法的性能，本实验采用了**精度（Precision）**、**召回率（Recall）**和 **F1-score** 作为评估指标。这些指标广泛用于异常检测方法的评估。

（1）精度（Precision）

精度是指模型检测出的所有异常中，实际为异常的比例，公式如下：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

其中，TP（True Positive）为正确检测的异常数，FP（False Positive）为误报的正常数据数。精度反映了模型在检测异常时的准确性。

（2）召回率（Recall）

召回率是指实际异常中被模型正确识别的比例，公式如下：

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

其中，FN（False Negative）为模型漏检的异常数。召回率衡量了模型检测异常的全面性。

（3）F1-score

F1-score 是精度和召回率的加权调和平均值，公式如下：

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

F1-score 在精度和召回率之间寻求平衡，是综合评价模型性能的重要指标。

通过这些指标，可以分别评估模型的异常检测能力在准确性、全面性和整体表现上的优劣，从而全面衡量方法的有效性。

2.4.5 实验结果与分析

（1） 研究问题一：框架整体性能评估

已完成整个多源异构时序数据异常检测模型 **M3FusionAD** 的设计与实现，并针对所选的两个数据集（D1 和 D2）按照框架的需求进行了系统的预处理与格式统一工作。在此基础上，进一步开展了实验评估，以验证所提出方法在多源异构时序数据异常检测任务中的有效性与鲁棒性。实验结果如表 1：

D1 数据集

表 1 D1 数据集上实验结果

	Precision	Recall	F1
AnoFusion	0.795	0.945	0.857
SCWarn	0.547	0.425	0.447
TranAD	0.107	0.99	0.193
M3FusionAD	0.9298	0.5668	0.8915

在 **D1 数据集**上，M3FusionAD 表现较好，尤其在 Precision（0.9298）和 F1 值（0.8915）方面，相较于 AnoFusion（0.795 / 0.857）和 SCWarn（0.547 / 0.447）均有明显提升，说明模型在多源异构特征融合下具有更强的异常判别能力。但同时可以看到，Recall 值为 0.5668，明显低于 AnoFusion（0.945），说明模型对部分异常样本的召回能力仍有待提升。

造成 Recall 较低的可能原因包括：

- 模型偏向于保守地输出高置信度异常，导致部分边界样本未被覆盖；
- 多源异构特征融合策略可能对部分模态过拟合，降低了整体对某些异常模式的感知能力；

D2 数据集

表 2 D2 数据集上实验结果

	Precision	Recall	F1
AnoFusion	-	-	-
SCWarn	-	-	-
TranAD	0	0	0
M3FusionAD	0.045	1	0.3892

在 **D2 数据集**上，如表 2，检测效果较差。TranAD 完全无法识别异常（Precision 和 Recall 均为 0），而 M3FusionAD 尽管 Recall 达到 1，，但 Precision 仅为 0.045，导致 F1 值较低（0.3892），暴露出严重的误报问题。该现象可能归因于以下几点：

- D2 数据集本身质量较差，如标注不一致、模态间时序对齐不佳等
- M3FusionAD 当前的门控机制与池化策略未能充分适应 D2 的数据分布，存在过拟合或泛化不足；
- 预处理过程中对于 D2 的时间窗或特征抽取参数不合理，影响了模型的表达能力。

综上，M3FusionAD 在多源异构时序数据的异常检测场景下具备一定的检测能力，尤其在高精度和融合表达上具备显著优势。但仍需重点优化召回性能与泛化能力，尤其是在复杂或低质量数据集上的适配性。后续工作可从改进模态对齐策略、引入更强的异常感知模块，以及增强模型对少数类的学习能力等方面进行深入探索。

（2） 研究问题四：框架优化探究

为提升模型在 D1 数据集上异常检测任务的性能，在实际工作中进行了很多次的探索优化，优化目标聚焦于**提升模型精度（Precision）**、**保持较高召回率（Recall）**、**减少误报（FP）**，并通过多轮实验验证优化有效性。如表 3 所示为每次优化前后的性能变化：

表 3 优化前后实验结果

	Precision	**Recall**	**F1**
第一阶段	0.2078	1	0.0715
第二阶段	0.2422	0.9144	0.1654
第三阶段	0.9298	0.5668	0.8915

核心优化阶段过程如下所述：

阶段一：基础模型训练结果。

在初始模型训练过程中，采用 StableAnomalyDetectionLoss 损失函数，设置较高的 recall_weight 和 fn_penalty 强调召回率。训练在 10 轮内快速收敛，但暴露出以下严重问题：

- 模型在验证集上异常类召回率达到 **1.0000**，但精度仅为 **0.2709**，验证集 F1 分数停留在 **0.4263**；
- 几乎所有样本都被预测为异常（验证集异常预测比例达 **100%**），即：**正常样本全部被误判（TN=0）**；
- 测试集精度仅为 **0.2078**，整体 F1 为 **0.0715**，说明模型缺乏有效的异常判断边界。

根因分析表明，模型训练时受到损失函数中异常强化项主导，出现过拟合异常类的倾向，急需优化。

阶段二：优化异常权重参数、增加 TN 强化。

本阶段优化聚焦于两个核心问题：**误报过多（FP 高）与阈值不合理（固定值）**。具体优化操作如下：

- **优化 1：调整损失函数参数**

  弱化异常样本惩罚项，调整为：

  "recall_weight": 5.0, "fn_penalty": 10.0, "pos_weight": 2.0

该设置降低对异常召回的过度偏向，释放模型对正常样本的判别能力。

- **优化 2：奖励正常样本预测正确（TN 强化）**

  在 StableAnomalyDetectionLoss 中新增 TN 强化函数，鼓励模型降低正常样本的异常概率，从而强化 TN。

实验结果显示测试集 F1 提升至 **0.1654**，仍有较多的误判，需要进一步优化。

阶段三：优化阈值选择策略、更换神经网络模块。

为进一步抑制误报并提升整体精度，在第三阶段引入以下关键优化：

- **优化 1：进一步降低异常样本损失权重**

  将权重设为："recall_weight": 3.0, "fn_penalty": 5.0, "pos_weight": 1.5

- **优化 2：动态阈值选择策略**

  使用 sklearn.metrics.precision_recall_curve 计算 P-R 曲线，选择 F1 分数最大的点作为最优阈值（而非固定）。

- **优化 3：多次更换神经网络模块**

模型不再依赖压倒性的召回率，Precision 显著提升至 **0.9298**，同时保持良好的异常检测能力。验证集与测试集性能一致性增强，模型泛化能力获得明显改善。

本章节探究验证了基于多策略组合的模型优化路径，较好解决了初始模型中“全异常预测、精度低、误报严重”等问题。最终优化版本兼顾异常检测召回率与精度，展现出较好的稳定性与进一步优化潜力。

3 关键技术

为实现对多源异构时序数据的高效建模与异常检测，本文围绕“**特征增强和提取**”与“**特征融合**”两个核心关键技术环节进行了深入设计与优化。本章将对所采用的关键技术进行系统阐述。

3.1 基于多源异构时序数据特性的特征提取技术

在微服务系统中，监控数据呈现出强异构性特征：指标（Metric）为连续数值型时间序列，日志（Log）为半结构化事件流，调用链（Trace）则体现为服务间的时序调用信息。这种结构差异使得统一处理策略难以有效提取各模态中的关键特征。若直接采用通用建模方式，容易导致信息压缩、语义丢失或模态干扰，影响最终检测效果。因此，本文针对三种异构时序数据分别设计了定制化的特征增强和提取技术，以充分挖掘各自的异常表达模式。

然而，在实际工作过程中，定制化特征提取面临多项挑战。**一方面**，不同数据源之间存在维度、结构与时间粒度的差异，使得特征提取技术必须具备高度的结构适应性；**另一方面**，在生产环境中常会遇到数据缺失、指标数量波动大、调用链深度不一致等问题，对提取器的鲁棒性提出更高要求。此外，高频指标或大规模日志在处理时也存在计算资源压力。

为此，本文提出如下应对策略与模技术设计：

Metric ：构建**多尺度卷积** + **注意力**结构，以捕捉局部趋势与全局依赖特征，同时通过自动转置机制适配不同输入维度；

Log ：利用日志模板构建结构化统计向量，结合**全连接神经网络**与**位置编码**建模事件上下文，增强序列模式识别能力；

Trace ：采用**双分支卷积网络**分别提取调用次数与时延信息，结合双**向 GRU** 进行时序建模，并引入**门控融合机制**整合模态内语义。

此外，为增强模型适应性，本文在特征提取过程中引入自适应池化、Dropout 正则化与残差连接等结构，有效缓解输入规模不均、特征过拟合与梯度消失等问题，确保模型在复杂场景下仍具备良好的鲁棒性与计算效率。

3.2 基于门控机制的异构特征融合技术

在多源异构时序数据的异常检测任务中，不同类型数据往往存在信息互补关系：**指标反映系统运行状态趋势，日志揭示操作事件演化过程，调用链呈现请求路径与服务依赖结构。**若仅依赖单一数据源进行建模，往往难以全面捕捉异常模式，易出现误检或漏检。因此，如何有效融合三类数据中提取的高质量特征，成为提升整体检测性能的关键。然而，异构数据间存在表达尺度不一致、信噪比差异显著以及异常信号表达方式不统一等问题，稍有不慎便可能在融合过程中引入冗余信息，甚至掩盖关键特征。

为此，本文提出一种**基于门控机制的异构特征融合方法**，集成了**门控融合机制**、**特征重标定机制**与**参数化残差连接机制**，旨在充分整合异构模态信息的同时，增强判别维度、抑制噪声干扰，并保留原始信息中的稳定结构。具体设计包括：

- **门控融合机制**：通过两层**全连接结构**结合 **Softmax 函数**生成模态权重，动态建模每个模态在当前上下文中的语义贡献，实现模态级别的自适应融合；
- **特征重标定机制**：采用**双层线性映射**与 Sigmoid 激活生成维度级注意力权重，突出关键信息维度，弱化冗余与干扰特征；
- **参数化残差连接机制**：引入**可学习残差系数** β，实现原始融合特征与增强特征之间的动态平衡，提升融合过程的稳定性与泛化能力。

在实际部署过程中，融合过程亦面临若干挑战，如早期模态权重不稳定、重标定过程存在过拟合风险，以及融合特征分布偏移对下游分类器性能造成影响。对此，本文引入如下改进策略以提高融合质量与系统鲁棒性：

- 使用 **LayerNorm** 替代 **BatchNorm**，增强模型对小批量异构输入的适应能力；
- 在特征重标定中加入 **20% Dropout**，缓解过拟合；
- 对融合输出进行归一化与维度压缩处理，以匹配下游 MLP 分类器结构并确保特征分布的一致性。

4 下一阶段工作计划

4.1 存在的问题

4.1.1 D2 数据集异常检测性能不佳

在对两个数据集进行实验评估的过程中，模型在 D2 数据集上的整体检测效果明显低于其他数据集。具体表现见 2.4.5（1）。

综合分析，造成上述现象的潜在原因包括：

（1） D2 数据集质量存在问题

- 数据标注可能存在漏标、错标等现象，导致模型训练受噪声影响；
- 多源异构时序数据之间在时间戳上存在不同步问题，导致特征融合效果受限；
- 异常样本与正常样本之间区分度低，分布重叠，难以建立有效的分类边界。

（2） 模型结构对 D2 数据不具鲁棒性

- 当前的门控融合机制对异常信号缺乏足够的抑制，可能对部分模态中的异常敏感而误判；
- 自适应池化策略在 D2 数据的特征分布下效果不佳，可能丢失了关键时序信息；

（3） 预处理策略不匹配 D2 数据特点

- 时间窗大小、滑动步长等参数未针对 D2 特征进行调优，影响了序列建模；
- 特征工程中未对各异构时序数据的尺度和异常分布进行统一规范，造成融合阶段信号失衡；
- 现有滑窗切分方法可能破坏了 D2 中异常事件的连续性，导致模型难以捕捉有效上下文信息。

4.2 尚未完成的工作

总体而言，目前大约已完成毕设总工作量的 50%。已经完成的工作包括：**面向多源异构时序数据的异常检测框架设计与实现、基于多源异构时序数据的特征增强和提取技术设计与实现、基于门控机制的异构特征融合技术设计与实现**，并在 D1 和 D2 数据集上完成**部分实验分析**与**整体框架的初步调优**。

表 4 下一阶段计划表

工作	进度	完成情况
面向多源异构时序数据的异常检测框架设计	100%	✓
基于多源异构时序数据特性的特征增强与提取技术研究	100%	✓
基于门控机制的异构特征融合技术研究	100%	✓
实验评估	40%	✕
（1）整体性能评估	60%	✕
（2）特征增强和提取技术的作用	0%	✕
（3）特征融合技术的作用	0%	✕
（4）框架优化探究	60%	✕

目前未完成的工作包括：

（1） 基线方法在数据集上的完整适配与实验复现

当前实验仅在部分数据集上完成了部分基线方法的运行和对比，尚未实现对全部目标数据集 D1、D2 的适配和实验评估。需进一步统一输入格式、调整超参数并完成全量实验，以确保对比结果的公平性和全面性，为后续模型性能评价和分析提供可靠依据。

（2） 特征提取技术的效果可视化与定量分析

尽管已实现面向多源异构时序数据（metric、log、trace）的定制特征提取技术，但其实际在数据表示质量、异常感知能力等方面的作用尚未充分验证。

后续工作将重点通过消融实等方式，分析各类特征提取技术对最终检测效果的影响，进一步明确设计合理性。

（3） 特征融合技术对性能提升的贡献评估

目前已完成特征融合技术设计和实现，但尚未系统开展与传统融合方式（如直接拼接、平均融合、注意力加权等）的对比实验。后续将通过结构消融与替代实验，分析本研究提出的融合方式在整合多源异构信息、提升检测精度与稳定性方面的优势与局限，进一步优化融合策略。

（4） 数据集适配与扩展工作

D2 数据集的实验效果表现不佳，存在质量不高、分布复杂等问题。后续将尝试引入新的数据集进行对比实验，或通过清洗增强、合成扩展等方式改善数据质量，确保模型训练与评估过程更加稳健。必要时，也将考虑替换掉部分难以适配的数据集，以提升整体评估的参考价值。

4.3 解决问题的技术思路或措施

4.3.1 解决 D2 数据集异常检测性能不佳的思路

为提升模型在 D2 数据集上的检测性能，需从数据质量、模型结构和预处理策略等多个层面进行优化。具体改进方案如下：

（1） 增强 D2 数据质量与一致性：

- 对 D2 原始数据进行人工抽检与异常可视化分析，重新校验标签质量；
- 对多源异构时序数据进行统一的时间戳重对齐操作（如通过插值或对齐 anchor 时间窗），确保各模态同步；
- 尝试引入数据清洗步骤，如去除重复或明显错误数据点，提升训练数据质量。

（2） 优化预处理参数以适应 D2 特性：

- 针对 D2 数据的事件时长与分布密度，重新设计时间窗口大小与滑窗步长（如增大时间窗口捕获完整上下文）；
- 在特征工程阶段对不同数据类型的特征进行归一化处理，并进行异常敏感度分析，避免部分模态主导异常判断；

（3） 增强模型对不平衡数据的鲁棒性：

- 在损失函数中引入 **类别不平衡补偿项**，降低模型对异常标签的过拟合；
- 优化**注意力机制**，弱化对低质量模态的依赖；

（4） 尝试替换或引入辅助数据集以增强模型适配性：

- 考虑替换当前的 D2 数据集或引入与其相似结构的其他公开数据集，用于辅助训练或评估；
- 若 D2 数据确实质量偏低、分布异常、不具备代表性，则有必要重新选取结构更清晰、标注更准确、模态对齐更完善的数据集，确保评估结果具有可信度；

4.4 下一阶段计划

表 5 下一阶段计划表

时间	计划
2025.07~2025.08	完成所有基线方法在数据集上的适配与实验复现，开展完整的对比实验；必要时更换额外数据集的适配与测试，确保评估结果全面有效。
2025.08~2025.09	开展特征提取技术的消融实验与可视化分析，评估其在表示能力和检测精度方面的贡献。。
2025.09~2025.10	完成特征融合技术的对比实验与优化设计，分析融合方式对模型整体性能的影响；同步开展模型整体效果的优化与调参。
2025.10~2025.11	整理实验结果，撰写框架设计思路与各技术性能分析部分，完成论文主体内容初稿。。
2025.11~2025.12	补充图表和相关引用文献，完成毕业论文定稿与查重准备，进行答辩演示内容准备，完成毕业答辩。

5 主要参考文献

[1] Zhao C., Ma M., Zhong Z., et al. Robust Multimodal Failure Detection for Microservice Systems[A]. Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining[C]. Long Beach CA USA: ACM, 2023: 5639-5649

[2] Xu H., Wang Y., Jian S., et al. Calibrated One-Class Classification for Unsupervised Time Series Anomaly Detection[J]. IEEE Transactions on Knowledge and Data Engineering, 2024: 1-14

[3] Jin M., Koh H. Y., Wen Q., et al. A Survey on Graph Neural Networks for Time Series: Forecasting, Classification, Imputation, and Anomaly Detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024,46(12): 10466-10485

[4] Zamanzadeh Darban Z., Webb G. I., Pan S., et al. Deep Learning for Time Series Anomaly Detection: A Survey[J]. ACM Computing Surveys, 2025,57(1): 1-42

[5] Meng W., Liu Y., Zhu Y., et al. LogAnomaly: Unsupervised Detection of Sequential and Quantitative Anomalies in Unstructured Logs[A]. Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence[C]. Macao, China: International Joint Conferences on Artificial Intelligence Organization, 2019: 4739-4745

[6] Zhang C., Peng X., Sha C., et al. DeepTraLog: Trace-Log Combined Microservice Anomaly Detection through Graph-Based Deep Learning[A]. Proceedings of the 44th International Conference on Software Engineering[C]. Pittsburgh Pennsylvania: ACM, 2022: 623-634

[7] Liu X., Liu Y., Wei M., et al. LMGD: Log-Metric Combined Microservice Anomaly Detection through Graph-Based Deep Learning[J]. IEEE Access, 2024: 1-1

[8] Wu H., Hu T., Liu Y., et al. TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis[EB]. arXiv, 2023

[9] Yue Z., Wang Y., Duan J., et al. TS2Vec: Towards Universal Representation of Time Series[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2022,36(8): 8980-8987

[10] Arevalo J., Solorio T., Montes-y-Gómez M., et al. Gated Multimodal Units for Information Fusion[EB]. arXiv, 2017

[11] Schmidl S., Wenig P., Papenbrock T. Anomaly Detection in Time Series: A Comprehensive Evaluation[J]. Proceedings of the VLDB Endowment, 2022,15(9): 1779-1797

[12] Jiang Z., Liu J., Huang J., et al. A Large-Scale Evaluation for Log Parsing Techniques: How Far Are We?[A]. Proceedings of the 33rd ACM SIGSOFT International Symposium on Software Testing and Analysis[C]. New York, NY, USA: Association for Computing Machinery, 2024: 223-234

[13] Du M., Li F., Zheng G., et al. DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning[A]. Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security[C]. Dallas Texas USA: ACM, 2017: 1285-1298

[14] Meng W., Liu Y., Zaiter F., et al. LogParse: Making Log Parsing Adaptive through Word Classification[A]. 2020 29th International Conference on Computer Communications and Networks (ICCCN)[C]. Honolulu, HI, USA: IEEE, 2020: 1-9

[15] Zhang T., Qiu H., Castellano G., et al. System Log Parsing: A Survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2023: 1-20

[16] He P., Zhu J., Zheng Z., et al. Drain: An Online Log Parsing Approach with Fixed Depth Tree[A]. 2017 IEEE International Conference on Web Services (ICWS)[C]. Honolulu, HI, USA: IEEE, 2017: 33-40

[17] Guo H., Yang J., Liu J., et al. LogFormer: A Pre-Train and Tuning Pipeline for Log Anomaly Detection[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2024,38(1): 135-143

[18] Yadav R. B., Kumar P. S., Dhavale S. V. A Survey on Log Anomaly Detection Using Deep Learning[A]. 2020 8th International Conference on Reliability, Infocom

Technologies and Optimization (Trends and Future Directions) (ICRITO)[C]. Noida, India: IEEE, 2020: 1215-1220

[19] Vaswani A., Shazeer N., Parmar N., et al. Attention Is All You Need[J]

[20] Child R., Gray S., Radford A., et al. Generating Long Sequences with Sparse Transformers[EB]. arXiv, 2019

[21] Shafiq M., Gu Z. Deep Residual Learning for Image Recognition: A Survey[J]. Applied Sciences, 2022,12(18): 8972

[22] Lecun Y., Bottou L., Bengio Y., et al. Gradient-Based Learning Applied to Document Recognition[J]. Proceedings of the IEEE, 1998,86(11): 2278-2324

[23] Chen J., Liu F., Jiang J., et al. TraceGra: A Trace-Based Anomaly Detection for Microservice Using Graph Deep Learning[J]. Computer Communications, 2023,204: 109-117

[24] Wang H., Mo Y., Xiang K., et al. CSformer: Combining Channel Independence and Mixing for Robust Multivariate Time Series Forecasting[J]

[25] Yu F., Koltun V. Multi-Scale Context Aggregation by Dilated Convolutions[EB]. arXiv, 2016

[26] Schuster M., Paliwal K. K. Bidirectional Recurrent Neural Networks[J]. IEEE Transactions on Signal Processing, 1997,45(11): 2673-2681

[27] Cho K., Merrienboer B. van, Gulcehre C., et al. Learning Phrase Representations Using RNN Encoder-Decoder for Statistical Machine Translation[EB]. arXiv, 2014

[28] Ioffe S., Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[J]

[29] Szegedy C., Wei Liu, Yangqing Jia, et al. Going Deeper with Convolutions[A]. 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)[C]. Boston, MA, USA: IEEE, 2015: 1-9

[30] Zhang S., Jin P., Lin Z., et al. Robust Failure Diagnosis of Microservice System through Multimodal Data[EB]. arXiv, 2023

[31] Hu J., Shen L., Sun G. Squeeze-and-Excitation Networks[J]

[32] Rumelhart D. E., Hintont G. E., Williams R. J. Learning Representations by Back-Propagating Errors[J]. 1986

[33]Zhao N., Chen J., Yu Z., et al. Identifying Bad Software Changes via Multimodal Anomaly Detection for Online Service Systems[A]. Proceedings of the 29th ACM Joint Meeting on European Software Engineering Conference and Symposium on the Foundations of Software Engineering[C]. Athens Greece: ACM, 2021: 527-539

[34]Tuli S., Casale G. TranAD: Deep Transformer Networks for Anomaly Detection in Multivariate Time Series Data[A]. VLDB[C]. arXiv, 2022

[35] Darban Z. Z., Webb G. I., Pan S., et al. CARLA: Self-Supervised Contrastive Representation Learning for Time Series Anomaly Detection[J]. Pattern Recognition, 2025,157: 110874

[36] Gao R., He W., Yan L., et al. Hybrid Graph Transformer Networks for Multivariate Time Series Anomaly Detection[J]. The Journal of Supercomputing, 2024,80(1): 642-669