北京航空航天大学计算机学院

硕士研究生学位论文
文献综述

论文题目：　面向多元时序数据的系统异常检测技术研究

专　　业：　电子信息

研究方向：　智能化系统运维

研 究 生：　于郅豪

学　　号：　ZY2306322

指导教师：　高小鹏 教授

北京航空航天大学计算机学院

2024 年 11 月 9 日

目录

摘要.....1
1 概述.....2
2 时序数据序列.....3
2.1 单元时序数据.....3
2.2 多元时序数据.....3
3 多元时间序列异常检测方法.....4
3.1 传统的多元时间序列异常检测方法.....4
3.2 基于深度学习的多元时间序列异常检测方法.....5
3.2.1 基于预测.....5
3.2.2 基于重构.....6
3.2.3 基于表示.....7
3.2.4 混合模型.....8
4 日志数据异常检测.....9
4.1 日志解析方法.....9
4.2 日志异常检测方法.....10
5 结论.....11
6 参考文献.....12

面向多元时序数据的系统异常检测技术研究

摘要

多元时间序列异常检测在金融、制造业、医疗监控以及网络安全等领域中发挥着关键作用，能够有效识别潜在风险、预警异常行为，从而保障系统运行的安全性和稳定性。传统异常检测方法，例如基于统计学或机器学习的技术，尽管在特定应用场景中取得了一定成功，但在建模复杂数据依赖关系和处理高维数据方面表现出不足。这种局限性削弱了它们在处理非线性、多变量和高度动态的时间序列数据时的适用性。随着深度学习技术的迅猛发展，基于深度神经网络的异常检测方法展现了卓越的性能。这些方法通过预测、重构和表示学习等策略，能够更好地捕捉时间序列数据的动态变化和复杂模式，从而显著提高异常检测的精度与效率。

然而，目前的研究大多集中于单一数据来源的建模，未能充分挖掘多模态数据之间的潜在互补性。多模态数据融合能够整合来自不同来源的多样化信息，例如将传感器数据与日志信息相结合，从而全面反映系统运行状态。这种融合不仅能增强模型的鲁棒性，还能提升对复杂异常行为的检测能力，尤其在异构数据场景下具有显著优势。

此外，许多现有研究采用通道独立的建模方式，忽略了时间序列中变量间可能存在的延迟依赖关系。延迟依赖关系反映了不同变量在时间维度上的因果联系或交互效应，是系统行为的特征之一。对延迟依赖关系的忽视可能导致模型在捕捉时间序列真实动态特性时的准确性下降，从而影响异常检测的可靠性。

为克服上述不足，本文拟基于多模态数据融合与延迟依赖关系建模的视角，构建适用于多元时间序列异常检测任务的框架。为此，本文对多元时间序列异常检测方法、日志数据异常检测方法进行了详尽的调研，旨在突破现有方法的瓶颈，为提高异常检测的精度和鲁棒性提供理论支持和实践依据，从而帮助各行业及时发现潜在风险，降低经济损失并保障系统安全。

关键词：多元时间序列、异常检测技术、多模态融合、延迟依赖

1 概述

时间序列数据在当今数据驱动的环境中扮演着至关重要的角色，广泛应用于金融市场、制造业、互联网流量分析等多个领域。作为系统状态的实时反映，时间序列数据为异常检测提供了关键依据，有助于维持运营稳定性、降低财务风险并保障网络安全。

在金融市场中，时间序列数据用于监测股票价格和交易量的动态变化，通过异常检测可以及时识别潜在的欺诈行为或市场操纵，从而维护投资者利益并促进市场稳定。在制造业中，传感器数据实时跟踪设备的运行状态，通过时间序列异常检测技术，可以提前预测和预警设备故障，避免生产中断和质量问题。在互联网领域，对流量数据的时间序列分析有助于识别网络攻击或异常访问模式，从而增强网络安全防护。

对时间序列数据进行异常检测是制造业、金融应用和医疗监控等多个领域中的重要任务。异常可能指示重要事件，如生产故障、交付瓶颈、系统缺陷或心脏颤动，因此具有核心意义[1]。异常检测（又称离群点检测）是一种分析过程，旨在识别显著偏离典型模式的数据点。此方法在自动化监控系统中具有重要地位，有助于保护数据完整性和安全性。在金融行业中，异常检测技术被应用于欺诈检测和反洗钱，通过识别异常交易模式来防范财务损失。在零售业，异常检测可以帮助发现异常的购买行为或库存问题，从而优化供应链管理。在网络安全领域，异常检测用于识别潜在的安全漏洞或网络攻击，通过早期预警有效降低数据泄露和网络攻击风险。

时间序列数据的重要性不仅体现在其对系统状态的实时监控上，还在于其提供的预警能力，帮助预测潜在的故障、威胁和风险。通过时间序列异常检测，可以及时发现并处理异常情况，从而避免经济损失和声誉损害。在城市管理、入侵检测、医疗风险识别和自然灾害预警等领域，自动化的时序异常检测需求持续增长，进一步凸显了时间序列数据在现代社会中的关键地位。

近年来，随着大数据分析和深度学习技术的进步，时间序列异常检测能力显著增强。现代 IT 系统生成的大量高维传感器数据为异常检测提供了丰富的数据源，而工业 4.0 的推进进一步推动了自动化故障检测、系统恢复和智能管理的发展。在分布式计算、物联网（IoT）、机器人和城市资源管理等多个数据驱

动行业中，各种异常检测方法被广泛采用，以应对日益增长的数据量和复杂性。

综上所述，时间序列数据在多个领域中的广泛应用及其重要性不可忽视。借助先进的数据分析和异常检测技术，各行业可以有效提升系统的稳定性和安全性，为持续发展提供有力支持。

2 时序数据序列

数据序列是一组有序排列的数据点，这些数据点用于描述某个对象或过程在连续测量中的特定属性，如温度（物理学领域）、质量（化学领域）、角度（天文学领域）、位置（地质学领域）或速度（机械工程领域）。当这些数据点的排列顺序与时间相关时，该序列通常被称为时间序列[1]。

因此，时间序列是一系列按照时间顺序排列的数据点。时间序列通常分为单变量（一维/单元）和多变量（多维/多元）。

2.1 单元时序数据

单元时间序列（UTS）是指一组按照时间顺序排列的记录某单一变量变化的数据序列。例如，每秒钟记录一次 CPU 的占用率水平。假设，时间序列 X 包含 t 个时间戳，那么这个单元时序数据可以表示为如下格式：

$$X = (x_1, x_2, \ldots, x_t)$$

其中，x_i 表示在时间戳i $(i \in T)$ 时的这一单变量的数据，$T = \{1, 2, \ldots, t\}$。

2.2 多元时序数据

多元时间序列（MTS）就表示一组按照时间顺序排列的记录多个变量变化的数据序列。例如，每秒钟不仅记录一次 CPU 的占用率水平，同时还要记录内存的占用率水平，硬盘温度等等。假设，时间序列 X 包含 t 个时间戳，那么这个多元时序数据可以表示为如下格式：

$$X = (X_1, X_2, \ldots, X_t) = \left(\left(x_1^1, x_1^2, \ldots, x_1^d\right), \left(x_2^1, x_2^2, \ldots, x_2^d\right), \ldots, \left(x_t^1, x_t^2, \ldots, x_t^d\right)\right)$$

其中，$X_i = \left(x_i^1, x_i^2, \ldots, x_i^d\right)$ 表示在时间戳i $(i \in T)$ 时的数据向量，每个 x_i^j 表示在时间戳i $(i \in T)$ 第 j 个变量的数据，$T = \{1, 2, \ldots, t\}$，$j = \{1, 2, \ldots, d\}$，d 是变量的总个数。

3 多元时间序列异常检测方法

多元时序数据异常检测（Multivariate Time Series Anomaly Detection，简称 MTSAD）即是通过算法识别偏离正常模式的异常数据点或模式，以预防或解决潜在的问题。它涵盖了检测金融市场中的异常波动、工业制造中的设备故障、互联网流量中的安全威胁等场景。通过检测到的异常点，企业能够采取预防措施，从而降低系统风险，避免经济损失并保障用户体验。

3.1 传统的多元时间序列异常检测方法

传统的多元时间序列异常检测方法提供了多种不同的策略，这些策略在处理复杂的时间序列数据时各有优势。

基于统计的方法[3]通过构建时间序列正常行为的统计模型来识别异常。该框架利用在线折扣学习算法动态跟踪数据源的变化，并通过计算数据点的偏离度来识别异常和变化点，实验结果验证了其在股票市场数据分析中的有效性。

基于聚类的方法[4]则通过学习时间序列窗口的正常轮廓来进行异常检测。在这种方法中，正常的时间序列窗口会被聚类到较大的簇中，而异常窗口则可能被聚类到较小的簇中，或者与正常簇中心的距离较远，从而被视为异常。

基于距离的方法[5]通过计算时间序列子序列与其最近邻之间的距离，生成矩阵剖面，矩阵剖面中的最大值对应于时间序列异常值，从而高效地识别异常值和基序。

基于密度的方法[6]通过构建隔离树来评估数据实例的异常程度，利用异常数据点“少且不同”的特性，计算其在隔离树中的平均深度作为异常分数，平均深度越低，数据点越可能是异常。

综上所述，这些传统的多元时间序列异常检测方法各有千秋，可以根据具体的应用场景和数据特性选择合适的方法来提高异常检测的准确性和效率。

3.2 基于深度学习的多元时间序列异常检测方法

随着深度神经网络技术的迅猛发展，其在处理复杂结构数据中的应用日益广泛。在时间序列数据分析领域，深度神经网络在捕捉时间和空间依赖性方面展现出卓越的能力。众多研究者已经尝试将多种深度学习架构应用于异常检测领域，以应对时间序列数据中的复杂性和动态变化。

在时间序列异常检测（TSAD）的文献中，主要存在三种方法：基于预测的、基于重构的和基于表示的。如表 1，这些方法利用深度神经网络的强大特征提取能力，分别从预测未来值、重构当前值和提取数据表示三个角度出发，实现对时间序列中异常行为的有效检测。

表 1 基于深度学习的多元时许数据异常检测方法

方法分类	方法名称
基于**预测**的异常检测方法	AD-LTI、TimesNet、GDN、HGTMAD
基于**重构**的异常检测方法	AMSL、RDSSM、DCT-GAN、TranAD
基于**表示**的异常检测方法	CARLA、TS2Vec
混合模型的异常检测方法	CAE-M、MTAD-GAT、FuSAGNet

3.2.1 基于预测

基于预测的异常检测方法通过建立模型来预测多元时间序列的未来值，并将预测值与实际观测值进行比较。当实际值与预测值的差异超过设定的阈值时，被判定为异常。本小节主要调研了基于循环神经网络（Recurrent Neural Network, RNN）、卷积神经网络（Convolutional Neural Network, CNN）和图神经网络（Graph Neural Network, GNN）的预测模型。

Wu 等人[7]提出了一种基于 GRU 网络与时间序列分解的帧到序列预测模型，实现了对多重季节性时间序列数据的无标签、容忍污染的训练。他们引入了新的度量“局部趋势不一致性”（LTI），并基于此开发了基于局部趋势不一致性的异常检测方法（AD-LTI），用于评估数据异常概率。

Wu 等人[8]提出了一种基于 CNN 的 TimesNet 模型，通过将 1D 时间序列转换为 2D 张量空间，分别嵌入周期内和周期间的变化特征，以更有效地进行时

间变化建模。TimesNet 中的 TimesBlock 模块可以自适应地发现多周期性，并通过高效的 Inception 模块从 2D 张量中提取复杂的时间变化特征。

Deng 和 Hooi[9]提出了一种基于 GNN[16]的多变量时间序列异常检测方法，称为 Graph Deviation Network (GDN)。该方法通过图结构学习建立传感器之间的关系图，并结合图注意力机制预测每个传感器的未来行为，从而检测偏离正常关系的异常情况。GDN 还通过传感器嵌入和学习的图结构提供了良好的可解释性，能够帮助用户根据偏差子图、注意力权重及传感器的预测与实际行为差异来推导出异常原因。

Guo 等[37]提出了一种用于多变量时间序列异常检测的混合图转换器网络（HGTMAD）。该方法结合了图卷积网络（GCN）和基于 Transformer 的模型，分别在空间和时间维度建模。GCN 用于捕获多传感器之间的复杂拓扑关系，通道卷积转换器增强了对局部空间依赖的学习，同时稀疏度度量 Transformer 利用 Wasserstein 距离优化了时间序列的长时依赖建模。

3.2.2 基于重构

基于重构的异常检测方法通过训练模型来重构多元时间序列数据，然后将重构值与原始观测值进行比较。当重构误差超过某个设定阈值时，该数据点被视为异常。本小节主要调研了采用自编码器（Autoencoder, AE）、变分自编码器（Variational Autoencoder, VAE）和生成对抗网络（Generative Adversarial Network, GAN）作为主要架构的模型。

Zhang 等人[10]提出了一种基于卷积 AE 的自适应记忆网络与自监督学习相结合的无监督异常检测方法（AMSL），用于提高在多变量时间序列数据上的泛化能力。该方法进行端到端训练，结合自监督学习和记忆网络应对有限正常数据的挑战。通过将原始时间序列及其六种变换映射到特征空间并分类，AMSL 增强了泛化能力，并通过全局和局部记忆网络学习共性和特性特征，最终通过自适应融合模块生成新的重构表示。

Li 等人[11]提出了一种鲁棒深度状态空间模型（Robust Deep State Space Model, RDSSM），旨在提升在噪声污染数据上的鲁棒性检测能力。与大多数方法假设训练数据干净不同，RDSSM 直接在可能包含异常的原始数据上进行训练。RDSSM 结合了两个过渡模块来处理时间依赖性和不确定性。它基于深度

生成模型和状态空间模型，通过设计带有重尾分布的发射模型吸收异常引起的变化，实现对受污染和无标签的时间序列数据的鲁棒训练。该方法通过密度估计来适应时间上波动的噪声，能够为异常分配自适应得分以进行概率检测。

Zhao 等人[12]提出了一种膨胀卷积 Transformer 的 GAN 模型（Dilated Convolutional Transformer-based GAN, DCT-GAN），用于提升时间序列异常检测（TSAD）的准确性和泛化能力。为解决 GAN 模型在 TSAD 中常见的模式崩溃问题，DCT-GAN 采用多个生成器和一个判别器的结构。每个生成器由膨胀卷积神经网络和 Transformer 模块组成，用于提取时间序列的细粒度和粗粒度信息，以增强模型的泛化能力。此外，DCT-GAN 还引入基于权重的机制来平衡各生成器，使模型能够适应不同类型的异常。

Shreshth Tuli 等人[34]提出一种基于 Deep Transformer 网络的多元时间序列异常检测模型，结合了重建和对抗训练的混合方法。其设计通过序列编码器捕捉全局时间趋势，同时利用双阶段自我调节和注意力机制增强对异常的敏感性。TranAD 的重建模块用于生成输入数据的近似表示，并通过偏差放大技术提取异常特征，而对抗训练则进一步优化模型的鲁棒性和泛化能力。

3.2.3 基于表示

基于表示的异常检测方法通过学习多元时间序列的特征表示，从中提取潜在模式和异常点。该方法的关键在于提取特征的有效性，而不是直接预测或重构数据。本小节主要调研了使用卷积神经网络（Convolutional Neural Network, CNN）和 Transformer 作为基础的表示学习模型。

Zamanzadeh Darban 等人[13]提出了一种自监督对比学习模型 CARLA，用于时间序列异常检测。该模型通过两阶段框架解决标签稀缺问题。第一阶段（预训练）通过注入多种类型的异常，学习正常行为和异常行为的差异，在表示空间中将邻近的正常样本拉近，并与异常样本区分开来；第二阶段（自监督分类）则基于邻域关系进一步优化分类表现，以提高异常检测性能。

Yue 等人[14]利用分层 Transformer 架构提出了 TS2Vec，一种通用的时间序列表示学习框架，旨在不同语义层次上为时间序列学习上下文表示。TS2Vec 通过分层对比学习在增强的上下文视图上捕捉多尺度的上下文信息，以实现稳健

的时间戳级表示。该方法利用时间戳掩码和随机裁剪生成上下文，以选取相同时间戳的正样本对，增强了模型在分类、预测和异常检测等任务中的表现。

3.2.4 混合模型

混合模型的异常检测方法结合了多种方法的优势，通过预测、重建和表示学习等不同方式来识别异常。该方法力求在捕捉数据的多层次特征和异常模式上取得平衡。本小节主要调研了同时使用不同架构组合的混合异常检测模型。

Zhang 等人[20]提出了一种同时进行重建和预测的，名为深度卷积自编码记忆网络（CAE-M）的新型无监督深度学习异常检测算法，旨在解决多传感器时间序列数据中的异常检测问题。CAE-M 模型由两个主要子网络组成：特征化网络和记忆网络。特征化网络使用深度卷积自编码器（CAE）来捕捉多传感器数据的空间依赖性，并通过最大均值差异（MMD）惩罚项来区分噪声、正常和异常数据。记忆网络则结合了线性预测（自回归模型）和非线性预测（基于注意力机制的双向 LSTM）来捕捉时间序列数据的时间依赖性。通过联合优化这两个子网络，CAE-M 模型能够有效地检测多传感器时间序列数据中的异常。实验结果表明，CAE-M 在 HAR 和 HC 数据集上的表现优于现有的几种最先进的异常检测方法。

Zhao 等人[21]提出了一种结名为 MTAD-GAT 的新型框架，用于多变量时间序列异常检测。该方法通过自监督学习的方式解决了现有方法未能显式捕捉时间序列间关系的问题。MTAD-GAT 模型的核心是两个并行的图注意力网络（GAT）层，分别用于捕捉特征间的因果关系和时间维度的依赖关系。此外，该框架联合优化了基于预测的模型和基于重构的模型，通过单时间戳预测和整段时间序列重构相结合，获得更好的时间序列表示。实验结果表明，该方法在三个真实数据集上优于现有的最先进模型，尤其在工业应用场景中表现出色，显著提高了 F1 分数，并对异常诊断具有良好的解释性和实际应用价值。

Han 等人[22]提出了一种名为 FuSAGNet 的新型异常检测框架，用于多变量时间序列。FuSAGNet 通过联合优化稀疏自动编码器(Sparse Autoencoder, SAE)的重构任务和图神经网络(Graph Neural Network, GNN)的预测任务，显式建模高维传感器数据的复杂特征间依赖性。该模型包含四个主要阶段：1）基于双向 GRU 的传感器嵌入，2）通过余弦相似性生成图结构，3）结合 KL 散度正则的

稀疏约束优化，以及 4）利用加权谐波平均计算重构和预测误差的异常评分。实验表明，FuSAGNet 在三个真实工业控制系统数据集上表现优于现有最先进方法，并通过 TSNE 可视化验证了其稀疏潜在表示和传感器嵌入的解释性。该框架在提升鲁棒性和异常检测性能方面展现出显著优势。

4 日志数据异常检测

日志数据异常检测是一种通过分析系统日志数据以识别异常行为、故障或安全事件的技术。日志数据是由系统或应用程序生成的按时间顺序排列的事件序列，包含丰富的系统状态信息，从正常操作（如进程启动和用户访问）到意外异常（如进程失败或安全威胁）。日志检测的核心在于解析非结构化或半结构化日志消息，提取关键事件类型和参数，以便更高效地进行后续分析。这一过程对于系统维护和安全保障具有重要意义，能够帮助运维人员及时发现潜在问题，采取预防措施，减少系统损害并防止负面影响的扩散，从而提升系统的可靠性和安全性。

4.1 日志解析方法

日志解析是日志数据异常检测的第一步，也是最关键的一步。日志解析的主要目的是将半结构化的日志数据转化为结构化数据，以便于后续的异常检测和分析[19]。由于原始日志通常包含变量和常量的混合内容，未解析的日志难以高效利用。通过日志解析，可以将日志消息中的常量提取为模板，同时标识出变量部分，这种转换能显著提升异常检测的精度和效率。减少计算资源的消耗，并且增强数据的可解释性，有助于开发人员快速定位和识别异常。因此，日志解析在日志数据异常检测中起着至关重要的作用。

Xu 等[28]提出了一种名为 DivLog 的日志解析框架，该框架利用大型语言模型（LLMs）的上下文学习（ICL）能力来提高日志解析的效果。DivLog 在日志解析之前，通过最大化日志样本的多样性来选择一小部分离线日志作为候选样本，并在解析过程中为每个目标日志选择五个适当的标记候选样本作为示例，构建一个提示。通过挖掘提示中示例的语义，DivLog 能够在无需训练的情况下生成目标日志模板。此外，文章还设计了一种简单而有效的提示格式，以提取输出并增强生成的日志模板的质量。

Meng 等[29]提出了一种名为 LogParse 的日志解析框架，通过将日志模板生成问题转化为单词分类问题，实现了日志解析的自适应性。LogParse 利用现有的模板提取方法自动生成单词标签，并使用字符级计数向量表示单词，训练一个二分类器来区分模板词和变量词。在实时日志生成时，LogParse 能够匹配现有模板，并在无法匹配时自动生成新模板并更新模板集。这种方法不仅支持跨服务和跨语法的自适应性，还能显著提高日志解析的准确性，并应用于日志压缩等实际应用中。

4.2 日志异常检测方法

在开展日志异常检测方法的调研过程中，我深入阅读了以下几篇文献，这些文献涵盖了当前领域内的主要研究成果和创新方法，为本研究奠定了理论基础。

Meng 等[31]提出了 LogAnomaly 框架，用于在非结构化日志流中无监督地检测顺序和定量异常。LogAnomaly 首次结合了日志的顺序和定量模式，通过引入 template2Vec 方法，生成捕捉日志模板语义和上下文关系的向量表示，从而解决了仅依赖模板索引导致的语义信息丢失问题。框架利用 LSTM 模型学习日志的高维依赖关系，在离线阶段构建顺序和定量模式，在线阶段通过模板近似方法应对新出现的日志模板。

Guo 等[30]提出了一种名为 LogFormer 的日志异常检测框架，采用了基于预训练和适配器调优的两阶段流程，旨在提高多域日志异常检测的泛化能力。在预训练阶段，模型通过对源领域日志数据的学习，获取通用的日志语义表示。接着，适配器调优阶段将预训练的知识迁移到目标领域，仅更新少量适配器参数，从而显著降低训练成本并提升效率。此外，框架引入了 Log-Attention 模块，以减少日志解析过程中丢失的语义信息，从而更准确地捕获日志序列的特征。

Li 等[32]提出了一种名为 Logs2Graphs 的基于图神经网络的无监督日志异常检测与解释方法。该方法首先将日志事件转化为具备属性、有向性和权重的图结构，并引入了一种新型图神经网络模型 OCDiGCN，用于进行图级别的异常检测。通过将图表示学习与异常检测过程结合，Logs2Graphs 实现了针对异

常检测优化的图嵌入表示。同时，通过分解图的异常评分到节点级别，并可视化关键节点，该方法能够提供详细的异常解释以支持根因分析。

Crispin Almodovar 等[33]提出了 LogFiT，一种基于微调语言模型的日志异常检测方法。LogFiT 摒弃了传统的日志解析和模板生成步骤，通过预训练的 BERT-based 模型（如 RoBERTa 和 Longformer）直接对原始日志进行语义分析，并利用一种自监督的掩码句子预测目标来学习正常日志的语言和顺序模式。在检测阶段，模型通过预测掩码词的准确性作为异常评分，从而识别偏离正常行为的日志数据。

5 结论

通过对相关工作的分析、研究与复现，本文认为多元时间序列异常检测目前还存在以下难点：

（1）多模态数据的利用不足。现有的大多数研究在多元时间序列异常检测中，仅关注单一或少数类型的数据源，而未充分挖掘来自不同模态的数据间的协同作用。大部分方法通常采用单一的数据输入，即传感器数据或者日志数据，忽视了多模态数据所能提供的互补信息。多模态数据可能在内容、尺度、分布等方面存在显著差异。传统的方法往往以各模态数据为孤立个体进行处理，缺乏有效的融合策略，从而无法充分发挥其优势。

然而，随着数据采集技术的进步和多源数据的普及，越来越多的研究表明，多模态数据的融合处理可以显著提升异常检测的效果。不同模态的数据往往能够提供互补的信息，例如，传感器数据可以提供物理量的实时变化情况，而系统日志帮助操作员从自然语言文本、序列信息和数值的角度理解系统在运行时的行为[15]。因此，如何有效地将这些不同来源的数据进行融合，不仅能够提高异常检测的精度，还能增强模型的鲁棒性，使其能够适应不同的数据噪声和不确定性。

（2）对指标间延迟依赖的建模不足。多元时间序列中的变量间往往存在复杂的延迟依赖关系，然而现有方法大多假设变量间具有同步的动态关系。这种简化建模方式可能导致对系统中隐含的真实动态关系的刻画不足。尤其在面对非线性和非平稳时间序列时，传统方法难以适应这些复杂的延迟依赖模式。此

外，缺乏有效的方法对多元时间序列中各变量间的延迟依赖进行准确识别和解释，这进一步限制了对系统行为异常的全面理解和早期检测。

上述难点揭示了多元时间序列异常检测领域在多模态时序数据处理和延迟依赖关系建模两个核心方向上的不足，为本文的研究提供了明确的方向。通过将多模态数据融合处理和对延迟依赖关系的深入建模，本文力图突破现有方法的瓶颈，从而提升多元时间序列异常检测的准确性和鲁棒性。

6 参考文献

[1] Schmidl S., Wenig P., Papenbrock T. Anomaly Detection in Time Series: A Comprehensive Evaluation[J]. Proceedings of the VLDB Endowment, 2022,15(9): 1779-1797

[2] James Douglas Hamilton. 2020. Time Series Analysis. Princeton University Press

[3] Kenji Yamanishi and Jun-ichi Takeuchi. 2002. A unifying framework for detecting outliers and change points from non-stationary time series data. In KDD. 676–681.

[4] Moshtaghi M., Bezdek J. C., Leckie C., et al. Evolving Fuzzy Rules for Anomaly Detection in Data Streams[J]. IEEE Transactions on Fuzzy Systems, 2015,23(3): 688-700

[5] Chin-Chia Michael Yeh, Yan Zhu, Liudmila Ulanova, Nurjahan Begum, Yifei Ding, Hoang Anh Dau, Diego Furtado Silva, Abdullah Mueen, and Eamonn Keogh. 2016. Matrix profile I: All pairs similarity joins for time series: A unifying view that includes motifs, discords and shapelets. In ICDM. 1317–1322.

[6] Zhiguo Ding and Minrui Fei. 2013. An anomaly detection approach based on isolation forest algorithm for streaming data using sliding window. IFAC Proceedings Volumes 46, 20 (2013), 12–17.

[7] Wu W., He L., Lin W., et al. Developing an Unsupervised Real-Time Anomaly Detection Scheme for Time Series with Multi-Seasonality[J]. IEEE Transactions on Knowledge and Data Engineering, 2022,34(9): 4147-4160

[8] Wu H., Hu T., Liu Y., et al. TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis[EB]. arXiv, 2023

[9] Deng A., Hooi B. Graph Neural Network-Based Anomaly Detection in Multivariate Time Series[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021,35(5): 4027-4035

[10] Zhang Y., Wang J., Chen Y., et al. Adaptive Memory Networks with Self-Supervised Learning for Unsupervised Anomaly Detection[J]. IEEE Transactions on Knowledge and Data Engineering, 2023,35(12): 12068-12080

[11] Li L., Yan J., Wen Q., et al. Learning Robust Deep State Space for Unsupervised Anomaly Detection in Contaminated Time-Series[J]. IEEE Transactions on Knowledge and Data Engineering, 2022: 1-1

[12] Li Y., Peng X., Zhang J., et al. DCT-GAN: Dilated Convolutional Transformer-Based GAN for Time Series Anomaly Detection[J]. IEEE Transactions on Knowledge and Data Engineering, 2023,35(4): 3632-3644

[13] Darban Z. Z., Webb G. I., Pan S., et al. CARLA: Self-Supervised Contrastive Representation Learning for Time Series Anomaly Detection[J]. Pattern Recognition, 2025,157: 110874

[14] Yue Z., Wang Y., Duan J., et al. TS2Vec: Towards Universal Representation of Time Series[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2022,36(8): 8980-8987

[15] Notaro P., Cardoso J., Gerndt M. A Survey of AIOps Methods for Failure Management[J]. ACM Transactions on Intelligent Systems and Technology, 2021,12(6): 1-45

[16] Jin M., Koh H. Y., Wen Q., et al. A Survey on Graph Neural Networks for Time Series: Forecasting, Classification, Imputation, and Anomaly Detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024,46(12): 10466-10485

[17] Devlin J., Chang M.-W., Lee K., et al. BERT: Pre-Training of Deep Bidirectional Transformers for Language Understanding[J]

[18] Yun S., Jeong M., Kim R., et al. Graph Transformer Networks[J]

[19] Zhang T., Qiu H., Castellano G., et al. System Log Parsing: A Survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2023: 1-20

[20] Zhang Y., Chen Y., Wang J., et al. Unsupervised Deep Anomaly Detection for Multi-Sensor Time-Series Signals[J]. IEEE Transactions on Knowledge and Data Engineering, 2021: 1-1

[21] Zhao H., Wang Y., Duan J., et al. Multivariate Time-Series Anomaly Detection via Graph Attention Network[A]. 2020 IEEE International Conference on Data Mining (ICDM)[C]. Sorrento, Italy: IEEE, 2020: 841-850

[22] Han S., Woo S. S. Learning Sparse Latent Graph Representations for Anomaly Detection in Multivariate Time Series[A]. Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining[C]. Washington DC USA: ACM, 2022: 2977-2986

[23] Meng W., Liu Y., Zhu Y., et al. LogAnomaly: Unsupervised Detection of Sequential and Quantitative Anomalies in Unstructured Logs[A]. Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence[C]. Macao, China: International Joint Conferences on Artificial Intelligence Organization, 2019: 4739-4745

[24] Zhao L., Shen Y. Rethinking Channel Dependence for Multivariate Time Series Forecasting: Learning from Leading Indicators[EB]. arXiv, 2024

[25] Brogi A., Zimmermann W., Kritikos K. Service-Oriented and Cloud Computing: 8th IFIP WG 2.14 European Conference, ESOCC 2020, Heraklion, Crete, Greece, September 28–30, 2020, Proceedings: Vol. 12054[M]. Cham: Springer International Publishing, 2020

[26] Su Y., Zhao Y., Niu C., et al. Robust Anomaly Detection for Multivariate Time Series through Stochastic Recurrent Neural Network[A]. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining[C]. Anchorage AK USA: ACM, 2019: 2828-2837

[27] Liu X., Liu Y., Wei M., et al. LMGD: Log-Metric Combined Microservice Anomaly Detection through Graph-Based Deep Learning[J]. IEEE Access, 2024: 1-1

[28] Xu J., Yang R., Huo Y., et al. DivLog: Log Parsing with Prompt Enhanced in-Context Learning[A]. Proceedings of the IEEE/ACM 46th International Conference on Software Engineering[C]. Lisbon Portugal: ACM, 2024: 1-12

[29] Meng W., Liu Y., Zaiter F., et al. LogParse: Making Log Parsing Adaptive through Word Classification[A]. 2020 29th International Conference on Computer Communications and Networks (ICCCN)[C]. Honolulu, HI, USA: IEEE, 2020: 1-9

[30] Guo H., Yang J., Liu J., et al. LogFormer: A Pre-Train and Tuning Pipeline for Log Anomaly Detection[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2024,38(1): 135-143

[31] Meng W., Liu Y., Zhu Y., et al. LogAnomaly: Unsupervised Detection of Sequential and Quantitative Anomalies in Unstructured Logs[A]. Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence[C]. Macao, China: International Joint Conferences on Artificial Intelligence Organization, 2019: 4739-4745

[32] Li Z., Shi J., Van Leeuwen M. Graph Neural Networks Based Log Anomaly Detection and Explanation[A]. Proceedings of the 2024 IEEE/ACM 46th International Conference on Software Engineering: Companion Proceedings[C]. Lisbon Portugal: ACM, 2024: 306-307

[33] Almodovar C., Sabrina F., Karimi S., et al. LogFiT: Log Anomaly Detection Using Fine-Tuned Language Models[J]. IEEE Transactions on Network and Service Management, 2024,21(2): 1715-1723

[34] Tuli S., Casale G. TranAD: Deep Transformer Networks for Anomaly Detection in Multivariate Time Series Data[A]. VLDB[C]. arXiv, 2022

[35] Xu H., Wang Y., Jian S., et al. Calibrated One-Class Classification for Unsupervised Time Series Anomaly Detection[J]. IEEE Transactions on Knowledge and Data Engineering, 2024: 1-14

[36] 曾凡锋,吕繁钰.基于 Transformer 和 GAN 的多元时间序列异常检测方法[J]. 北方工业大学学报,2024,36(01):100-109.

[37] Gao R., He W., Yan L., et al. Hybrid Graph Transformer Networks for Multivariate Time Series Anomaly Detection[J]. The Journal of Supercomputing, 2024,80(1): 642-669