中图分类号：TP311

论 文 编 号：10006ZY2306322

北京航空航天大學

专业硕士学位论文

面向多源异构时序数据的系统异常检测技术研究

作 者 姓 名　于 郅 豪

学 科 专 业　计算机技术

指 导 教 师　高小鹏 教授

培 养 学 院　计算机学院

Research on System Anomaly Detection Technology for Multi-source Heterogeneous Time Series Data

The Professional Degree of Master of Electronic and Information Engineering

Candidate: Zhihao Yu

Supervisor: Prof. Xiaopeng Gao

School of Computer Science & Engineering

Beihang University, Beijing, China

中图分类号：TP311

论 文 编 号：10006ZY2306322

硕　士　学　位　论　文

面向多源异构时序数据的系统异常检测技术研究

作者姓名	于郅豪	申请学位类别	工学硕士
指导教师姓名	高小鹏	职　　称	教授
学科专业	计算机技术	研究方向	智能化系统运维
学习时间自	2023 年 9 月 1 日	起　　至	2026 年 06 月 01 日止
论文提交日期	2026 年 04 月 14 日	论文答辩日期	2026 年 05 月 22 日
学位授予单位	北京航空航天大学	学位授予日期	年　月　日

关于学位论文的独创性声明

本人郑重声明：所呈交的论文是本人在指导教师指导下独立进行研究工作所取得的成果，论文中有关资料和数据是实事求是的。尽我所知，除文中已经加以标注和致谢外，本论文不包含其他人已经发表或撰写的研究成果，也不包含本人或他人为获得北京航空航天大学或其它教育机构的学位或学历证书而使用过的材料。与我一同工作的同志对研究所做的任何贡献均已在论文中作出了明确的说明。

若有不实之处，本人愿意承担相关法律责任。

学位论文作者签名：_____　　日期：　　年　　月　　日

学位论文使用授权书

本人完全同意北京航空航天大学有权使用本学位论文（包括但不限于其印刷版和电子版），使用方式包括但不限于：保留学位论文，按规定向国家有关部门（机构）送交学位论文，以学术交流为目的赠送和交换学位论文，允许学位论文被查阅、借阅和复印，将学位论文的全部或部分内容编入有关数据库进行检索，采用影印、缩印或其他复制手段保存学位论文。

保密学位论文在解密后的使用授权同上。

学位论文作者签名：_____　　日期：　　年　　月　　日

指导教师签名：_____　　日期：　　年　　月　　日

摘 要

随着云计算、容器编排和云原生技术的快速发展，微服务架构已经成为现代大型软件系统的主流组织方式。微服务系统通常由大量服务实例、数据库、中间件和通信组件构成，其内部存在复杂的调用依赖关系和高度动态的运行环境。一旦局部服务出现异常，故障往往会沿调用链传播，并在指标、日志和调用链追踪等多源监控数据中表现为不同形式的异常信号。因此，如何面向多源异构时序数据开展高效、准确和鲁棒的系统异常检测，已成为智能运维领域的重要研究问题。

现有研究大多基于单一模态数据开展异常检测，难以同时刻画系统状态变化、行为语义和异常传播结构等多层次信息；而已有多模态方法在样本级特征建模、跨模态结构表达以及融合策略适应性方面仍存在不足。特别是在复杂微服务场景下，不同模态的质量和贡献往往随样本而变化，固定融合方式难以充分适应实际异常检测需求。针对上述问题，本文围绕指标（Metric）、日志（Log）和调用链追踪（Trace）三类监控数据，系统研究面向多源异构时序数据的系统异常检测方法，并开展了如下工作：

（1）本文提出了一种面向微服务异常检测的多源异构时序数据统一建模框架。针对指标、日志和调用链追踪三类监控数据在数值属性、语义表达和结构依赖上的差异，分别构建 Trace-Metric 图与日志异构图，并在统一框架下完成多模态异常检测建模，为后续特征学习与融合分析提供了结构化基础。

（2）本文针对样本级多模态特征表达不足的问题，设计了结合特征增强、特征提取与图构建的表示学习方法。具体地，面向日志模态、调用链模态和指标模态分别构建样本级增强机制，在图编码前对局部语义信息、结构信息和时序统计信息进行补充，从而提升多模态表示的判别能力。消融实验表明，该设计能够在保持高精度的同时显著提升异常样本识别能力。

（3）本文提出了一种基于不确定性感知混合专家的层次化动态融合方法。该方法显式建模模态质量与跨模态冲突信息，通过不确定性估计、动态路由和专家聚合实现样本级自适应融合，有效缓解了固定融合方式在复杂异常场景中的局限。实验结果表明，该方法能够提升融合结果的稳定性与适应性，并在最终检测性能上优于简化版融合策略。

（4）本文围绕所提出方法开展了系统的实验验证，包括总体对比实验、创新点消融实验和模态敏感性实验。实验结果表明，本文方法在两个数据集上均表现出领先的 F1-score 和 AUC，相比基线模型在异常识别能力和综合检测性能上均表现出稳定优势。同时，模态敏感性实验进一步表明，日志模态在本文实验设置下对模型性能影响最为显著，调用链追踪模态和指标模态则从结构传播与系统状态两个角度提供了重要补充。

总体来说，本文面向微服务系统中的多源异构时序监控数据，提出了一套集样本级增强、图结构建模与不确定性感知动态融合于一体的异常检测方法框架。本文工作不仅从方法层面提升了复杂系统异常检测的准确性与鲁棒性，也从实验层面对多模态特征表达、动态融合机制和模态互补关系进行了较为系统的分析，可为后续面向智能运维场景的系统异常检测研究提供参考。

关键词：微服务异常检测，多源异构时序数据，多模态融合

Abstract

With the rapid development of cloud computing, container orchestration, and cloud-native technologies, microservice architecture has become the mainstream paradigm for modern large-scale software systems. A microservice system usually consists of numerous service instances, databases, middleware components, and communication modules, with complex dependency relationships and highly dynamic runtime environments. Once a local service becomes abnormal, failures may propagate along service invocation paths and manifest as heterogeneous anomaly signals in metrics, logs, and traces. Therefore, how to perform efficient, accurate, and robust anomaly detection over multi-source heterogeneous time-series data has become an important research issue in intelligent operations and maintenance.

Existing studies mostly focus on anomaly detection based on a single data modality, which makes it difficult to jointly characterize system state changes, behavioral semantics, and propagation structures of anomalies. Although multimodal approaches have been explored, they still suffer from insufficient sample-level feature modeling, inadequate cross-modal structural representation, and limited adaptability of fusion strategies. In practical microservice scenarios, the quality and contribution of different modalities often vary from sample to sample, making fixed fusion mechanisms insufficient for complex anomaly detection tasks. To address these issues, this thesis systematically studies system anomaly detection over three major monitoring modalities, namely metrics, logs, and traces, and makes the following contributions:

（1）A unified modeling framework for multi-source heterogeneous time-series anomaly detection in microservice systems is proposed. Considering the differences among metrics, logs, and traces in numerical attributes, semantic expressions, and structural dependencies, a Trace-Metric graph and a log heterogeneous graph are constructed, and multimodal anomaly detection is performed within a unified framework, providing a structured basis for subsequent feature learning and fusion analysis.

（2）To improve sample-level multimodal feature representation, a representation

learning method integrating feature enhancement, feature extraction, and graph construction is designed. Specifically, sample-level enhancement mechanisms are developed for logs, traces, and metrics respectively, so that local semantic information, structural information, and temporal statistical information can be enriched before graph encoding, thereby improving the discriminative power of multimodal representations. Ablation studies show that this design significantly improves anomaly recognition ability while maintaining high precision.

（3）A hierarchical dynamic fusion method based on uncertainty-aware mixture of experts is proposed. This method explicitly models modality quality and cross-modal conflicts, and performs sample-adaptive fusion through uncertainty estimation, dynamic routing, and expert aggregation. In this way, it alleviates the limitations of fixed fusion mechanisms in complex anomaly scenarios. Experimental results demonstrate that the proposed method improves the stability and adaptability of multimodal fusion and achieves better final detection performance than simplified fusion variants.

（4）Extensive experiments are conducted, including overall comparison experiments, innovation-oriented ablation studies, and modality sensitivity analysis. The results show that the proposed method achieves the best F1-score and AUC on both datasets, and consistently outperforms baseline methods in anomaly recognition capability and overall detection performance. Moreover, modality sensitivity analysis further indicates that the log modality is the most critical factor determining the upper bound of model performance, while trace and metric modalities provide important complementary information from the perspectives of structural propagation and system state, respectively.

In summary, this thesis proposes a systematic anomaly detection framework for multi-source heterogeneous time-series monitoring data in microservice systems, integrating sample-level enhancement, graph-based representation learning, and uncertainty-aware dynamic fusion. The proposed approach not only improves the accuracy and robustness of anomaly detection for complex systems, but also provides a relatively comprehensive empirical analysis of multimodal feature representation, dynamic fusion mechanisms, and modality complementarity. It can serve as a useful reference for future research on intelligent operations and maintenance

oriented system anomaly detection.

Keywords: Microservice Anomaly Detection，Multi-source Heterogeneous Time-series Data，Multimodal Fusion

目 录

第一章 绪论 1
1.1 研究背景和意义 1
1.2 国内外研究现状 5
1.2.1 基于单一数据的异常检测相关研究 5
1.2.2 基于多源数据的异常检测相关研究 8
1.2.3 现有研究不足和本文切入点 10
1.3 研究目标及内容 11
1.3.1 面向多源异构时序数据的整体异常检测框架设计 12
1.3.2 基于多源异构时序数据的特征增强和提取技术 13
1.3.3 基于不确定性感知混合专家的动态融合方法 13
1.4 本文组织结构 13
第二章 相关技术基础介绍 15
2.1 图神经网络与异构图学习 15
2.1.1 图神经网络基本原理 15
2.1.2 典型图神经网络模型 16
2.1.3 异构图学习方法 17
2.2 多模态融合技术 19
2.2.1 多模态融合的基本问题 19
2.2.2 特征级、模型级与决策级融合 19
2.2.3 动态融合与层次化融合方法 20
2.3 注意力机制与时序表示学习 21
2.3.1 卷积与循环网络的时序建模能力 21
2.3.2 自注意力与多头注意力机制 22
2.3.3 位置编码与残差连接 23
2.4 本章小结 23
第三章 面向多源异构时序数据的异常检测总体框架 25

3.1 研究目标与问题定义 25
3.2 整体架构 26
3.3 特征增强与提取技术 28
3.4 图构建与图表示学习技术 29
3.5 跨模态融合技术与异常判别 30
3.6 多 Loss 联合优化目标 31
3.7 本章小结 32
第四章 基于多源异构时序数据特性的特征增强与提取技术 33
4.1 研究动机 33
4.2 面向日志数据的特征增强与提取技术 34
4.2.1 日志数据的特点分析 34
4.2.2 日志数据的特征增强方法 35
4.2.3 日志数据的特征提取方法 36
4.3 面向调用链数据的特征增强与提取技术 38
4.3.1 调用链数据的特点分析 38
4.3.2 调用链数据的特征增强方式 38
4.3.3 调用链数据的特征提取方式 39
4.4 面向指标数据的特征增强与提取技术 40
4.4.1 多尺度卷积 41
4.4.2 残差块 Residual Block 41
4.4.3 位置编码与多头注意力机制 42
4.4.4 双池化聚合与输出 42
4.5 图构建与图表示学习 43
4.5.1 建图目标与整体思路 43
4.5.2 时间窗约束下的多模态对齐 43
4.5.3 Trace-Metric 联合图构建逻辑 44
4.5.4 日志异构图构建逻辑 45
4.5.5 双图输出与后续编码衔接 46

第五章 基于不确定性感知混合专家的层次化动态融合方法 48
5.1 研究动机 48
5.2 整体设计 50
5.3 不确定性估计 50
5.3.1 单模态质量特征提取 52
5.3.2 跨模态一致性特征提取 53
5.3.3 不确定性量生成 54
5.4 不确定性感知路由 55
5.4.1 路由输入向量 55
5.4.2 专家权重分布 57
5.4.3 路由熵 57
5.5 混合专家融合模块 58
5.5.1 层次记忆专家 58
5.5.2 双线性交互专家 59
5.5.3 冲突感知专家 59
5.5.4 保守残差专家 60
5.5.5 专家聚合与最终输出 60
第六章 实验与结果分析 62
6.1 实验的目的与内容 62
6.2 实验设置 63
6.2.1 数据集与预处理设置 63
6.2.2 评价指标 64
6.2.3 实验环境设置 64
6.3 总体对比实验 65
6.3.1 实验设置 65
6.3.2 结果与分析 66
6.4 消融实验 1——特征增强与提取的影响 68
6.4.1 实验设置 68

6.4.2 结果与分析 68
6.5 消融实验 2——动态融合方法的影响 70
6.5.1 实验设置 70
6.5.2 结果与分析 71
6.6 模态敏感性实验 73
6.6.1 实验设置 73
6.6.2 结果与分析 74
6.7 本章小结 76
总结与展望 82
参考文献 84
致谢 92

第一章　绪论

1.1　研究背景和意义

随着云计算、容器编排、持续交付和云原生技术体系的不断成熟，软件系统的构建方式正从传统的单体架构快速转向高度服务化、分布式化和弹性化的微服务架构。微服务架构通过将一个复杂系统拆解为多个围绕业务能力组织的小型服务，使各服务能够独立开发、独立部署和独立扩容，从而显著提升了系统在开发效率、部署灵活性和资源利用率方面的表现。对于电商平台、金融系统、社交平台、工业互联网平台以及智能运维场景中的大型应用而言，微服务已经成为支撑复杂业务快速演进的重要基础设施。

然而，架构灵活性和业务敏捷性的提升，往往伴随着系统运行复杂度的成倍上升。一个典型的微服务系统通常由大量服务实例、容器、数据库、中间件和消息系统组成，请求在系统内部需要跨越多个服务节点并通过复杂调用链完成业务闭环，任何一个环节的异常都可能沿依赖路径扩散并引发更大范围的性能退化甚至服务雪崩。在这种背景下，如何面向复杂微服务系统开展高效、稳定和准确的异常检测，已经成为智能运维领域亟待解决的重要问题[1]。

与传统单机程序或简单分布式系统相比，微服务系统异常具有更强的复杂性、动态性和传播性[2]。首先，异常来源更加多样。异常可能来自代码逻辑错误、服务间调用异常、资源竞争、网络抖动、数据库瓶颈、消息堆积、配置失误，甚至来自局部服务升级引起的兼容性问题。其次，异常表现更加隐蔽。许多异常在早期并不会直接导致服务不可用，而是以响应时延抖动、错误率轻微上升、链路局部拥塞、日志模板分布变化等形式逐步积累。再次，异常传播方式更加复杂。在强依赖的微服务系统中，一个看似局部的故障可能通过调用链快速向上下游传播，最终在多个服务、多个实例乃至多个数据源中表现出不一致但相关联的观测信号。因此，微服务系统异常检测已经不是简单的阈值判断问题，而是一个需要综合考虑时间依赖、服务依赖和多模态观测信息的系统级分析问题。

为了持续感知系统运行状态，现代微服务平台通常会构建完善的可观测性体系，对系统运行过程中产生的大量监控数据进行采集、存储和分析。其中，指标（Metric）、

日志（Log）和调用链追踪（Trace）是最核心、最常见也是最具代表性的三类监控数据[3]。指标数据通常以规则采样的多变量时间序列形式存在，能够从数值层面连续反映系统的资源利用、性能波动和服务状态，例如 CPU 使用率、内存占用率、磁盘 I/O、网络吞吐量、线程数量、QPS、错误率和服务响应时延等。由于指标具有采样连续、统计稳定和变化敏感的特点，因此在异常预警中往往最先被关注，也是许多传统监控系统的核心数据来源。日志数据则更多地从语义层面描述系统行为，它以文本或半结构化事件流的形式记录程序执行路径、状态变化、异常报错、请求上下文以及人工定义的重要业务事件。与指标相比，日志不仅反映系统“发生了什么”，还在一定程度上解释“为什么会发生”，因此在故障诊断和根因分析中具有重要作用。调用链追踪数据则从结构层面记录一次请求在多个服务之间的传播路径、节点间依赖关系和调用时延，能够显式揭示系统内部服务交互模式和性能瓶颈位置，是理解分布式系统异常传播的重要依据。

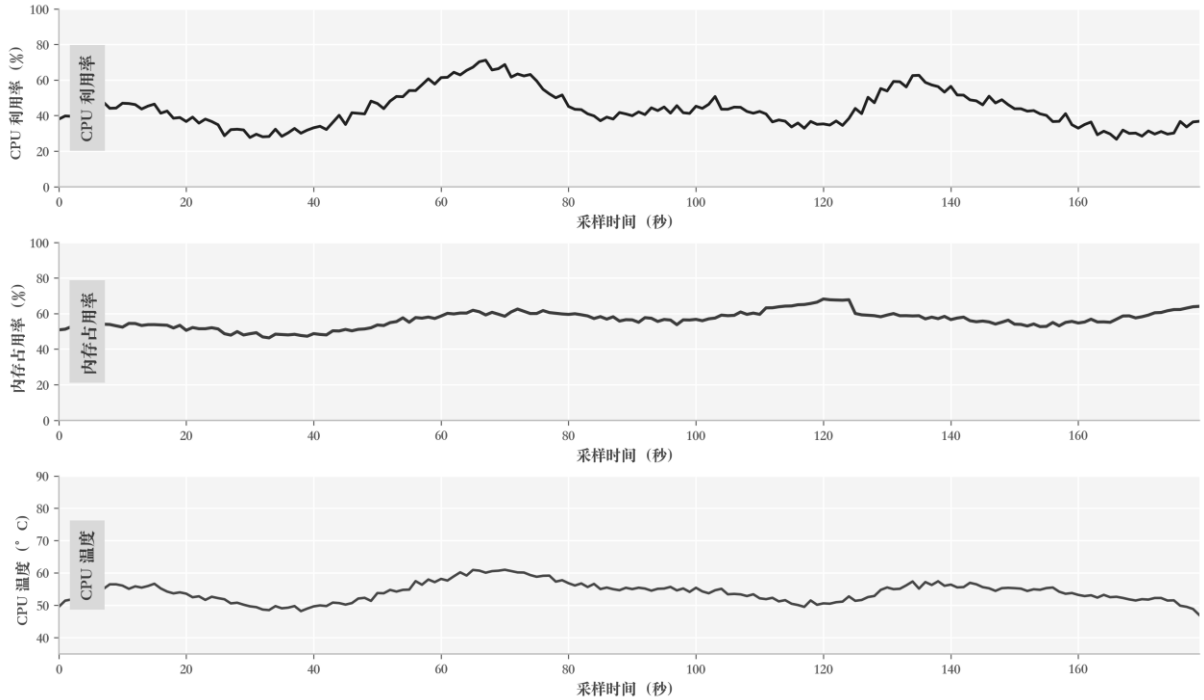

图 1-1 指标（Metric）数据示例

```
0,2021-07-01,webservice,webservice2,"2021-07-01 11:16:52,953 | WARNING | 0.0.0.3 | 172.17.0.4 | webservice2 | [memory_anomalies] trigger a high memory program, start at 2021-07-01 11:06:52.24
",WARNING,[memory_anomalies],2021-07-01 11:06:52.249428,2021-07-01 11:16:52.249428,600.0,train
1,2021-07-01,dbservice,dbservice1,"2021-07-01 11:54:27,616 | WARNING | 0.0.0.4 | 172.17.0.3 | dbservice1 | [memory_anomalies] trigger a high memory program, start at 2021-07-01 11:44:26.882752
",WARNING,[memory_anomalies],2021-07-01 11:44:26.882752,2021-07-01 11:54:26.882752,600.0,train
2,2021-07-01,dbservice,dbservice1,"2021-07-01 12:25:08,804 | WARNING | 0.0.0.4 | 172.17.0.3 | dbservice1 | [normal memory freed label] lasts ten minutes
",WARNING,[normal memory freed label],2021-07-01 12:25:08.804000,2021-07-01 12:35:08.804000,600.0,train
3,2021-07-01,dbservice,dbservice2,"2021-07-01 12:54:56,480 | WARNING | 0.0.0.2 | 172.17.0.2 | dbservice2 | [memory_anomalies] trigger a high memory program, start at 2021-07-01 12:44:55.798971
",WARNING,[memory_anomalies],2021-07-01 12:44:55.798971,2021-07-01 12:54:55.798971,600.0,train
4,2021-07-01,redisservice,redisservice1,"2021-07-01 13:18:43,143 | WARNING | 0.0.0.1 | 172.17.0.4 | redisservice1 | [memory_anomalies] trigger a high memory program, start at 2021-07-01 13:08:
",WARNING,[memory_anomalies],2021-07-01 13:08:42.446638,2021-07-01 13:18:42.446638,600.0,train
```

图 1-2 日志（Log）数据示例

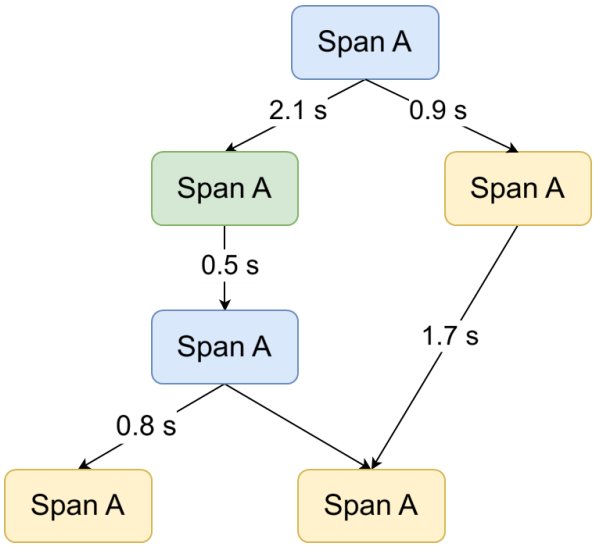

图 1-3 调用链追踪（Trace）数据示例

从学术研究角度看，面向多源异构时序数据的异常检测问题具有鲜明的交叉学科特征和较高的研究价值。其一，该问题天然涉及时间序列建模、文本语义理解、图结构学习和多模态融合等多个研究方向，需要在统一框架下同时考虑时序依赖、结构依赖和语义依赖，这为多模态表示学习研究提供了极具挑战性的应用场景。其二，异常检测区别于普通分类任务，往往存在标签稀缺、异常形态多样和分布不平衡等问题，因此需要在监督学习之外引入增强学习、自监督约束、对比学习或一致性学习等策略，以提升模型对复杂异常模式的泛化能力。其三，微服务异常具有明显的层次性和传播性，研究如何从局部服务现象推断系统级异常，如何从多模态信息中抽取统一的异常表示，对于推动系统智能诊断从“单点监控告警”向“系统级智能分析”演进具有重要理论意义。

从工程应用角度看，这一问题同样意义重大。对于大规模在线服务系统而言，异常检测能力的提升直接关系到系统可用性和业务连续性。若模型能够更早、更准地发现潜在异常，则运维人员便可以在故障演变为大规模事故之前进行处置，降低服务中断风险和经济损失。进一步地，多源联合异常检测得到的结果往往比单模态结果更具解释性，因为模型可以同时给出性能波动、日志语义变化和调用链结构异常等多方面证据，这对于后续根因定位、影响面评估和自动化修复决策具有直接价值。对于智能运维平台而言，构建面向多源异构监控数据的异常检测方法，还能够为异常告警压缩、故障关联分析、服务级别保障和弹性资源调度等上层任务提供更加可靠的基础能力。可以说，在当前大规模云服务和微服务应用日益普及的背景下，多源异构异常检测既是一个理论问题，也

是一个迫切的工程问题。

综上所述，面向微服务系统的多源异构时序数据异常检测问题具有明确的现实需求、丰富的理论内涵和较大的方法创新空间。它既要求研究者能够充分理解微服务系统异常的复杂传播规律，又要求在方法上打通数值时序建模、文本语义建模、图结构建模和多模态学习等多个方向。围绕这一问题开展研究，不仅有助于提升复杂系统异常检测的准确性和鲁棒性，也有助于推动智能运维技术从基于单一告警信号的被动监控，向面向系统全局状态的主动分析和智能诊断方向发展。正是在这样的背景下，本文选择以微服务系统中的指标、日志和调用链追踪三类监控数据为研究对象，系统研究**多源异构时序数据异常检测中的框架设计**、**特征表征**与**融合建模**问题，并尝试构建一套结构清晰、逻辑完整且具有一定可扩展性的异常检测方法框架。

1.2 国内外研究现状

1.2.1 基于单一数据的异常检测相关研究

目前，在工业界和学术界，基于单一数据源的异常检测方法仍然大量存在。以指标数据为例，传统系统监控主要依赖阈值规则、滑动窗口统计、变化点检测和时间序列预测等方法完成性能异常识别[4]。这类方法实现简单、部署方便，对于明显的资源异常和短时性能波动具有一定效果，但当异常模式隐蔽、指标相关关系复杂或异常传播路径较长时，单纯依赖指标很容易出现误报和漏报。一方面，指标本质上反映的是系统状态的“结果变量”，很多异常在指标层面的响应滞后于真正的故障触发点；另一方面，即使指标发生变化，系统也可能无法仅凭数值波动判断异常来自何处、为何发生。对于日志模态而言，日志模板匹配、日志序列建模和日志语言模型等方法能够在行为语义分析方面发挥重要作用[5]，但日志通常存在模板稀疏、变量噪声大、服务上下文混杂等问题，仅依赖日志容易在高噪声环境下失去稳定性，并且难以刻画资源状态和调用结构层面的异常。对于调用链数据而言，其在分析异常传播路径和定位性能瓶颈方面具有天然优势[6]，但 Trace 数据本身往往采样不完整、覆盖率不稳定，且更擅长揭示结构依赖，而不擅长刻画文本语义和连续性能变化。由此可见，单模态异常检测各有价值，但也都存在不可忽视的盲区。

（1）基于指标数据的异常检测研究

指标数据是系统异常检测中最常见的输入形式之一，通常表现为较为规整的多变量时间序列。早期研究主要依赖统计建模和传统机器学习方法，通过构建时间序列的分布模型、趋势模型或相关性模型来判断当前观测是否偏离正常范围。这类方法具有一定可解释性，在数据维度较低、系统行为模式相对稳定时能够取得较好的检测效果。然而，随着系统规模扩大、指标维度增加以及序列模式日益复杂，传统方法在刻画非线性依赖关系和复杂动态变化方面逐渐显得不足。

为提升对复杂时序模式的建模能力，研究者逐步将深度学习方法引入指标异常检测任务[7]，并形成了基于预测、基于重构、基于表示学习以及混合建模等几类典型思路。在基于预测的方法中，Wu 等[8]利用 GRU 与时间序列分解提出 AD-LTI，通过预测误差与局部趋势不一致性度量异常；Wu 等[9]提出 TimesNet，将一维时间序列映射到二维

张量空间以捕获多周期变化特征；Deng 和 Hooi[10]提出 GDN，通过图结构学习与图注意力机制建模多变量之间的依赖关系；Guo 等[11]进一步结合 GCN 与 Transformer，提出 HGTMAD 以同时建模空间拓扑关系和时间长依赖。基于重构的方法则通常通过重构误差识别异常，例如 Zhang 等[12]提出 AMSL，将卷积自编码器、记忆网络和自监督学习结合起来以增强泛化能力，Li 等[13]提出 RDSSM，通过鲁棒深度状态空间模型提升对受污染数据的适应性，Tuli 等[14]提出 TranAD，将 Transformer 重构与对抗训练结合以提高异常敏感性和鲁棒性。此外，表示学习方法也受到广泛关注，例如 Zamanzadeh Darban 等[16]提出 CARLA，通过自监督对比学习增强正常与异常模式的区分能力，Yue 等[17]提出 TS2Vec，从多尺度上下文中学习通用时间序列表征。与此同时，MTAD-GAT[18]、FuSAGNet[19]等混合模型进一步联合预测、重构和图结构建模，在复杂多变量场景中取得了较好的检测效果。

总体来看，基于指标数据的异常检测方法已经从传统统计分析逐步发展到深度时序建模、图结构建模和自监督表示学习等更深层次的分析范式，在多变量依赖关系建模和复杂波动模式识别方面取得了显著进展。然而，单纯依赖指标数据仍存在明显局限。一方面，指标主要反映系统的数值状态变化，对系统行为语义和异常传播路径的表达能力有限；另一方面，复杂系统中不同指标之间往往存在时滞依赖、拓扑关联和动态耦合关系，仅依赖单一模态的时间序列建模难以完整刻画异常的系统级传播机制。因此，基于指标的异常检测虽然仍是重要研究方向，但其单模态局限性也推动相关研究逐步向日志、调用链等多源数据联合建模演进。

（2）基于日志数据的异常检测研究

日志数据是系统运行行为的重要记录形式，也是智能运维领域中广泛使用的异常分析依据。早期日志异常检测研究主要依赖日志解析与模板匹配方法，即先通过日志解析算法将原始日志转化为结构化日志模板，再基于模板频次、模板序列或模板转移关系进行异常识别。这类方法实现相对成熟，在日志格式较为稳定、系统行为模式相对固定的场景下能够取得较好的效果。

随着系统规模扩大和日志复杂性增加，研究者逐步将深度学习与语义建模方法引入日志异常检测任务。例如，Meng 等[20]提出了 LogAnomaly 框架，用于在非结构化日志流中无监督地检测顺序异常和定量异常。该方法首次联合建模日志的顺序模式与定量

模式，并通过 template2Vec 生成能够表征日志模板语义及上下文关系的向量表示，从而弥补了仅依赖模板索引所带来的语义信息缺失问题。进一步地，Guo 等[21]提出了 LogFormer 框架，采用“预训练+适配器调优”的两阶段流程，在源领域上学习通用日志语义表示，再通过少量适配器参数将知识迁移到目标领域，以提升多域日志异常检测的泛化能力；同时，该方法引入 Log-Attention 模块，以减少日志解析过程中语义信息的损失，从而更准确地刻画日志序列特征。除基于序列和语义表示的方法外，也有研究开始从图结构角度建模日志之间的关联关系。Li 等[22]提出了 Logs2Graphs 方法，将日志事件转换为具有属性、有向性和权重的图结构，并设计 OCDiGCN 模型进行图级异常检测，使异常检测过程能够直接面向图表示学习进行优化；此外，该方法还能将图级异常评分分解到节点层面，为异常解释和根因分析提供支持。

总体来看，现有基于日志的异常检测方法已经从传统模板统计逐步发展到序列建模、语义表示学习以及图结构建模等更深层次的分析范式，在日志上下文依赖挖掘、跨域泛化和异常可解释性等方面取得了显著进展。然而，日志异常检测仍存在一定局限。首先，日志中通常包含大量动态变量、重复信息和冗余噪声，不同服务和模块生成的日志风格差异明显，这给日志解析和统一建模带来了较大挑战。其次，日志主要反映系统行为和事件语义，对于资源利用变化、性能波动以及服务间依赖关系的表达能力相对有限。再次，在高并发和复杂调用链场景下，单纯依赖日志往往难以完整刻画系统级异常的传播过程。因此，尽管日志数据具有较强的行为解释性，但仅依赖日志进行异常检测，在系统级建模和全局状态感知方面仍存在天然不足。

（3）基于调用链数据的异常检测研究

调用链追踪数据通过记录请求在多个服务间的传播路径、跨服务调用关系和阶段性时延信息，为理解微服务系统的运行机制和异常传播路径提供了重要支撑。相比指标和日志，Trace 数据天然具备结构化、拓扑化特征，因此在性能分析、瓶颈定位和根因追踪等场景中具有独特优势。

围绕调用链数据的异常检测研究，早期方法主要基于调用时延统计、关键路径分析和链路模板匹配等思路。例如，通过统计请求链路的平均时延、方差变化或异常跨度占比来识别性能异常；通过构建正常调用路径模板，并检测链路偏离模式来识别结构异常。随着深度学习和图学习方法的发展，研究者开始将调用链表示为向量、序列或图结构，

以更充分地挖掘服务依赖关系与异常传播模式。例如，Liu 等[23]提出 TraceAnomaly，将调用路径及其响应时间编码为服务级向量，并利用深度贝叶斯网络对正常 trace 模式进行无监督建模；Nedelkoski 等[24]提出 Multimodal LSTM，将调用链的结构特征与时延特征联合编码，并通过 LSTM 建模序列依赖，以同时识别结构异常和时延异常；Xie 等[25]提出 TraceVAE，将调用链建模为图结构，分别利用结构 VAE 和时间 VAE 对结构特征与时延特征进行建模，并结合图注意力机制捕获节点间关联；进一步地，Xie 等[26]提出 GTrace，通过图级和节点级 VAE 联合重构 trace 的结构与时延信息，并引入基于子结构分组和 Tree-LSTM 的编码策略，以兼顾检测精度与效率；此外，Zhang 等[27]提出 PUTraceAD，在少量异常标签条件下结合图注意力网络与正未标记学习实现半监督异常检测；Zhang 等[28]提出 TraceCRL，利用图对比学习来学习更具判别性的 trace 表示，并结合 One-Class SVM 完成异常识别。总体来看，基于调用链的异常检测方法已经从基于统计特征和模板匹配的浅层分析，逐步发展到面向图表示学习、对比学习和深层结构建模的分析范式。这类方法能够更好地利用微服务系统中的拓扑信息，对结构异常和传播异常具有较强的分析能力。

但是，Trace 模态也并非完美无缺。一方面，调用链数据通常存在采样率有限、链路信息缺失、跨度长度不一致等问题，导致数据完整性和稳定性不足。另一方面，调用链主要描述请求传播和结构依赖，对于日志中的语义异常和指标中的连续数值波动表达有限。特别是在一些异常尚未充分影响调用拓扑、但已在日志语义或指标趋势中出现先兆的场景下，仅依赖 Trace 往往难以及时完成准确识别。Sun 等[29]在针对 Trace 异常检测的综合基准研究中也指出，不同方法对 trace 深度、span 数量、服务规模和异常比例等数据特征较为敏感，目前尚不存在能够在各种场景下始终占优的通用方法。因此，调用链异常检测虽然在结构分析方面具有明显优势，但其单模态建模能力依然存在边界。

1.2.2 基于多源数据的异常检测相关研究

从信息属性上看，指标、日志和调用链追踪并不是对同一问题的简单重复观测，而是分别从性能、语义和结构三个互补视角共同刻画系统状态。指标数据强调“数值状态的变化”，适合捕捉系统资源和性能的波动趋势；日志数据强调“运行行为的语义表达”，适合揭示系统内部事件、异常上下文和操作意图；调用链追踪强调“请求传播与服务依赖关系”，适合刻画微服务间的交互结构与异常传播路径。三者在数据类型、组织形式、

时间粒度和噪声特征方面均存在明显差异：指标是典型的规整数值时序，日志是半结构化文本流，Trace 则具有天然的拓扑结构和链路关系。这种差异使得微服务监控数据天然属于多源异构时序数据。也正因如此，异常检测问题不再是对单一输入形式建模，而是面向多源异构数据开展统一表征与综合推断的复杂任务。

在实际场景中，系统异常往往会在多个模态上产生联动响应。例如，当某个关键下游服务出现阻塞时，调用链中可能首先表现为某一段链路时延急剧上升和关键路径延长；随后，其上游服务的请求堆积会体现在 CPU、内存或队列长度等指标的异常波动上；与此同时，系统日志中还可能出现超时重试、连接失败、降级处理或错误码爆发等现象。再如，当数据库连接池耗尽时，指标层面可能表现为资源利用不高但响应时间变长，日志层面则出现连接超时或事务异常，Trace 层面则表现为相关数据库调用跨度显著拉长。由此可见，异常不是某个模态中的孤立点事件，而往往是系统级故障在不同观测视角下的综合映射。若只依赖单一模态进行检测，模型通常只能看到异常的一部分影子，而无法完整把握异常的传播逻辑和系统影响范围。

认识到单模态方法的局限后，越来越多研究开始关注多源异构监控数据异常检测问题。从已有工作看，该方向大致经历了从双模态联合建模到三模态统一建模、再到图表示与协同优化的演进过程。在双模态异常检测方面，Zhang 等[30]提出 DeepTraLog，将调用链与日志统一表示为 trace event graph，并利用 GGNN + Deep SVDD 进行无监督异常检测，从而在统一图结构中同时刻画跨服务调用关系与服务内部日志事件；Liu 等[31]提出 LMGD，通过 time-aware LSTM 挖掘服务依赖关系，并在服务依赖图上融合日志和指标信息，实现了 log + metric 的联合异常检测。上述工作表明，多模态联合建模较单模态方法能够获得更完整的异常表征，但双模态方法仍然难以同时覆盖结构传播、性能波动与行为语义三个层面的异常信息。

在三模态异常检测方面，Ren 等[32]提出 Triple，以 trace 为骨架构建图表示，并将日志与指标嵌入节点特征，再结合 STGCN + Deep SVDD 完成异常检测，同时设计解释器输出关键日志语句、重要指标与相关 trace 线索，提升了检测结果的可解释性。Zhao 等[33]提出 AnoFusion，将指标、日志和调用链按各自模态特征序列化后构造成异构图流，利用 Graph Transformer Network 学习多模态相关性，并结合 GAT + GRU 建模动态图中的结构关系与时间依赖，进一步提升了实例级故障检测效果。相比之下，Wang 等

[34]提出的 AMulSys 则代表了当前多源异常检测更深入的发展方向。该方法不再将三类数据简单拼接或粗粒度映射到同一结构中，而是分别构建 trace-metric 有向加权图与日志异构图，利用 GAT 与 HGTN 对不同模态进行差异化建模，并进一步引入类别先验引导的数据增强和多层次对比学习，以缓解异常样本稀缺与类别不平衡问题，在两个真实微服务数据集上取得了优于已有方法的检测效果。总体来看，这些研究表明，多源异构异常检测已经从“多模态数据联合使用”逐步发展为“面向模态差异的结构化表示学习和跨模态协同优化”。

1.2.3 现有研究不足和本文切入点

尽管近年来已有研究开始尝试利用多模态监控数据提升异常检测效果，但整体上仍然存在三个突出的短板。

第一，**缺乏面向微服务多源异构监控数据的统一异常检测框架设计。**现有研究中，不少方法往往仅针对某一类监控数据设计局部模型，或者只是将多种模态数据简单接入同一分类器中，缺乏从问题定义、数据组织、特征表示到最终异常判定的系统性设计。这使得模型虽然形式上使用了多模态输入，但在整体结构上仍然较为松散，难以真正适应微服务系统中异常传播复杂、观测信号异构、模态关联紧密的场景。尤其在实际系统中，指标、日志和调用链追踪数据在时间粒度、组织形式和信息属性上存在显著差异，若缺乏统一且合理的框架约束，往往难以实现稳定、清晰且可扩展的异常检测流程。

第二，**多模态特征表征能力仍然不足**。许多方法虽然引入了 Metric、Log 和 Trace 等多类输入，但在具体建模时仍采用较为粗粒度的编码方式，例如直接对日志做模板计数、对 Trace 做简单统计、对指标做统一时序编码，然后在高层进行拼接。这种方式虽然便于实现，但难以充分发挥不同模态各自的结构优势。日志中的事件语义、上下文关系和服务交互线索没有被充分利用，Trace 中的调用拓扑、关键路径与时延传播特征没有得到深入表达，指标中的局部异常波动、多尺度变化规律和潜在关联结构也难以被完整建模。换言之，很多方法只是“把多种数据放进模型”，但并没有真正解决“如何高质量表示每一种数据”的问题。

第三，**多模态融合方式仍偏浅层，动态性与层次性不足**。现有研究中常见的融合方式包括特征拼接、平均加权、单层注意力或简单门控等。这些方法能够在一定程度

上实现信息整合，但通常难以充分考虑不同模态在不同异常场景下的信息质量差异。实际系统中，不同模态对异常的响应具有明显不均衡性：有时日志语义最敏感，而指标变化尚不明显；有时调用链结构异常更突出，而日志中几乎没有明显错误文本；也有时指标最先反映出异常趋势，而其他模态仍较为平稳。若融合机制缺乏对模态可靠性、信息层次和局部—全局语义关系的建模能力，模型就容易受到低质量模态噪声的干扰，导致融合结果在复杂场景下不够稳定和鲁棒。

综合上述分析可以看出，现有系统异常检测研究已经从单一指标分析逐步扩展到日志建模、调用链分析以及多源联合检测，但整体上仍存在明显不足。首先，单源方法难以充分反映系统级异常的复杂性，而多源方法虽然引入了多类数据，却常常停留在“多源输入、浅层融合”的层面。其次，不同模态的结构差异尚未得到充分重视，导致多源联合建模过程缺乏真正意义上的模态特性适配。最后，现有方法在整体框架设计、差异化特征建模以及层次化动态融合等方面仍有较大的改进空间。

基于这些问题，本文围绕多源异构时序数据异常检测中的三个关键问题展开研究。第一，针对现有方法整体结构松散、缺乏系统性的问题，设计一个面向微服务多源异构监控数据的统一异常检测框架，以明确问题定义、数据输入形式、处理流程与检测逻辑。第二，针对多模态特征表征不足的问题，研究差异化的特征增强与特征提取方法，以充分挖掘日志、调用链和指标三类数据中的异常模式。第三，针对多模态融合过程缺乏动态性、难以适应模态质量变化以及难以处理模态冲突的问题，研究基于不确定性感知混合专家的层次化动态融合方法，以提升融合表示对复杂异常场景的适应能力、鲁棒性与可解释性。

1.3 研究目标及内容

本文面向微服务系统运行过程中产生的多源异构时序监控数据，旨在构建一套能够综合利用指标、日志和调用链追踪信息的系统异常检测方法框架。与传统单模态异常检测方法不同，本文从多模态联合建模的角度出发，在充分保留各模态结构特性的基础上，提升模型对系统异常的识别能力、鲁棒性和泛化能力。

围绕这一总体目标，本文具体希望解决以下几个问题。首先，在整体建模层面，如何针对微服务系统中指标、日志和调用链追踪数据的异构性，构建一个结构清晰、流程

完整且具有可扩展性的统一异常检测框架，使不同模态能够在同一体系下完成组织、表示与联合推断。其次，在特征层面，如何针对三类结构差异显著的数据设计合理的增强与表示方式，使其能够在进入深度模型前保留更强的异常判别信息。最后，在融合层面，如何设计更具层次性和动态性的融合机制，使模型能够根据当前样本中模态信息质量的差异，自适应地整合不同来源的异常线索。

因此，本文的总体研究目标可以概括为：面向微服务系统中的多源异构时序数据异常检测任务，构建一个集**统一框架设计、差异化特征建模与层次化动态融合**于一体的异常检测方法体系，从而提升对复杂系统异常的识别能力。

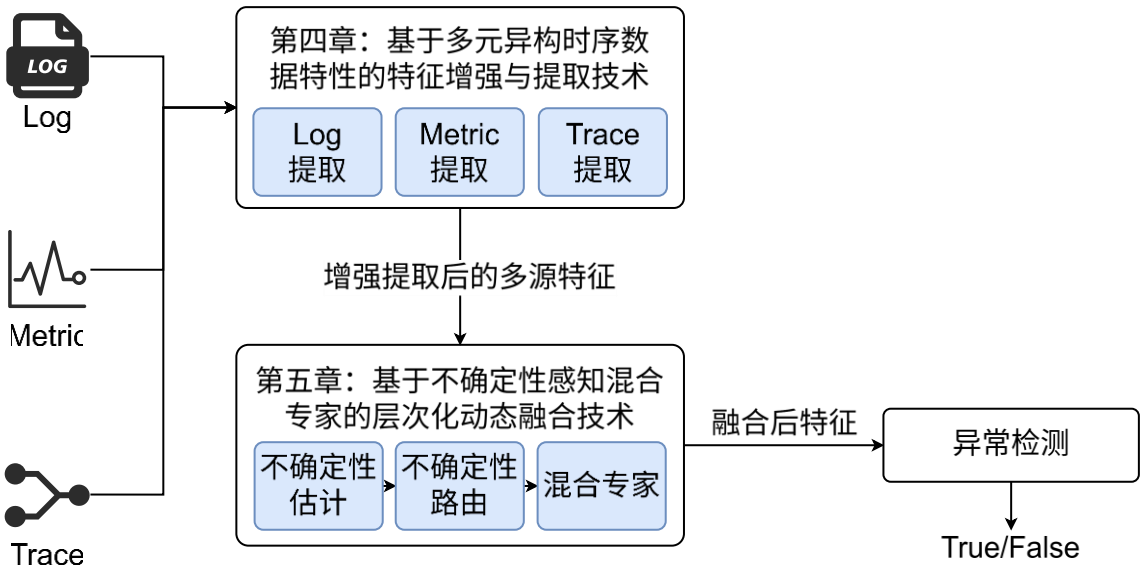

图 1-4 多源异构时序数据异常检测研究内容

1.3.1 面向多源异构时序数据的整体异常检测框架设计

针对微服务系统中指标、日志和调用链追踪三类监控数据在表示形式、时间粒度和结构特征上的异构性，本文首先从整体层面设计面向多源异构时序数据的异常检测框架。该框架以统一的数据预处理与时间对齐为基础，以差异化的模态特征建模为核心，以跨模态协同学习与异常判别为目标，系统构建从原始监控数据输入到异常结果输出的完整流程。通过在统一框架下组织多模态特征增强、图结构表示学习、跨模态信息交互和异常检测决策等关键环节，提升模型对复杂系统异常的整体感知能力和综合判别能力，为后续具体方法设计奠定总体架构基础。

1.3.2 基于多源异构时序数据的特征增强和提取技术

在训练阶段，本文不仅关注多种模态信息的简单拼接，更强调不同模态之间的一致性建模与互补关系挖掘。通过构建跨模态协同学习机制，引导模型在共享异常语义的同时保留各模态的独特表达能力，从而缓解模型对单一模态的过度依赖问题。该策略有助于提升模型在模态缺失、噪声干扰或数据质量不均衡场景下的稳定性和鲁棒性。

1.3.3 基于不确定性感知混合专家的动态融合方法

针对传统融合方法难以根据样本状态动态调整融合行为、难以处理模态质量不稳定以及模态冲突等问题，本文研究一种基于不确定性感知混合专家的层次化动态融合方法。该方法首先估计当前样本中不同模态的可靠性与跨模态冲突程度，随后基于不确定性信息动态路由不同融合专家，并通过多种具有不同归纳偏置的专家共同完成跨模态信息整合，从而实现更加灵活、精细和鲁棒的融合过程。通过这种设计，模型能够依据样本状态自适应选择融合行为，进一步提升多模态异常表征的表达能力、鲁棒性与可解释性。

1.4 本文组织结构

为清晰地展开本文研究内容，全文共分为六章，各章安排如下。

第一章为绪论。 本章主要介绍本文的研究背景与研究意义，系统梳理基于指标、日志、调用链以及多源异构监控数据的异常检测研究现状，在分析现有方法不足的基础上，提出本文的研究目标、研究内容和主要创新点，并给出全文的组织结构。

第二章为相关技术基础。本章主要介绍本文研究所涉及的基础理论与关键技术，重点包括图神经网络与异构图学习、多模态融合技术，以及注意力机制与时序表示学习等内容。其中，图神经网络与异构图学习为后续 Trace-Metric 联合图和日志异构图的建模提供理论基础；多模态融合技术为不同监控模态之间的信息交互与协同表达提供方法支撑；注意力机制与时序表示学习则为多源异构时序数据的特征提取与表示增强提供关键支撑。上述内容共同构成了本文后续方法设计与模型实现的理论基础。

第三章为面向多源异构时序数据的异常检测总体框架。 本章从整体角度给出本文方法的系统结构，明确问题定义、输入输出形式以及数据处理、特征提取、融合分类的完整流程，阐明本文方法的总体设计思路。

第四章为基于多源异构时序数据特性的特征增强与提取技术。 本章针对日志、调用链追踪和指标三类监控数据的差异化特征，分别研究相应的数据增强和特征提取方法，重点介绍日志特征建模、Trace 结构特征建模以及指标多尺度时序特征提取机制。

第五章为基于不确定性感知混合专家的层次化动态融合方法。本章针对多模态融合中固定融合方式难以适应样本差异、模态质量动态变化以及模态冲突等问题，提出一种融合不确定性估计、动态路由、混合专家交互与门控更新的层次化动态融合方法，并说明其在异常检测框架中的作用机制。

第六章为实验设计与结果分析。 该章首先对本文方法的实验设置、对比实验和消融实验结果进行系统分析，验证各模块设计的有效性；

随后对全文工作进行总结，并针对当前研究存在的不足与未来可能的改进方向进行展望。

通过上述章节安排，本文从问题背景、理论基础、总体框架到关键方法与实验验证层层展开，逐步完成对多源异构时序数据异常检测问题的系统研究。

第二章　相关技术基础介绍

本章介绍本研究的技术背景，主要包括图神经网络与异构图学习、多模态融合技术，以及注意力机制与时序表示学习等内容，为后续异常检测框架设计与关键方法实现提供理论基础。

2.1　图神经网络与异构图学习

2.1.1　图神经网络基本原理

图神经网络（Graph Neural Network, GNN）是一类面向图结构数据的深度学习模型，主要用于建模节点、边及其拓扑关系所共同构成的非欧式数据[35]。与图像、语音等规则结构数据不同，图数据通常具有节点数不固定、连接关系不规则、局部结构差异大等特点，传统卷积神经网络难以直接适用。图神经网络通过在图结构上定义信息传播和特征聚合机制，使模型能够在保留拓扑信息的基础上学习节点表示、边表示以及图级表示，因而在推荐系统、知识图谱、社交网络分析、程序分析和异常检测等领域得到了广泛应用。

从数学上看，一个图通常表示为 $G = (V, E)$，其中 V 表示节点集合，E 表示边集合。若每个节点或边还具有属性信息，则可以分别用节点特征矩阵和边特征矩阵进行表示。图神经网络的核心思想是消息传递（Message Passing）机制，即通过多层迭代地聚合邻居节点的信息来更新当前节点表示。对于某个节点而言，其表示不仅依赖于上一层自身的特征，还依赖于相邻节点通过边传递来的上下文信息。经过多层传播后，节点表示能够逐步融合更大范围内的结构依赖，从而形成兼顾局部属性和全局拓扑的表示结果。

一般来说，图神经网络的一次迭代可以抽象为两个步骤。第一步是邻域聚合，即从节点的邻居集合中收集相关特征信息；第二步是状态更新，即将聚合结果与当前节点原有表示结合，并通过线性变换和非线性激活函数得到新的节点表示。这一过程可以形式化表示为：节点首先对邻居信息进行聚合，然后再通过更新函数完成自身状态更新。通过堆叠多层图神经网络，模型可以逐步获得更高阶的结构语义信息。

除了节点级表示学习外，图神经网络还可以通过图级读出（Readout）操作获得整个

图的表示。常见的图级读出方法包括平均池化、最大池化、加权求和和注意力池化等。这类机制尤其适用于图分类、图异常检测等任务。例如，在微服务异常检测中，一次调用链或一个结构化样本可以被建模为图对象，模型通过节点级编码和图级汇聚获得整张图的全局表示，再据此进行异常判定。

图神经网络相较于传统序列模型和多层感知机的优势，在于它能够显式利用实体之间的关系信息。对于微服务系统而言，无论是服务间调用关系、日志事件之间的上下文依赖，还是指标与调用结构之间的耦合关系，都天然具有图结构特征。若仅采用向量拼接或序列建模方法，往往难以充分刻画这些关系模式；而图神经网络则能够将“节点属性”和“结构依赖”统一纳入学习过程，从而更适合复杂系统场景下的异常检测任务。

然而，图神经网络也存在一些局限性。例如，随着网络层数加深，节点表示可能出现过平滑（over-smoothing）问题，即不同节点的特征逐渐趋同，导致判别能力下降；同时，图结构中往往存在噪声边、稀疏连接和异构关系，若建模不当，也会影响模型效果。因此，在实际应用中，通常需要结合注意力机制、残差连接、异构关系建模等策略来提升图神经网络的表达能力和鲁棒性。

2.1.2 典型图神经网络模型

随着图神经网络的发展，研究者提出了多种典型模型，以适应不同类型图数据和不同任务需求。其中，图卷积网络（GCN）、门控图神经网络（GGNN）和图注意力网络（GAT）是最具代表性的三类方法。

图卷积网络（Graph Convolutional Network，GCN）是图神经网络中最经典的模型之一，其核心思想是将卷积操作推广到图结构空间，通过对邻接节点的特征进行加权聚合，实现节点表示更新[36]。GCN 通常采用归一化邻接矩阵来平衡不同节点度数带来的影响，从而使模型在传播过程中更加稳定。由于 GCN 结构相对简洁、训练效率较高，因此被广泛应用于节点分类、图分类以及关系建模任务。在系统异常检测中，GCN 可用于建模服务间依赖关系、变量之间的结构联系等，但其聚合权重通常较为固定，难以区分不同邻居的重要性。

门控图神经网络（Gated Graph Neural Network, GGNN）在图传播过程中引入门控循环单元思想，通过类似 GRU 的更新机制控制信息保留与遗忘，从而增强模型对长距离依赖关系的建模能力[37]。与普通图卷积相比，GGNN 更适合处理具有较强状态传播特

征的图结构数据，例如程序控制流图、调用路径图以及具有明确传播过程的系统拓扑图。在多步传播过程中，门控机制能够抑制无关信息积累，使模型更稳健地建模远距离节点之间的影响关系。不过，GGNN 在参数量和计算开销上通常高于 GCN，因此在大规模图场景下需要在性能与效率之间进行权衡。

图注意力网络（Graph Attention Network, GAT）则进一步提升了图神经网络对邻域异质性的建模能力[38]。该方法将注意力机制引入图结构学习过程中，使节点在聚合邻居信息时能够动态学习不同邻居的重要程度。具体而言，GAT 通过可学习的注意力参数计算节点与其邻居之间的相关性分数，再利用归一化权重完成加权聚合。相比 GCN 的固定邻域聚合方式，GAT 更能突出关键节点和关键边的作用，因此在复杂关系建模、局部异常识别和噪声抑制方面具有明显优势。对于微服务系统中的 Trace-Metric 联合图而言，不同服务节点在一次请求链路中的贡献程度往往存在差异，GAT 可以更灵活地对关键服务和关键交互关系进行建模。

除了上述三类模型外，图神经网络还衍生出了许多面向图级任务的扩展方法，例如基于图池化的层次化图学习模型、基于 Transformer 的图结构建模模型，以及结合自编码器思想的图重构模型。这些方法在图分类、图异常检测和图表示压缩等方面表现出良好能力。对于本文研究而言，图神经网络的意义不仅在于提供图结构建模工具，更在于为后续 Trace-Metric 图表示学习与日志异构图编码提供统一的理论基础。

总体来看，典型图神经网络模型在建模目标、特征传播方式和结构适应能力上各有特点。GCN 更适合高效的基础结构聚合，GGNN 更强调传播过程中的状态控制，GAT 则更突出邻居重要性的动态分配。在面向微服务异常检测的任务中，往往需要结合具体数据特点选择合适的图神经网络结构，或者在此基础上进一步设计适配复杂关系模式的改进模型。

2.1.3 异构图学习方法

现实世界中的许多图数据并非由单一类型的节点和边构成，而是包含多种实体类型及多种关系类型。这类图通常被称为异构图（Heterogeneous Graph）。与同构图相比，异构图能够更丰富、更准确地表达复杂系统中的多实体交互关系。例如，在微服务日志场景下，不同服务产生的日志事件具有不同的语义角色，日志事件之间也可能存在时间相邻、模板相似、服务归属和上下文依赖等多种关系，这些都天然适合通过异构图进行

描述。

异构图学习的核心目标，是在统一表示空间中同时建模结构关系和类型差异。若将异构图简单视为普通同构图处理，往往会忽略不同节点类型和边类型的语义差异，使模型难以准确捕获复杂关系模式[39]。因此，异构图学习通常需要为不同类型的节点、边或元路径设计差异化的建模机制。

早期异构图学习方法多基于元路径（Meta-path）思想，即通过预先定义一类典型的节点类型连接模式来刻画语义关系。例如，在学术网络中，作者—论文—作者构成一类元路径，可用于表示合作关系；在系统日志中，服务—日志事件—模板也可构成某种语义路径。元路径方法能够显式引入领域知识，但往往依赖人工设计，灵活性相对有限。

随着图神经网络的发展，研究者开始将异构图与神经网络模型结合，通过类型感知的参数设计来实现异构关系学习。其基本思想是：在邻域聚合过程中，不同类型的节点和边采用不同的投影矩阵、变换函数或注意力权重，从而保留关系异质性。与同构图上的统一聚合不同，异构图学习更强调“按类型区分建模”，即不仅要考虑某个邻居是否连接到当前节点，还要考虑它属于什么类型、通过什么关系发生连接。

近年来，异构图 Transformer 成为异构图学习的重要方向。该类方法借鉴 Transformer 的自注意力机制，为不同节点类型和边类型设计独立的查询、键、值映射或关系偏置，使模型能够在统一框架下建模复杂异构关系[40]。与传统元路径方法相比，异构图 Transformer 能够自动学习不同关系的重要性，减少人工特征设计带来的限制；与普通 GNN 相比，它在表达远距离依赖和多关系交互方面也具有更强能力。

在微服务异常检测场景中，异构图学习尤其适合日志建模。一方面，日志事件本身具有明显的语义异构性，不同服务、不同模板、不同时间上下文形成的结构关系并不一致；另一方面，日志异常往往不是孤立出现的，而是与服务交互、调用上下文和事件传播路径紧密相关。将日志表示为异构图，能够同时编码日志语义信息、服务归属关系和事件交互模式，再通过异构图学习模型提取更具判别力的结构化表示。因此，异构图学习为复杂日志数据建模提供了重要技术支撑，也为后续多模态图表示学习奠定了基础。

2.2 多模态融合技术

2.2.1 多模态融合的基本问题

多模态学习旨在联合利用不同来源、不同结构或不同语义空间的数据，以提升模型对复杂任务的理解能力。在微服务异常检测中，指标、日志和调用链分别从数值状态、事件语义和结构传播三个角度刻画系统运行过程，三类模态具有明显的互补性[33]。因此，多模态融合的核心目标，是在保留各模态专属信息的同时，挖掘模态间的一致性与互补性，从而构建更具判别力的联合表示。

尽管多模态融合具有明显优势，但在实际建模过程中仍面临若干基础问题。首先，不同模态的数据结构存在显著差异。指标通常为规则时间序列，日志多为半结构化文本，调用链则具有树状或图状结构，这使得三类数据难以直接映射到统一表示空间。其次，不同模态的采样频率和时间粒度往往不一致，指标通常按固定周期采样，日志和调用链则以事件驱动方式产生，因此需要进行时间对齐和窗口化处理。再次，不同模态对异常的敏感程度并不相同，在不同异常场景中，各模态的重要性可能动态变化。例如，有些异常会首先表现为日志报错，而另一些异常则更早反映在时延增长或调用链结构变化上。

此外，多模态融合还容易受到噪声和冗余信息的干扰。某些模态可能存在信息缺失、质量不稳定或异常信号较弱的问题，若简单将各模态一并纳入建模过程，反而可能降低整体性能。因此，多模态融合并非简单的信息叠加，而是需要解决表示空间不一致、信息重要性动态变化以及噪声抑制等关键问题。只有在此基础上，才能实现真正有效的多模态协同学习。

2.2.2 特征级、模型级与决策级融合

根据融合发生的阶段不同，多模态融合方法通常可分为特征级融合、模型级融合和决策级融合三类。

特征级融合是最直接的方式，即先分别提取不同模态的表示向量，再通过拼接、加权求和、线性投影或共享映射等方式得到统一特征表示。这类方法实现简单、计算代价较低，在工程上较易部署。对于模态差异不大或任务结构较简单的场景，特征级融合通常能够取得较好效果。然而，当各模态之间存在较大结构差异时，简单拼接往往只能实现信息堆叠，难以显式建模模态间的语义关联和互补关系。

模型级融合则强调在特征提取过程中引入模态间交互，使一个模态能够感知另一个模态的信息。例如，可以通过共享编码层、跨模态注意力、交互式 Transformer、协同图学习等机制，在编码阶段实现模态之间的信息流动。相比特征级融合，模型级融合更有利于挖掘模态间深层关联，因此在复杂多模态任务中更具优势。但这类方法模型结构较复杂，对训练数据规模和计算资源也提出了更高要求。

决策级融合则是在不同模态分别完成建模和预测后，对各模态的输出结果进行加权组合或投票决策。例如，可将不同模态的异常得分按固定权重或学习到的权重进行融合，得到最终判定结果。该方法具有较强的模块独立性，便于对单一模态模型进行替换和维护，在解释性方面也较为直观。然而，决策级融合由于发生在较晚阶段，模态之间缺乏深入交互，因此往往难以充分利用跨模态互补信息。

在实际应用中，上述三类融合方式并非相互排斥。很多多模态系统会采用混合融合策略，例如先通过模型级交互增强各模态表示，再通过特征级拼接得到统一向量，最终结合决策级机制完成判别与校准。对于微服务异常检测任务而言，考虑到不同模态结构差异较大、异常信号动态变化明显，单一融合方式往往难以兼顾表达能力与鲁棒性。因此，需要结合任务需求设计更灵活、更具适应性的融合机制。

2.2.3 动态融合与层次化融合方法

随着多模态任务复杂度提升，静态融合方式逐渐暴露出局限性。所谓静态融合，是指在所有样本上采用统一的融合结构和固定的模态权重，而不考虑具体输入场景中模态重要性的变化。然而，在实际系统中，不同样本、不同异常类型对应的模态贡献往往并不一致。例如，某些异常更依赖日志语义信息，而另一些异常则更依赖调用结构和时延变化。若始终采用固定权重进行融合，模型容易忽略关键模态，影响异常检测效果。

为此，研究者提出了动态融合方法。动态融合的核心思想，是根据输入样本的特征自动调整不同模态的权重或交互方式。常见方法包括门控机制、注意力加权、动态路由和条件计算等。门控机制[41]通常通过一个可学习的控制函数，根据输入特征生成不同模态的保留比例，从而实现自适应融合；注意力加权则通过计算不同模态或不同特征之间的相关性分数，突出关键模态信息；动态路由进一步通过路径选择或专家分配机制，使不同样本能够走向不同的融合分支，提高模型对复杂场景的适应能力。

层次化融合则强调在不同语义层次上逐步整合多模态信息，而非一次性完成融合。

其基本思想是：先在模态内部提取局部和全局表示，再在跨模态层面进行交互，最后在高层语义空间中得到联合表示。相比单层融合，层次化融合更适合处理结构复杂、语义层次丰富的多模态数据。一方面，它能够避免过早融合导致模态专属特征丢失；另一方面，也能够在高层抽象空间中更自然地建立跨模态关联。

在异常检测场景中，动态融合与层次化融合具有较强的适用性。系统异常往往具有阶段性和传播性，不同模态在不同阶段反映出的信息并不相同。通过动态融合，可以根据当前样本的实际特征自适应强调更可靠的模态；通过层次化融合，则可以逐步整合从局部特征到全局状态的多层信息，增强异常表示的完整性和鲁棒性。因此，动态融合与层次化融合已成为当前多模态异常检测研究中的重要方向，也为本文后续的融合方法设计提供了直接理论支撑。

2.3 注意力机制与时序表示学习

2.3.1 卷积与循环网络的时序建模能力

时序表示学习是异常检测任务中的关键基础问题之一。对于指标序列、日志序列乃至调用行为序列而言，模型需要同时刻画局部波动模式和跨时间步的长期依赖关系。为此，卷积神经网络和循环神经网络被广泛应用于时序建模任务中。

卷积神经网络（Convolutional Neural Network, CNN）虽然最早用于图像处理，但其局部感受野和参数共享机制同样适用于时间序列分析[42]。在时序建模中，一维卷积可通过滑动卷积核提取局部时间窗口内的变化模式，如突增、突降、周期性波动和局部异常峰值等。相较于传统全连接网络，卷积结构不仅能够降低参数规模，还能更有效地提取局部模式。进一步地，多尺度卷积可以使用不同大小的卷积核，从多个时间尺度上建模序列特征，使模型同时感知短期变化和中期趋势。因此，卷积网络在指标异常检测和局部行为模式提取方面具有良好效果。

循环神经网络（Recurrent Neural Network, RNN）则更适合建模序列中的顺序依赖关系[43]。它通过隐藏状态在时间维度上传递信息，使当前时刻的表示能够结合历史上下文进行更新。传统 RNN 在长序列建模时容易出现梯度消失和梯度爆炸问题，因此研究者进一步提出了长短期记忆网络（LSTM）和门控循环单元（GRU）等改进结构。LSTM 通过输入门、遗忘门和输出门控制信息保留与更新，能够较好地建模长期依赖关系[45]；

GRU 则在结构上更简洁，通过更新门和重置门实现状态控制，在保证表达能力的同时降低了计算开销[45]。

在异常检测任务中，卷积网络和循环网络各有优势。卷积网络擅长提取局部模式、短期波动和多尺度变化，适合处理具有明显局部异常特征的数据；循环网络则更擅长建模时间顺序关系和长程依赖，适合刻画异常随时间传播和累积的动态过程。因此，许多时序表示学习方法会结合卷积与循环结构，以实现局部模式提取和全局时序依赖建模的协同。

2.3.2 自注意力与多头注意力机制

随着 Transformer 架构的发展，自注意力机制成为时序建模和多模态学习中的核心技术之一[46]。与卷积和循环结构不同，自注意力机制不依赖固定感受野或时间递归传播，而是直接计算序列中任意两个位置之间的相关性，从而实现对全局依赖关系的建模。

自注意力机制的基本思想是：对于输入序列中的每个位置，分别生成查询（Query）、键（Key）和值（Value）三个向量，再通过查询与所有键之间的相似度计算注意力权重，最后对值向量进行加权求和，得到该位置的新表示。通过这一过程，模型能够根据任务需求，自适应关注序列中的关键位置。与循环网络相比，自注意力机制更容易并行计算，且在长序列建模中具有更强的全局依赖捕捉能力。

多头注意力机制是在自注意力基础上的进一步扩展。其核心思想是并行设置多组独立的注意力头，使模型能够从不同子空间、不同关系视角对序列进行建模。不同注意力头可以分别关注局部邻近关系、长距离依赖、周期性结构或异常突变模式，最终通过拼接或线性变换得到更丰富的表示结果。多头注意力的引入，显著增强了模型的表达能力和鲁棒性。

在时序异常检测中，自注意力和多头注意力尤其适用于建模复杂变量之间的远程依赖与全局交互。例如，在多变量指标序列中，某一变量的异常可能由较远时间步的另一变量变化触发，传统卷积或循环结构不一定能高效捕捉这类关系，而注意力机制则能够更直接地完成全局依赖建模。此外，在多模态融合中，跨模态注意力也可看作注意力机制的重要扩展形式，其本质是一个模态对另一个模态的信息进行选择性关注，从而实现更加细粒度的模态交互。

2.3.3 位置编码与残差连接

尽管注意力机制在全局依赖建模方面具有明显优势，但其本身并不显式包含序列顺序信息。换言之，若不引入额外机制，模型很难区分“先发生”和“后发生”的事件顺序。对于时序数据而言，时间顺序本身是极其重要的信息，因此需要通过位置编码为模型提供位置信息。

位置编码的作用，是将序列中每个位置的顺序信息映射为可学习或固定的向量，并将其加入输入表示中。常见方法包括基于正弦余弦函数的固定位置编码和基于参数学习的可训练位置编码。固定位置编码具有较好的泛化性，能够适应不同长度序列；可训练位置编码则更灵活，能够针对具体任务学习更合适的位置表示。在时序异常检测中，位置编码可以帮助模型区分不同时间步之间的先后关系，从而更准确地理解异常的发生顺序和演化过程。

残差连接（Residual Connection）则是深层网络中常用的重要结构，其基本思想是将输入直接与变换后的输出相加，从而保留原始信息并缓解深层网络训练中的梯度消失问题。残差连接最早在卷积网络中取得成功，后来也被广泛应用于 Transformer、图神经网络和多模态融合模型中[47]。对于异常检测任务而言，残差连接不仅有助于提升模型训练稳定性，还能够在多层表示学习过程中保留低层次的原始特征，使模型兼顾浅层局部信息和深层抽象信息。

在时序表示学习中，位置编码与残差连接通常与注意力机制共同使用。位置编码负责提供顺序先验，残差连接负责稳定深层学习过程，而注意力机制负责建模全局依赖，三者结合能够显著提升模型对复杂时序模式的表达能力。在本文后续方法中，相关机制将被进一步用于多源异构时序数据的特征提取和融合表示学习，因此有必要在本章中加以介绍。

2.4 本章小结

本章围绕本文后续方法设计所涉及的关键技术基础进行了介绍。首先，阐述了图神经网络的基本原理及其典型模型，包括图卷积网络、门控图神经网络和图注意力网络，并进一步介绍了异构图学习方法，为后续面向 Trace-Metric 联合图和日志异构图的表示学习提供了理论支撑。其次，围绕多模态融合技术，分析了多模态建模中面临的表示差

异、时间对齐和动态权重分配等基本问题，并总结了特征级、模型级、决策级融合，以及动态融合与层次化融合的主要思想。最后，介绍了注意力机制与时序表示学习中的关键技术，包括卷积与循环网络的时序建模能力、自注意力与多头注意力机制，以及位置编码和残差连接等内容。

总体来看，上述技术共同构成了本文方法的核心理论基础。其中，图神经网络与异构图学习为多源异构数据的结构化建模提供了有效工具，多模态融合技术为不同模态之间的信息协同提供了基本框架，注意力机制与时序表示学习则为复杂时序模式的提取与建模提供了重要支撑。基于这些技术基础，下一章将进一步给出本文面向多源异构时序数据的异常检测总体框架，并系统阐述各模块之间的协同关系与整体设计思路。

第三章　面向多源异构时序数据的异常检测总体框架

前两章对微服务异常检测的研究背景、相关技术基础以及多源异构监控数据建模方法进行了梳理。在此基础上，本章从整体方法框架出发，对本文提出的多源异构时序数据异常检测模型进行系统说明。本章首先明确微服务异常检测任务的问题定义、输入输出形式与建模目标，然后给出整体架构及主要数据流，进一步阐述特征增强、图构建、图表示学习、跨模态融合和异常判别等关键模块之间的关系，最后说明模型训练过程中的多损失联合优化目标。通过本章内容，可以为后续第四章的特征增强与提取方法以及第五章的动态融合方法提供统一的框架基础。

3.1　研究目标与问题定义

微服务系统在运行过程中会持续产生调用链追踪、性能指标和日志事件等多源监控数据。三类数据分别从系统调用关系、运行状态变化和语义行为模式等不同角度描述系统状态，具有明显的互补性。然而，这些数据在时间粒度、组织形式和语义层次上存在显著差异，若直接进行特征拼接，不仅难以刻画模态内部的结构信息，也容易削弱异常传播过程中的跨模态关联特征。因此，本文不仅关注单一数据源上的局部异常模式，还强调不同模态之间的互补性、传播性和协同性，希望构建一个能够统一处理多源异构监控数据、并兼顾结构建模与模态协同的异常检测模型，在统一框架下同时刻画系统状态的性能变化、行为语义以及结构依赖关系，从而提升复杂异常场景下的检测能力与模型鲁棒性。

设训练集表示为

$$D = (T_i, L_i, M_i, y_i)_{i=1}^{N}$$

其中，T_i、L_i 和 M_i 分别表示第 i 个样本对应的调用链追踪数据、日志数据和指标数据，$y_i \in 0,1$ 表示该样本的异常标签，$y_i = 1$ 表示异常样本，$y_i = 0$ 表示正常样本。考虑到三类监控数据在采样方式和时间粒度上存在明显差异，本文首先以时间窗为中心完成多模态对齐，再将对齐后的样本输入统一的异常检测框架。

对于任意时间窗 $W_i = [t_i^s, t_i^e]$，若其与异常区间集合 $A = [a_k^s, a_k^e]_{k=1}^{K}$ 中任一

区间存在重叠，则将其标记为异常样本，即

$$y_i = I(W_i \cap (\bigcup_{k=1}^{K}[a_k^s, a_k^e]) \neq \emptyset)$$

其中，$I(\cdot)$ 为示性函数。该定义保证了样本标签与真实异常发生区间在时间上保持一致，也为后续滑动窗口建模和统一监督学习提供了基础。

那么，异常检测任务可形式化为学习映射关系：

$$F: (T_i, L_i, M_i) \mapsto \hat{y}_i,$$

其中，$\hat{y}_i$ 为模型输出的异常概率。

围绕这一任务，本文在整体设计上遵循以下三个目标。其一，模型应能够保留不同模态各自的结构特征，而不是将其简单压缩为同构向量；其二，模型应能够在特征层和表示层同时引入跨模态互补信息，以提升复杂异常场景下的判别能力；其三，模型应具备统一的训练与推理路径，使其既具有较好的方法完整性，也便于后续部署到真实微服务监控环境中。

3.2 整体架构

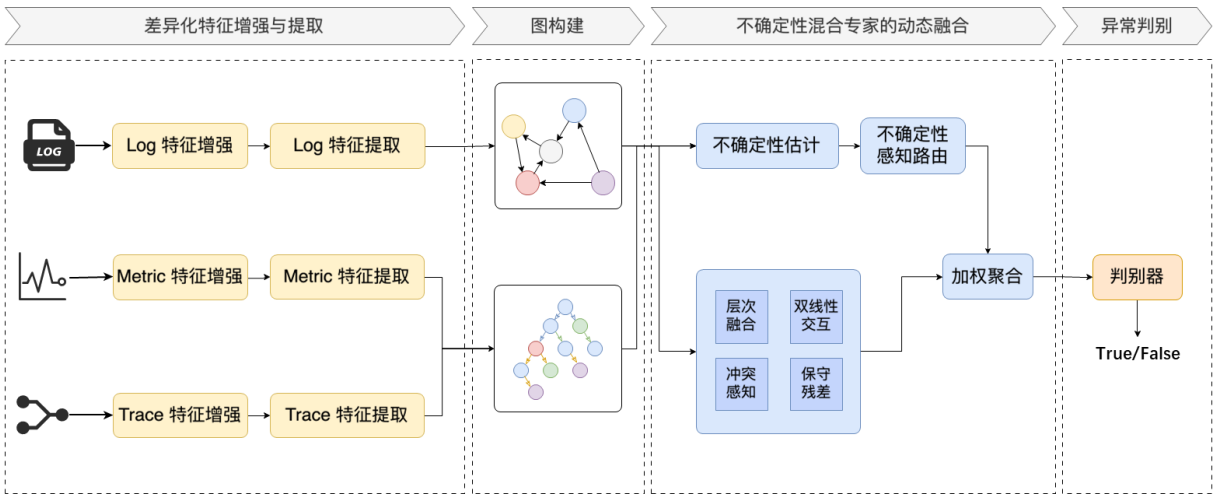

图 3-1 多源异构时序数据异常检测整体架构图

结合上述目标，本文将模型总体流程组织为“原始数据输入 - 特征增强与提取 - 图构建与图表示学习 - 动态融合 - 判别”的主链路，并在训练阶段通过协同训练机制对表示空间和分类边界进行联合优化。换言之，从推理路径看，模型关注的是如何逐步将原始监控数据转化为可判别的异常表示；而从训练路径看，协同训练并不是一个独立于主流程之外的串行模块，而是以辅助约束的形式贯穿特征学习、模态融合和最终判别过

程。

原始输入虽然来自指标、日志和调用链追踪三类数据，但在进入深度模型之前，并不是简单地进行向量拼接，而是首先根据三类模态的结构特征分别进行增强与重构；随后将 Trace 与 Metric 联合构造成 Trace-Metric 图，将日志序列构造成日志异构图，从而形成双分支图表示学习框架；之后通过跨模态协同学习机制和层次化动态融合模块完成多模态信息交互；最终由分类器输出异常概率。

从数学形式上看，本文模型可概括为如下分阶段映射：

$$\left(\mathbf{z}_i^{trace}, \mathbf{z}_i^{metric}, \mathbf{z}_i^{\log}\right) = f_{ext}(T_i, L_i, M_i)$$

$$\downarrow$$

$$\left(G_i^{tm}, G_i^{\log}\right) = f_{graph}\left(T_i, L_i, M_i, \mathbf{z}_i^{trace}, \mathbf{z}_i^{metric}, \mathbf{z}_i^{\log}\right)$$

$$\downarrow$$

$$\mathbf{h}_i^{tm} = f_{tm}\left(G_i^{tm}\right), \quad \mathbf{h}_i^{\log} = f_{\log}\left(G_i^{\log}\right)$$

$$\downarrow$$

$$\left(\tilde{\mathbf{h}}_i^{tm}, \tilde{\mathbf{h}}_i^{\log}\right) = f_{fus}\left(\mathbf{h}_i^{tm}, \mathbf{h}_i^{\log}\right)$$

$$\downarrow$$

$$\hat{y}_i = \sigma\left(\mathrm{MLP}\left([\tilde{\mathbf{h}}_i^{tm} \| \tilde{\mathbf{h}}_i^{\log}]\right)\right),$$

其中，$f_{ext}(\cdot)$ 表示模态内特征增强与提取过程，$f_{graph}(\cdot)$ 表示图构建过程，G_i^{tm} 表示第 i 个样本对应的 Trace-Metric 图，$G_i^{\log}$ 表示对应的日志异构图，$f_{tm}(\cdot)$ 和 $f_{\log}(\cdot)$ 分别表示 Trace-Metric 分支与日志分支的图表示学习函数，$f_{fus}(\cdot)$ 表示跨模态融合模块，$f_{cls}(\cdot)$ 表示分类头，$\sigma(\cdot)$ 为 Sigmoid 函数。该表达式反映出本文方法并非简单的单阶段分类模型，而是一个由特征组织、结构建模、跨模态交互和监督判别共同组成的整体框架。

需要强调的是，虽然原始输入包含 Trace、Metric 和 Log 三类数据，但在进入主干

模型后，并不是形成三条完全独立的编码路径。其中，Trace 和 Metric 在系统异常传播过程中具有天然耦合关系。Trace 提供异常传播路径和服务间依赖结构，Metric 反映链路节点上的性能状态变化，因此本文将二者联合建模为一条 Trace-Metric 分支，以突出结构与数值状态的耦合表征。而日志数据在本质上更适合从事件模板、服务归属和上下文转移关系三个层面建模，因此本文单独构建日志异构图分支，以保留日志模态独有的语义表达能力。经过这样的设计，三源数据在进入统一模型前既保持了模态差异，又具备了后续跨模态交互所需的结构化表示基础。由此，三源输入在模型内部被转化为“双图主干、双分支表示、后置融合判别”的总体架构

需要指出的是，本章侧重说明模型整体设计逻辑、模块衔接关系和数据流向。针对不同模态的特征增强与特征提取方法将在第四章展开论述；针对层次化动态融合方法将在第五章进一步深入分析。

3.3 特征增强与提取技术

在整体流程中，原始数据进入模型后的第一步不是直接构图，而是先进行模态内的特征增强与提取。之所以需要这一环节，是因为原始日志、指标和调用链数据虽然都与异常相关，但其原始观测形式往往具有噪声强、尺度不统一和局部信息稀疏等问题。如果直接以原始观测作为图节点特征，容易导致后续图编码阶段学习到的表示不稳定，进而影响融合和判别效果。因此，本文在构图之前引入样本级特征增强模块，以先行提炼每一模态内部更稳定、更具上下文语义的高层表示。

具体而言，本文分别针对日志、指标和调用链构造对应的模态内增强编码器。对于日志模态，模型从时间有序的日志事件序列中提取上下文语义表示，以增强对异常语义模式和事件上下文依赖的刻画能力；对于指标模态，模型从多变量时间序列中抽取窗口级状态表示，以强化对性能波动趋势和多指标耦合关系的感知能力；对于调用链模态，模型从调用时延与调用结构统计中提炼样本级结构摘要，以提升对异常传播路径和结构变化的描述能力。由此可得三类样本级增强表示：

$$\boldsymbol{z}_i^{log} = E_{log}(L_i),$$

$$\boldsymbol{z}_i^{metric} = E_{metric}(M_i),$$

$$\boldsymbol{z}_i^{trace} = E_{trace}(T_i)$$

这些表示并不直接替代原始数据，而是作为后续图节点特征增强的上下文信息参与建模。换言之，本文的“特征增强与提取”不是将原始数据完全映射为单个样本向量后再分类，而是先提炼样本级上下文，再将其回注到图构建和图编码阶段所需的节点表示中。这样处理有两个优势：一方面，它保留了图结构建模所需要的局部节点信息；另一方面，它又将样本级全局上下文提前引入到局部节点表示学习之中，使节点特征不再是孤立的静态观测，而是具备了更强的上下文感知能力。

从框架衔接角度看，这一阶段与第四章的创新点直接对应。第三章只从总体层面说明：模型先通过模态内增强与提取获得更稳定的高层语义与状态表示，再利用这些表示服务于后续图构建与结构编码；而具体的增强结构、提取过程和模块内部实现细节将在第四章展开论述。

3.4 图构建与图表示学习技术

在完成模态内增强之后，本文进一步将多源数据组织为适合结构建模的图表示。该阶段在总体流程中承担承上启下的作用：一方面，它承接原始数据和增强特征，将离散、异构的监控观测转化为结构化图输入；另一方面，它通过图表示学习将复杂的节点级与边级信息压缩为能够参与跨模态融合的图级表示。因此，本阶段包含“图构建”和“图表示学习”两个紧密耦合的步骤。

首先，对于调用链和指标数据，本文构建 Trace-Metric 联合图。该图以调用链中的服务调用节点为主体，并将与节点时间位置相对应的指标片段附着到节点特征中，从而同时保留调用结构和性能状态。设第 i 个样本对应的 Trace-Metric 图为

$$G_i^{tm} = \left(\mathcal{V}_i^{tm}, \mathcal{E}_i^{tm}, \mathbf{X}_i^{tm}\right),$$

其中，$\mathcal{V}_i^{tm}$ 表示节点集合，$\mathcal{E}_i^{tm}$ 表示基于调用父子关系建立的边集合，$\mathbf{X}_i^{tm}$ 表示节点特征矩阵。通过这种方式，模型能够在一条统一分支上刻画“异常如何沿调用链传播”以及“传播过程中节点状态如何变化”这两个互相关联的问题。

其次，对于日志数据，本文构建日志异构图。与 Trace-Metric 图不同，日志分支更关注模板语义、服务归属和时序转移关系，因此日志图的节点由“日志模板 - 服务”组合

定义，边则由相邻日志事件的时序转移关系诱导得到。设第 i 个样本对应的日志异构图为

$$G_i^{\log} = \left(\mathcal{V}_i^{\log}, \mathcal{E}_i^{\log}, \mathbf{X}_i^{\log}, \Gamma_i, \Phi_i\right),$$

其中，Γ_i 表示节点类型集合，Φ_i 表示边类型集合。该表示使模型不仅能够关注日志内容本身，还能够进一步捕捉同服务与跨服务场景下的事件转移模式。

在图构建完成后，模型分别对两类图进行图表示学习。对于 Trace-Metric 图分支，本文利用图神经网络对节点间依赖关系和边权信息进行编码，并通过图级读出得到样本级表示 $\mathbf{h}_i^{tm}$；对于日志异构图分支，本文通过异构图编码器对不同节点类型与边类型关系进行建模，得到日志图级表示 $\mathbf{h}_i^{\log}$。这一过程可写为

$$\mathbf{h}_i^{tm} = f_{tm}\left(\mathrm{G}_i^{tm}\right)$$

$$\mathbf{h}_i^{\log} = f_{\log}\left(\mathcal{G}_i^{\log}\right).$$

由此，原始三源监控数据经过特征增强、双图构建和图表示学习后，被统一映射为两路具有明确语义分工的高层表示。其中，$\mathbf{h}_i^{tm}$ 主要表征系统结构传播特征与指标状态耦合信息，$\mathbf{h}_i^{\log}$ 主要表征事件语义模式及其上下文转移特征。后续的跨模态融合模块正是在这两路图级表示基础上完成信息交互与互补表达。

需要说明的是，第三章仅从整体框架上说明为何采用双图表示以及双分支编码策略，而关于图节点定义、边关系构造、边权设置和具体建图逻辑等内容，将在第四章，特别是第 4.5 节中进一步详细阐述。

3.5 跨模态融合技术与异常判别

当两路图级表示 $\mathbf{h}_i^{tm}$ 与 $\mathbf{h}_i^{\log}$ 获得之后，模型进入动态融合阶段。该阶段的目标不再是简单地对两路表示进行线性拼接或固定形式的双向交互，而是根据当前样本中不同模态的可靠性、模态间一致性以及潜在冲突程度，自适应选择合适的融合行为。考虑到微服务异常在不同场景下可能优先显现在不同模态中，且模态质量本身也

可能随样本变化而波动，本文引入基于不确定性感知混合专家的层次化动态融合方法，以实现更加灵活、鲁棒的多模态信息整合。

基于此，本文将融合过程表述为

$$\left(\tilde{\mathbf{h}}_i^{tm}, \tilde{\mathbf{h}}_i^{\log}\right) = f_{fus}\left(\mathbf{h}_i^{tm}, \mathbf{h}_i^{\log}\right)$$

其中，$\tilde{\mathbf{h}}_i^{tm}$ 表示经日志信息补充后的 Trace-Metric 表示，$\tilde{\mathbf{h}}_i^{\log}$ 表示经 Trace-Metric 信息补充后的日志表示。这样得到的双向融合表示相较于单向映射或直接拼接，能够更好地保留模态差异性，同时增强跨模态共享异常语义的一致性。

在此基础上，模型通过分类头完成最终判别。设融合后的联合表示为

$$\mathbf{h}_i^{cat} = \left[\tilde{\mathbf{h}}_i^{tm} \| \tilde{\mathbf{h}}_i^{\log}\right]$$

则最终异常概率可表示为

$$\hat{y}_i = \sigma\left(\mathrm{MLP}\left(\mathbf{h}_i^{cat}\right)\right)$$

该设计意味着，异常判别并不是在原始特征层面直接进行，而是在模态内充分提取、图结构充分表达、跨模态充分交互之后进行决策。这样能够使分类结果更多地依赖于稳定、语义清晰的高层表示，而不是直接受原始噪声或局部偶然波动的影响。

从章节安排上看，本章只负责说明融合模块在整体框架中的位置与作用，即它连接双图表示学习与最终分类判别，是整体模型中的关键桥梁；而融合模块内部的具体机制、动态权重分配方式和结构创新点，将在后续对应章节中详细展开。

3.6 多 Loss 联合优化目标

在整体推理流程之外，本文进一步设计多损失联合优化目标，以保证模型不仅能够输出最终的异常分类结果，还能够在训练过程中学习到更加稳定、可分且具有跨模态一致性的表示空间。与将训练过程单纯视为分类问题不同，本文从监督判别、模态内表示约束、模态间表示对齐以及样本增强一致性等多个方面共同构建优化目标，从而提升模型在复杂异常场景下的鲁棒性与泛化能力。

从目标函数角度看，本文的训练过程由监督分类目标与多种协同约束共同组成。其核心思想在于：一方面利用分类损失直接学习正常样本与异常样本之间的判别边界；另一方面利用模态内对比、模态间对比以及样本增强约束，使模型在表示空间中同时保持

“同类更近、异类更远、跨模态一致、增强前后稳定”等性质。整体损失可写为

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda_1 \mathcal{L}_{tra} + \lambda_2 \mathcal{L}_{ter} + \lambda_3 \mathcal{L}_{orig} + \lambda_4 \mathcal{L}_{aug},$$

其中，$\mathcal{L}_{cls}$ 表示分类损失，$\mathcal{L}_{tra}$ 表示模态内对比损失，$\mathcal{L}_{ter}$ 表示模态间对比损失，$\mathcal{L}_{orig}$ 和 $\mathcal{L}_{aug}$ 分别表示围绕原始样本和增强样本构造的样本间协同约束，λ_1 至 λ_4 为相应权重系数。若在特定分支中额外引入潜变量正则化，则还可叠加对应的正则项以进一步约束表示分布。

通过这样的多损失联合优化方式，模型的训练目标不再局限于最终分类结果，而是进一步延伸到整个表示学习过程。这意味着模型在训练时不仅关注最终的异常判别是否准确，还同时约束不同模态是否学习到了具有一致异常语义的表示、增强样本是否能够有效提升模型鲁棒性，以及表示空间是否具备更加清晰的类间边界。由此，多损失联合优化为整体框架提供了更加稳定的训练基础，也为后续融合模块和分类模块的有效学习提供了保障。

3.7 本章小结

本章围绕整体模型框架，对本文方法从系统层面进行了统一说明。首先，本文从微服务异常检测任务出发，明确了多源异构监控数据的输入形式与总体建模目标；随后，按照“原始数据输入 - 特征增强与提取 - 图构建与图表示学习 - 跨模态融合 - 异常判别”的主链路，阐述了模型如何逐步将原始监控观测转化为异常概率输出；在此基础上，进一步说明了多损失联合优化目标并非推理阶段的独立功能模块，而是贯穿表示学习、模态融合与分类判别过程的统一训练机制。

总体而言，第三章建立了一个从任务定义到模型数据流、从主干结构到训练目标的完整方法框架。后续第四章将重点展开特征增强、特征提取与建图逻辑，第五章将进一步讨论融合模块及其具体实现方式。借助本章给出的总体框架，全文后续各方法模块可以在统一的系统视角下展开说明，从而保证论文结构上的连贯性与论述上的完整性。

第四章　基于多源异构时序数据特性的特征增强与提取技术

在第三章给出的总体框架中，特征增强与特征提取是连接原始监控数据和后续图表示学习、动态融合模块的关键环节。由于日志、调用链追踪和指标数据在数据形态、语义粒度、时间分布和结构关系上存在显著差异，若采用统一的编码方式进行处理，容易削弱各模态自身包含的异常判别信息。因此，本章围绕多源异构时序数据的模态特性，分别设计面向日志数据、调用链数据和指标数据的特征增强与提取方法，并进一步构建 Trace-Metric 联合图和日志异构图，为后续跨模态融合与异常检测提供更加充分、稳定和结构化的中间表示。

4.1　研究动机

在微服务系统运行过程中，指标（Metric）、日志（Log）和调用链追踪（Trace）是最具代表性的三类监控数据来源。三者从不同角度刻画系统状态：指标数据以连续数值序列的形式反映系统运行的性能波动，日志数据以半结构化文本的形式记录系统运行事件与语义上下文，而调用链追踪数据则以跨服务请求路径的形式揭示系统内部的调用依赖结构。

正是由于这三类数据在语义内容、统计分布、时间粒度以及结构组织方式上存在显著差异，因此多源异构监控数据异常检测的首要难点并不是简单地“把三类数据拼接到一起”，而是在进入融合与分类之前，首先获得质量足够高、表达能力足够强且能够代表各自模态本质特征的表征结果。

现有异常检测方法在这一问题上通常存在两类不足。第一类不足是对不同模态采用统一的编码方式，例如将日志、调用链和指标数据都简单转化为定长向量后输入同一模型。这种做法在工程上较为方便，但往往会抹平不同模态的结构差异，导致模型无法充分学习日志中的事件语义关系、调用链中的拓扑依赖以及指标序列中的多尺度动态变化规律。第二类不足是虽然分别处理不同模态，但对原始输入缺乏针对性的增强过程，导致后续编码器接收到的信息仍然较为稀疏、噪声较多，最终限制了异常表征的上界。

基于上述分析，本文认为，多源异构时序数据异常检测中的第一项核心工作应当围绕“特征增强与特征提取”展开。**所谓特征增强**，是指在保持原始监控语义不被破坏的

前提下，通过结构化重构、统计量扩展和关系补充等方式，使不同模态在进入深度模型之前具备更高的信息密度与更强的判别潜力；**所谓特征提取**，是指针对各模态的结构特征设计相适配的编码网络，使模型能够在更高层次上学习不同模态内部的关键模式与异常线索。基于这一思路，本文分别面向日志数据、调用链追踪数据和指标数据设计了差异化的增强与提取技术，构建了多源异构时序数据异常检测的高质量输入基础。

从整体框架上看，本章的目标并不是直接完成异常分类，而是回答如下问题：第一，如何从原始、多样且结构差异显著的监控数据中保留最有价值的异常信息；第二，如何针对不同模态的本质特点构建合适的中间表示；第三，如何为后续动态融合与异常判别提供更加稳定、更加语义化的输入特征。围绕这些问题，本文将日志、调用链追踪和指标三类数据分别建模，并在特征增强与特征提取两个层面展开研究。

4.2 面向日志数据的特征增强与提取技术

4.2.1 日志数据的特点分析

日志数据是系统行为语义最丰富的数据来源之一。与指标数据相比，日志数据不仅包含系统运行状态的事件描述，还包含大量由开发者或运行环境生成的上下文文本信息，因此在系统异常检测、故障定位以及根因分析中具有重要作用。然而，日志数据虽然语义信息丰富，却并不适合直接作为深度模型输入，其主要原因体现在以下三个方面。

首先，日志原文通常具有明显的半结构化特征。不同服务、不同组件甚至不同版本的系统在输出日志时往往遵循相似的模板形式，但其中又夹杂着时间戳、实例编号、请求标识、参数值等大量变量字段。这使得原始日志在词面层面呈现出高度稀疏和表面多样的特性，而真正决定日志语义的往往只是少数稳定模板与事件模式。若直接使用原始日志序列进行建模，模型容易将变量噪声误认为异常特征，从而降低对真实异常模式的识别能力。

其次，日志异常往往不表现为某一条日志消息本身的异常，而更可能表现为一组日志事件在时序上的异常组合。例如，在正常场景下，某一请求可能经历“接收请求—调用下游服务—返回成功”这一标准流程，而在异常场景下，日志中可能出现“接收请求—多次重试—连接失败—超时回滚”等事件序列。换言之，日志异常具有明显的上下文依赖与事件关系特征，这意味着仅仅统计单个模板的出现次数并不足以充分刻画异常。

最后，日志数据在不同时间窗口内还存在显著的频次突变特征。当系统发生服务崩溃、延迟抖动或资源竞争时，某些错误模板、警告模板和异常事件往往会在短时间内集中爆发，这些变化本身就是重要的异常信号。因此，日志模态的建模不仅要关注语义内容，还需要充分保留模板频次、模板比例关系以及窗口级分布变化。

4.2.2 日志数据的特征增强方法

针对上述问题，本文首先对日志数据进行结构化增强处理。具体而言，日志增强过程主要包括模板提取、频次统计、比例关系构建以及日志级别统计。

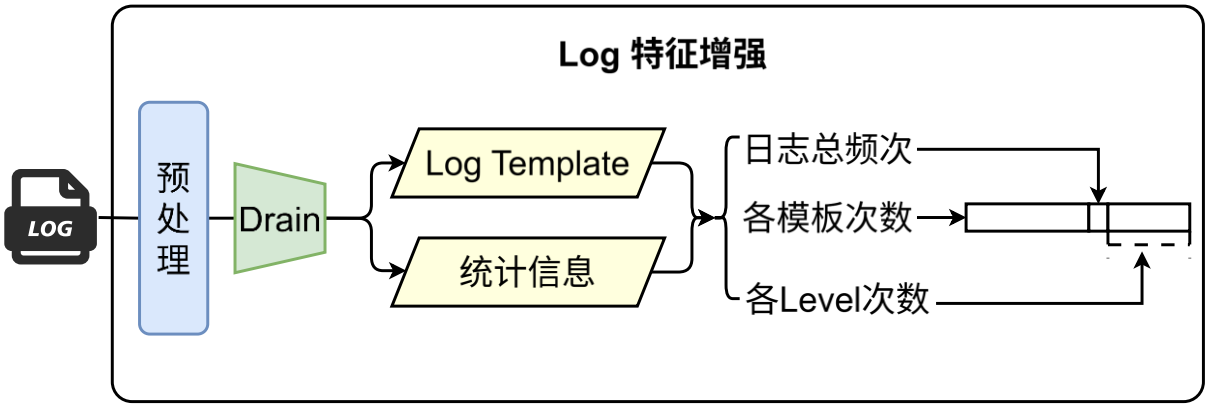

图 4-1 日志数据特征增强技术

在模板提取阶段，本文借助日志解析器 Drain[48]将原始日志消息映射为相对稳定的日志模板。与直接使用原始字符串不同，日志模板能够保留事件主体语义，同时显著削弱变量字段带来的稀疏性与噪声。通过这一处理，原本在文本层面高度离散的日志事件被映射到更为紧凑的模板空间，使得后续模型可以重点关注系统行为模式，而不是偶发性的参数变化。

在频次统计阶段，本文以固定时间窗口为单位，统计每种日志模板在窗口内的出现次数。频次统计的作用在于显式刻画某类事件是否发生了异常增长。例如，当某一服务的错误模板在短时间内大量出现时，尽管单条日志本身可能不具备足够强的异常区分能力，但聚合后的频次分布却能清晰地反映系统运行状态的异常变化。因此，模板频次可以视作日志模态中最基础、最稳定的一类统计增强特征。

在比例关系构建阶段，本文进一步计算不同模板之间的相对占比以及日志级别的分布比例。与绝对频次相比，比例特征更能反映系统内部行为结构的变化。例如，在总日志量大幅增长时，仅观察错误模板的绝对数量可能会造成误判，而若观察错误模板在全部模板中的占比，则能够更准确地区分“业务活跃导致日志总量增加”和“异常事件主

导日志分布变化”这两种不同情况。

在日志级别统计阶段，本文对 INFO、WARN、ERROR 等不同级别日志的分布情况进行窗口化统计。其原因在于，日志级别本身承载着系统设计者对事件重要性的先验判断。异常发生时，错误级别日志与告警级别日志通常会显著上升，因此日志级别分布可以为后续异常检测提供一类具有较高可解释性的辅助特征。

通过上述增强过程，原始日志模态不再是简单的文本序列，而被重构为一个融合了模板语义、窗口统计和分布关系的高维结构化特征集合。这一过程有效提升了日志数据的表达能力，为后续的异构图构建与深度编码奠定了基础。

4.2.3 日志数据的特征提取方法

在日志异常检测任务中，日志模板统计向量作为输入特征，虽然携带着系统运行行为的重要语义信息，但其结构本身存在以下挑战：

高维稀疏性[49]：日志模板种类通常在一个很大的量级，但在一个时间窗口内，仅会激活少量模板，导致日志模板统计向量极度稀疏。

隐式时序性：日志事件之间通常存在弱顺序依赖，但日志模板本身缺乏显式的时间戳或顺序标识。

上下文依赖性：系统异常往往表现为特定事件组合的协同模式，而非单一事件的孤立异常。

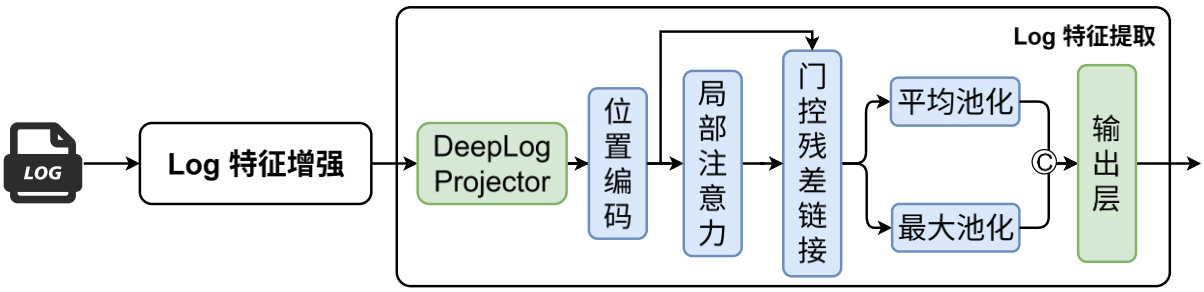

图 4-2 日志（Log）数据的特征提取

因此，基于以上特性，对于日志数据的特征提取技术需要提取事件分布中的语义信息；建模事件间的隐式上下文关系；将高维稀疏输入压缩为低维稠密表示；增强模型对异常事件模式的识别能力。对此，如图 4-2，本小节设计的特征提取技术，整体架构共分为四个阶段，分别是：

- 利用**投影网络**有效缓解高维稀疏问题；

- 通过**可学习位置编码[46]**与**局部注意力[50]**建模事件间上下文关系；
- 借助**门控残差连接[51]**来自适应融合原始与上下文特征；
- 使用**双池化策略[52]**强化异常模式捕捉能力。

（1）深度特征投影（Deep Log Projector）。用于将高维稀疏的事件计数向量映射为低维嵌入表示，通过三级的逐层非线性变换完成语义压缩与特征抽取。首层将输入维度扩展为 $2 \times \text{embed_dim}$，缓解稀疏性影响，增强线性可分性；中间层维持扩展维度，保持特征表达空间；最后一层压缩回embed_dim，以匹配后续需求。

（2）位置编码与多头局部注意力机制。日志模板时间序列缺乏明确时间戳，但其发生顺序蕴含系统行为的重要信息。该阶段通过引入**可学习的位置编码**和**局部注意力机制**，建模事件之间的上下文依赖。

- **可学习位置编码**

通过引入位置参数 $P \in R^{1\times L\times D}$ 与特征相加：

$$X_{\text{pos}} = X + P$$

该机制替代传统正弦编码，更好地适应日志事件的非等间隔、非均匀特性，同时捕捉隐式时序模式，发现事件发生顺序影响系统状态演化的规律。

- **局部注意力机制**（Sparse Sliding Attention）

在注意力权重的计算中，引入滑动窗口约束，限制每个位置仅与相邻 w 个事件进行交互。该机制在保持上下文建模能力的同时，将注意力复杂度由 $O(n^2)$ 降低为 $O(n \cdot w)$，更适用于长序列场景，且符合“异常往往由邻近事件组合触发”的实际模式。

（3）门控残差特征融合。引入门控残差结构。门控信号可以自适应地学习保留历史模式或更新为上下文特征的比例，并且残差结构避免梯度消失问题，尤其适用于深层网络，同时保留原始计数特征的统计信息。该结构可以融合注意力输出与原始特征并自适应地控制信息流。

$$\text{Output} = \sigma\left(W_g \cdot X\right) \odot \text{Attn} + \left(1 - \sigma\left(W_g \cdot X\right)\right) \odot X$$

其中 $\sigma(\cdot)$ 为 Sigmoid 函数，W_g 为可训练的线性映射，$\odot$ 表示逐元素乘法。

（4）双池化聚合与输出。最后，为综合考虑局部异常和全局状态，使用**双池化策略**（最大池化 + 平均池化）对时序输出进行压缩：

$$Y_{\text{pool}} = [\max(X)\,;\ \text{mean}(X)]$$

随后，通过一层线性变换完成最终嵌入输出：

$$E = \text{LeakyReLU}\left(\text{LayerNorm}\left(\text{W}_{\text{proj}} \cdot \text{Y}_{\text{pool}}\right)\right)$$

4.3 面向调用链数据的特征增强与提取技术

4.3.1 调用链数据的特点分析

调用链数据记录了一个请求在微服务系统中的跨服务传播路径以及每个服务节点的执行状态信息。与日志数据相比，Trace 数据具有更清晰的结构依赖关系；与指标数据相比，Trace 数据更直接地体现了服务之间的交互模式与传播路径。因此，Trace 数据在异常检测任务中的价值主要体现在两个方面：其一，它能够揭示异常在服务调用链上的传播过程；其二，它能够帮助模型识别某些结构性异常，例如请求链路过长、局部服务节点阻塞、某一调用边的延迟异常增大等。

然而，原始 Trace 数据同样不适合直接作为输入。首先，Trace 通常由大量跨度对象组成，包含调用方、被调用方、起止时间、状态码、时延等字段，属于高维、稀疏且

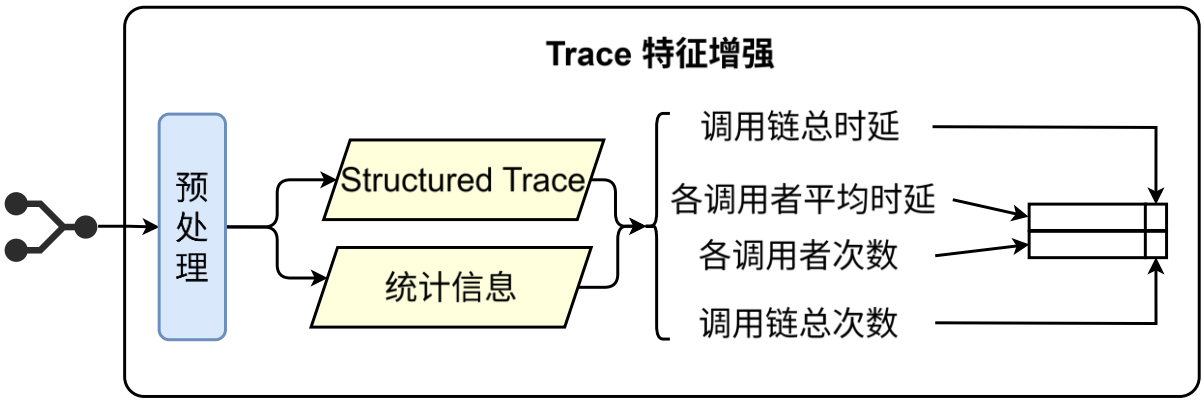

层次化的结构数据。若直接将其拉平为普通序列，不仅会破坏调用拓扑信息，也会使模型难以准确理解服务之间的上下游关系。其次，Trace 的异常并不总是体现在单个字段的绝对值上，而更可能体现在调用频次、调用方向、时延分布和链路结构的联动变化上。因此，需要在保留其结构信息的基础上进行有针对性的增强与编码。

4.3.2 调用链数据的特征增强方式

针对 Trace 数据，本文设计了面向结构与性能信息的增强策略，主要包括调用频次统计、调用时延统计以及全局调用负载描述三个层面。

图 4-3 调用链数据特征增强技术

首先，本文统计各服务节点在当前窗口内作为调用方出现的频率。调用频次能够反映某一服务是否在当前时间段内承担了异常负载，特别是在微服务架构中，热点服务、瓶颈服务和异常重试服务通常会表现为调用次数显著增加。因此，调用频次是一类能够直接反映服务交互强度变化的重要增强特征。

其次，本文对调用时延进行统计，包括平均时延、最大时延等指标。与调用次数相比，时延信息更加直接地反映服务执行性能。异常场景下，一个服务虽然调用次数不一定很多，但其平均时延或长尾时延可能显著上升，从而成为整条调用链的性能瓶颈。因此，通过引入多粒度时延统计特征，可以增强模型对性能退化异常的感知能力。

最后，本文进一步构造调用总次数与总时延等全局性特征，以描述窗口级别的整体负载情况。这类增强特征的意义在于，它们能够帮助模型从全局尺度判断当前系统是否处于超负荷状态，从而为局部链路异常判断提供背景信息。

4.3.3 调用链数据的特征提取方式

调用链（Trace）数据经过特征增强技术处理之后会提取出两个异构输入向量，分别是调用者的时延数据和调用次数两种类型。本小节设计了专用于调用链追踪输入向量的深度**特征提取技术**，旨在从中提取出具有高质量的特征向量。其核心架构为**双分支神经网络**，每个分支独立处理一种类型的数据**错误!未找到引用源。**，随后通过**门控机制**进行融合。如图 4-4，该特征提取技术通过如下技术路径应对调用链追踪数据的建模挑战：

- **残差扩张[53]卷积**：实现局部与远程依赖的多尺度感知；
- **双向 GRU[54][55]**：建模调用顺序与响应顺序的双向时序上下文建模；
- **门控融合机制**：对两分支实现自适应重要性加权融合。

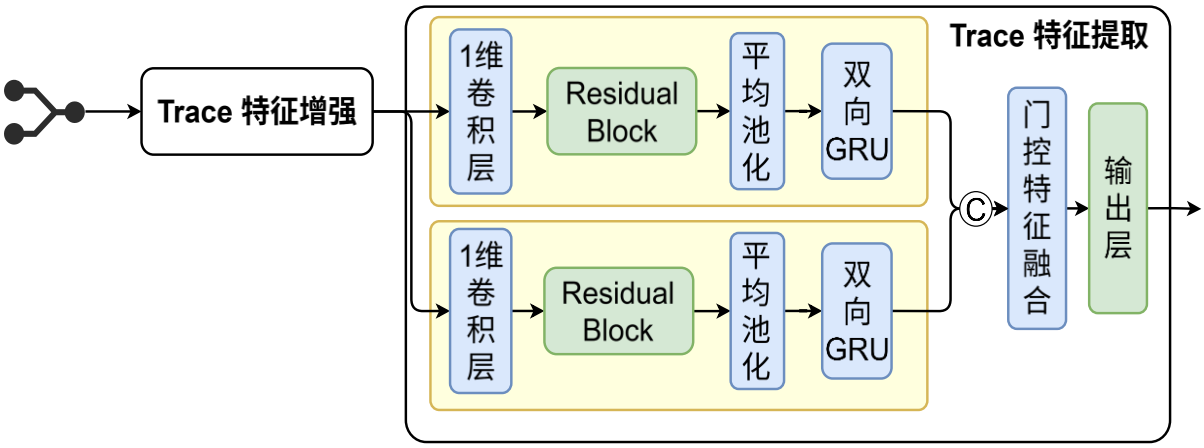

图 4-4 调用链追踪（Trace）数据的特征提取

（1）残差扩张卷积。每个分支均通过一组卷积与残差结构进行特征提取。核心模块为带扩张率的残差块，其结构如下：

$$\mathrm{ResBlock}(x) = \mathrm{LeakyReLU}(F(x) + W_s x)$$

其中 $F(x)$ 表示卷积变换，W_s 为 1×1 卷积捷径映射。这种设计能在保持原始输入长度的前提下扩大感受野，有助于建模调用链中较远服务节点之间的依赖关系。

（2）双向 GRU。对每一分支的卷积输出进行维度置换后输入至双向 GRU 网络：

$$h_t^{\rightarrow} = \mathrm{GRU}\ (x_t, h_{t-1}^{\rightarrow})$$
$$h_t^{\leftarrow} = \mathrm{GRU}\ (x_t, h_{t+1}^{\leftarrow})$$

最终从两个方向提取状态：前向最后一个状态：$h_{\mathrm{fw}} = h_T^{\rightarrow}$，反向第一个状态：$h_{\mathrm{bw}} = h_1^{\leftarrow}$。并拼接为该分支的特征：

$$e_{\mathrm{latency}} = [h_T^{\rightarrow}; h_1^{\leftarrow}] \in \mathbb{R}^{2H}$$
$$e_{\mathrm{count}} = [h_T^{\rightarrow}; h_1^{\leftarrow}] \in \mathbb{R}^{2H}$$

（3）门控融合机制。融合层首先拼接两个分支的输出：

$$e_{\mathrm{concat}} = \left[e_{\mathrm{latency}}; e_{\mathrm{count}}\right] \in R^{4H}$$

然后通过一个门控网络生成融合权重：

$$\boldsymbol{g} = \mathrm{Softmax}\left(W_2 \cdot \mathrm{LeakyReLU}(W_1 \cdot e_{\mathrm{concat}})\right) \in R^{2}$$

融合后的表征为：

$$e_{\mathrm{fused}} = g_0 \cdot e_{\mathrm{latency}} + g_1 \cdot e_{\mathrm{count}}$$

其中 g_0, g_1 为门控向量中两个元素。

（4）输出层。融合后的特征通过两层全连接映射为最终固定维度嵌入：

$$E = W_4 \cdot \mathrm{Dropout}\left(\mathrm{BN}\left(\mathrm{LeakyReLU}(W_3 \cdot e_{\mathrm{fused}})\right)\right)$$

该设计同时使用 BatchNorm **错误!未找到引用源。**、Dropout 和非线性激活函数，有效避免过拟合与梯度饱和问题

4.4 面向指标数据的特征增强与提取技术

与日志和 Trace 不同，指标数据本身已经是相对规整的数值型时序信号，因此本文没有对指标数据进行与日志、Trace 同等复杂的前置增强，而是重点围绕其动态模式提取能力展开建模。之所以采取这一设计，是因为指标数据的主要挑战不在于结构混乱，

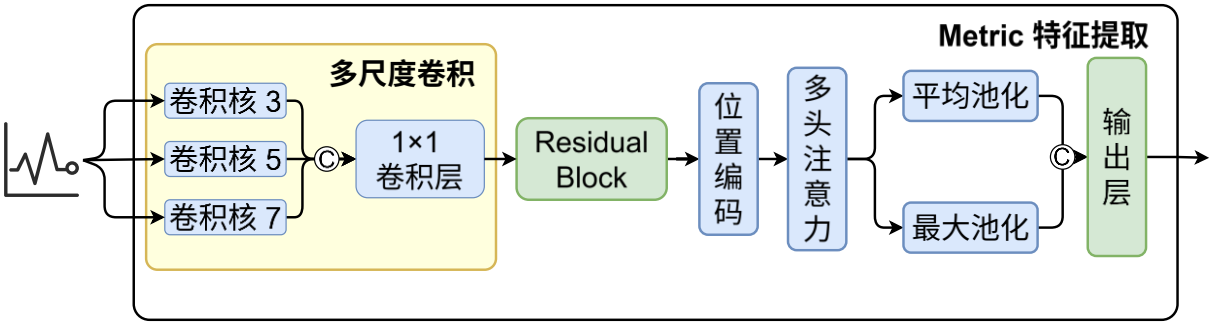

而在于如何从多变量时间序列中同时提取短期波动、中期趋势和长期依赖。

针对这一问题，本文设计了面向指标模态的多尺度特征提取机制，以充分挖掘指标（Metric）类时序数据中的复杂模式与多尺度依赖关系。该技术以原始的连续数值型指标时序数据为输入，结合**多尺度卷积提取[58]**、**残差结构增强**、**位置感知注意力机制**与**双池化聚合**策略，实现从局部模式到全局依赖的逐层特征提取过程，为后续的异常检测任务提供强判别性、高表达力的嵌入表示。

图 4-5 指标（Metric）数据的特征提取

4.4.1 多尺度卷积

为捕捉指标数据在不同时间尺度上的局部模式，模型设计了三个并行的一维卷积分支，分别使用不同大小的卷积核（kernel size）进行特征提取。该结构可表示为：

- $\mathcal{F}_{short} = \mathrm{Conv}_3(X)$：捕捉**短期**特征；
- $\mathcal{F}_{mid} = \mathrm{Conv}_5(X)$：提取**中期**特征；
- $\mathcal{F}_{long} = \mathrm{Conv}_7(X)$：提取**长期**变化模式。

三个分支输出拼接形成多尺度特征张量：

$$Y_{\text{multi}} = [\mathcal{F}_{short}; \mathcal{F}_{mid}; \mathcal{F}_{long}] \in \mathbb{R}^{B\times 3C\times L}$$

之后，为实现多尺度特征间的信息交互，同时压缩冗余通道维度，引入 1×1 卷积层进行跨通道融合，为后续残差块与注意力模块提供统一输入。

$$Y_{\text{fused}} = W_{\text{fusion}} \cdot Y_{\text{multi}}$$

其中$W_{\text{fusion}} \in \mathbb{R}^{2C\times 3C}$。

4.4.2 残差块 Residual Block

为了增强模型的非线性表达能力并缓解深层网络训练中的梯度消失问题，加入了标

准的残差块结构：

$$\mathrm{ResBlock}(X) = \sigma(\mathcal{W}_2(\sigma(\mathcal{W}_1(X))) + \mathcal{W}_{shortcut}(X))$$

（1）主路径 $\sigma(\mathcal{W}_2(\sigma(\mathcal{W}_1(X)))$ 包含两个一维卷积层：

$$\mathcal{W}_1 = \mathrm{Conv1d}(k = 3, \mathrm{dilation} = 1)$$

$$\mathcal{W}_2 = \mathrm{Conv1d}(k = 3, \mathrm{dilation} = 1)$$

（2）捷径连接根据输入输出通道是否一致，采用 Identity 或 1×1 卷积

$$\mathcal{W}_{shortcut} = \begin{cases} \mathrm{Identity} & \text{if } C_{in} = C_{out} \\ \mathrm{Conv1d}(1 \times 1) & \text{otherwise} \end{cases}$$

4.4.3 位置编码与多头注意力机制

为引入时序的全局依赖建模能力，在融合特征中加入位置编码，并引入多头自注意力机制：

- **位置编码注入：**

$$X_{\mathrm{pos}} = X_{\mathrm{in}} + P \text{where } P \in \mathbb{R}^{1 \times L \times D}$$

- **多头自注意力机制：**

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right)V$$

其中，$Q = K = V = X_{\mathrm{pos}}$ （自注意力）

4.4.4 双池化聚合与输出

双池化指的“**最大池化 + 平均池化**”。最大池化能够捕捉**局部峰值**特征，识别突发性异常事件；平均池化能够保留**全局分布**趋势，捕捉持续性系统异常。因此，双池化拼接后可兼顾整体分布与关键事件，融合局部显著性与全局上下文信息，最终通过线性投影进一步压缩并生成表征向量。

$$Y_{\mathrm{pool}} = [max(Y_{\mathrm{attn}}); mean(Y_{\mathrm{attn}})]$$

在此基础上，通过双层前馈网络输出最终的嵌入向量：

$$E_{metric} = W_2\left(\sigma\left(\mathrm{LayerNorm}\left(W_1(Y_{\mathrm{pool}})\right)\right)\right)$$

4.5 图构建与图表示学习

4.5.1 建图目标与整体思路

在完成日志、Trace 和指标三类数据的特征增强与特征提取之后，模型还需要进一步解决一个关键问题，即如何将这些已经具备较强异常判别能力的模态特征组织为适合图神经网络处理的结构化输入。与单纯的向量拼接不同，建图的核心目的在于显式保留微服务系统中原本就存在的结构依赖、时序依赖和跨服务关联关系，使后续编码器能够在“节点特征”和“关系结构”两个层面同时学习异常模式。

从总体上看，本文采用双图建模策略。对于调用链与指标模态，考虑到二者在微服务异常传播中具有天然耦合关系，本文构建 Trace-Metric 联合图，用于同时表达服务调用拓扑和节点性能状态；对于日志模态，考虑到其更适合从事件模板、服务归属和时序转移三个层面进行建模，本文构建日志异构图，用于表达日志事件之间的上下文关系和跨服务传播关系。由此，对于任一样本 S_i，建图后的输入可表示为

$$S_i = (G_i^{tm}, G_i^{log}, y_i)$$

其中，G_i^{tm} 表示第 i 个样本对应的 Trace-Metric 图，$G_i^{\log}$ 表示对应的日志异构图，y_i 为样本标签。设计使多源异构监控数据在进入深度模型之前，由原始数据流进一步转换为具有显式结构语义的图表示，为后续 GAT 和 HGTN 编码提供统一输入。

4.5.2 时间窗约束下的多模态对齐

建图的前提是完成多模态数据对齐。由于指标数据是规则采样序列，而日志和调用链数据属于事件驱动序列，三者在时间粒度上并不一致，因此本文首先采用时间窗约束下的对齐策略，将不同模态组织到统一的样本语义空间中。设第 i 个时间窗为

$$W_i = [t_i^s, t_i^e]$$

则首先在窗口内收集所有调用边、日志事件和指标观测，并以窗口中的服务调用关系为骨架重构样本级 Trace 结构。对于标签定义，若当前窗口与任一异常区间发生重叠，则该窗口被标记为异常样本。这样处理后，每个样本都对应一个明确的时间语义范围，保证后续图中的节点和边均来源于同一监控上下文。

在具体实现上，本文对三类模态采用如下对齐原则。第一，调用链模态以窗口内出

现的服务调用边为基础，构造样本级 Span 集合；第二，日志模态收集满足 $t_i^s \le t < t_i^e$ 的所有日志事件，并按时间顺序排序；第三，指标模态则以窗口中心时刻作为参考，为每个服务选择最能代表当前窗口状态的指标切片。设窗口中心时刻为

$$t_i^c = (t_i^s + t_i^e)/2$$

则对于服务 s 的指标序列，本文选择与 t_i^c 时间距离最近的观测点作为该窗口的代表性指标向量。该策略能够避免直接对不同长度指标子序列进行不稳定对齐，同时保留窗口级别最关键的性能状态信息。

4.5.3 Trace-Metric 联合图构建逻辑

在 Trace-Metric 分支中，本文以窗口内服务调用关系构造图结构，以服务级 Span 作为图节点，再将与该节点对应的指标向量附着到节点特征上，从而形成联合图表示。该图可记为

$$G_i^t m = (V_i^t m, E_i^t m, X_i^t m)$$

其中，V_i^{tm} 表示节点集合，E_i^{tm} 表示边集合，X_i^{tm} 表示节点特征矩阵。

对窗口内任一服务节点 v，本文首先根据其对应 Span 的起止时间计算三类时延特征，即执行时间、等待时间和本地执行时间：

$$E_v = t_v^{\mathrm{end}} - t_v^{start}$$

$$W_v = \Sigma_{u \in C(v)}(t_u^{end} - t_u^{start})$$

$$L_v = E_v - W_v$$

其中，$C(v)$ 表示节点 v 的子节点集合。上述三类特征分别刻画了当前服务的总执行跨度、子调用占用时间以及本地实际执行开销。由于不同窗口中的绝对时延范围可能差异较大，本文进一步对这些时间特征进行归一化处理，以减小量纲差异对训练稳定性的影响。

随后，将与节点服务对齐得到的指标向量记为 $\hat{m}_v$，并与归一化后的时间特征进行拼接，形成节点最终特征：

$$x_v^{tm} = [\hat{\mathrm{E}}_v, \hat{\mathrm{W}}_v, \acute{\mathrm{L}}_v, \hat{m}_v]$$

该设计使 Trace-Metric 图中的每个节点既能表达调用结构中的时延信息，又能反映

当前服务在该窗口下的性能状态，从而形成“结构 + 性能”联合表征。

在边构造方面，本文保留 Trace 中原有的父子调用关系。若节点 u 是节点 v 的父调用节点，则在图中构造有向边 $u \rightarrow v$。为了进一步表达调用发生的先后顺序，本文使用子节点相对开始时间作为边权。设根节点开始时刻为 t_{root}^{start}，则节点 v 的相对开始时间定义为

$$R_v = (t_v^{start} - t_{\mathrm{root}}^{start})/(max_{k \in V_i^{tm}} t_{\mathrm{k}}^{start} - t_{\mathrm{root}}^{start})$$

于是，对于父子边 $\boldsymbol{u} \rightarrow \boldsymbol{v}$，其边权取为

$$w_{uv} = R_v$$

该设计的直观含义在于：越晚发生的服务调用，其边权越能体现当前调用在整条 Trace 中所处的传播阶段。对于没有有效父节点或在当前窗口内表现为孤立节点的服务，本文进一步添加自环边，以保证图结构在输入图神经网络时不会出现完全孤立的节点表示。

4.5.4 日志异构图构建逻辑

日志模态与 Trace-Metric 模态在结构特征上存在明显差异。日志事件本身是按时间生成的半结构化事件流，其核心异常信息并不只体现在单条日志内容上，还体现在模板转移模式、跨服务传播关系以及异常事件频次变化上。因此，本文将日志数据构建为异构图而非普通序列。该图可表示为

$$G_i^{log} = (V_i^{log}, E_i^{log}, X_i^{log}, \Gamma_i, \Phi_i)$$

其中，$V_i^{\log}$ 为节点集合，$E_i^{\log}$ 为边集合，$X_i^{\log}$ 为节点特征矩阵，Γ_i 为节点类型集合，Φ_i 为边类型集合。

在节点定义上，本文不直接将单条日志事件视为独立节点，而是以“日志模板 + 服务标识”作为节点唯一键。对于日志事件 e，若其模板标识记为 $tpl(e)$，所属服务记为 $svc(e)$，则对应日志图节点定义为

$$u = (tpl(e), svc(e))$$

这种设计能够同时保留日志语义信息和服务上下文信息，避免将同一日志模板在不同服务中的行为差异混为一谈。

在节点特征构造上，本文将映射到同一节点的日志事件语义向量进行聚合。设映射

到节点 u 的事件集合为 E(u)，每条事件的语义向量为 z_e，则节点特征可写为

$$x_u^{\log} = (\frac{1}{|E(u)|})\Sigma_{e\in E(u)} z_e$$

在工程实现中，为增强模板语义稳定性，若存在预先训练好的模板级全局嵌入，则可进一步将其与窗口内聚合得到的局部语义向量进行拼接，得到更加稳定的日志节点表示。

在边构造上，本文首先将窗口内日志事件按时间排序。对任意相邻日志事件对 (e_t, e_{t+1})，若其对应节点分别为 u 和 v，则在图中构造有向边 u → v。若同一节点对在当前窗口内多次连续出现，则对其出现频次进行累加，并将累加结果作为边权。记该边权为

$$c_{uv} = \Sigma_t I((e_t, e_{t+1}) \mapsto (u, v))$$

进一步地，考虑到日志事件可能发生在同一服务内部，也可能反映跨服务传播，本文根据边两端节点的服务归属定义边类型：

$$\varphi_{uv} = \begin{cases} 0 & svc(u) = svc(v) \\ 1 & \mathrm{svc(u)} \neq \mathrm{svc(v)} \end{cases}$$

其中，$\varphi_{uv} = 0$ 表示同服务边，$\varphi_{uv} = 1$ 表示跨服务边。通过这一设计，日志异构图不仅能够表达“哪些事件相邻发生”，还能够表达“这些事件是在服务内部连续发生，还是沿着服务边界传播”的差异，这为后续 HGTN 在节点类型和边类型层面的建模提供了依据。

4.5.5 双图输出与后续编码衔接

经过上述步骤，本文最终为每个样本同时得到一个 Trace-Metric 联合图和一个日志异构图。前者重点保留服务调用结构与性能状态之间的耦合关系，后者重点保留日志语义关系与跨服务转移模式。两者分别从不同侧面表达微服务系统异常，并共同构成后续双分支图编码器的输入。

从整体数据流上看，4.5 节的建图逻辑起到了承上启下的作用。一方面，它将前面各模态经过增强与提取后的信息进一步组织为可供图神经网络利用的结构化表示；另一方面，它又为第五章中的动态融合提供了统一的中间表示基础。可以说，建图环节不仅是一个数据组织过程，更是将“模态特征”转化为“关系表达”的关键桥梁。

4.6 本章小结

本章围绕多源异构时序数据的特征增强与提取问题，分别从日志、调用链追踪和指标三类监控数据出发，设计了具有针对性的模态内建模方法。对于日志数据，本文通过模板提取、频次统计、比例关系和日志级别分布等方式增强日志事件的语义与统计表达，并结合日志异构图保留日志模板、服务实例和时间窗口之间的关联关系。对于调用链追踪数据，本文重点关注服务调用路径、响应状态和调用依赖结构，通过结构化增强与图建模方式刻画异常传播过程。对于指标数据，本文利用多尺度卷积、残差结构、位置编码、多头注意力和双池化聚合等模块，提取系统状态变化中的局部波动特征与长程时序依赖。

总体而言，本章的核心作用在于将原始、分散且结构差异明显的多源监控数据转化为更具判别能力和结构表达能力的中间表示。通过差异化的特征增强、模态适配的特征提取以及双图结构构建，模型能够在进入融合阶段之前充分保留日志语义、调用链拓扑和指标时序三类关键信息。上述设计不仅为异常检测提供了更加高质量的输入基础，也为第五章的不确定性感知动态融合方法提供了可靠的模态表示支撑。

第五章　基于不确定性感知混合专家的层次化动态融合方法

第四章已经围绕日志、调用链追踪和指标三类数据完成了特征增强、特征提取与图结构建模，使不同模态的异常线索能够以更高质量的表示形式进入后续模型。然而，在多源异构异常检测任务中，仅获得各模态表示并不足以保证最终检测效果，如何根据样本状态、模态质量和跨模态一致性动态整合不同信息，仍然是影响模型性能的关键问题。尤其在微服务系统中，不同异常类型可能首先体现在不同模态中，且各模态之间可能存在噪声、缺失或冲突。因此，本章提出一种基于不确定性感知混合专家的层次化动态融合方法，通过不确定性估计、动态路由、混合专家交互和门控更新机制，实现更加自适应、可靠和鲁棒的多模态融合。

5.1　研究动机

在获得高质量模态内表示并完成双分支图表示学习之后，多源异构时序数据异常检测还面临第三个关键问题，即如何实现真正有效地融合。实践表明，融合问题并不是一个简单的“把两个向量拼接起来”的工程步骤，而是关系到模型能否充分利用不同模态互补信息的核心环节。尤其在微服务异常检测场景下，不同模态的贡献程度具有明显的动态性和上下文依赖性：在某些异常场景中，调用链结构变化可能最先出现，因此 Trace-Metric 模态更重要；而在另一些场景中，错误日志或告警模板更具区分度，此时日志模态的作用更强。若融合方法缺乏动态调整能力，则很容易造成某一模态信息被过度强调或被噪声掩盖。

进一步地，多源异构监控数据还存在模态质量不稳定的问题。日志模态可能因窗口内日志过少、模板分布过于单一而信息不足，Trace-Metric 模态也可能因链路缺失、指标波动不明显而表现出较高不确定性。在这种情况下，若所有样本都采用同一种固定融合方式，则容易使高噪声模态干扰最终表示学习过程，降低模型对复杂异常的敏感性与鲁棒性。此外，异常检测任务中还普遍存在模态冲突现象，即某一模态已经出现明显异常信号，而另一模态尚未同步变化。此时，模态之间的不一致本身就是重要的判别信息，而不应在融合过程中被简单平滑掉。

基于以上分析，本文提出一种**基于不确定性感知混合专家的层次化动态融合方法**。

该方法的核心思想是：首先估计当前样本中不同模态的可靠性与跨模态冲突程度；随后基于不确定性信息动态路由不同融合专家；最后由多个具有不同归纳偏置的专家共同完成跨模态信息整合。通过这种设计，模型能够依据样本状态自适应选择融合行为，从而提升多模态异常表征的表达能力、鲁棒性与可解释性。

5.2 整体设计

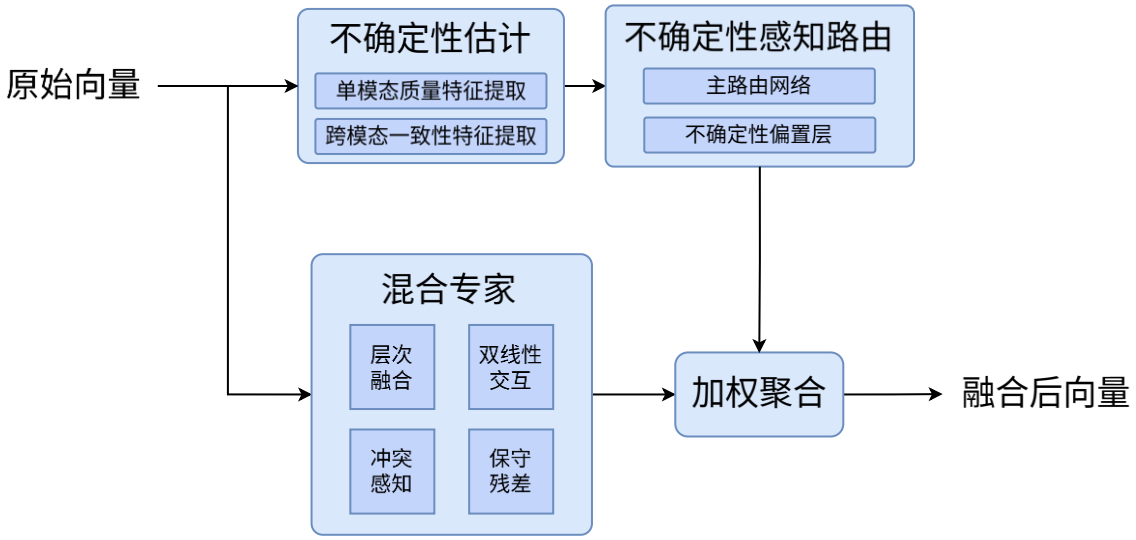

图 5-1 不确定性感知混合专家的层次化动态融合方法

设经过前述编码过程后，Trace-Metric 模态表示为 $h_{tm} \in R^{d_{tm}}$，日志模态表示为 $h_{log} \in R^{d_{log}}$。首先将两路模态映射到统一隐空间，得到共享表示：

$$x_{tm} = W_{tm} h_{tm} + b_{tm}$$

$$x_{log} = W_{log} h_{log} + b_{log}$$

随后，基于上述共享表示，本文方法的总体流程可表述为：首先根据模态质量特征与跨模态一致性特征估计不确定性；其次利用不确定性信号与跨模态交互特征构造路由向量，生成不同专家的权重分布；再次由四类专家并行输出不同风格的融合增量；最后对专家结果进行加权聚合，并结合输出门控得到最终的双向融合表示。

5.3 不确定性估计

不确定性估计模块位于整个动态融合流程的前端，其作用并不是直接完成异常分类，而是首先对当前样本的模态状态进行刻画，为后续路由决策与融合写回提供依据。具体而言，在多源异构监控数据场景下，融合过程至少面临三个核心判断问题：其一，Trace-Metric 模态当前是否具有足够稳定且有效的判别信息；其二，日志模态当前是否可靠；其三，两路模态之间是否存在显著冲突。若无法在融合前显式回答上述问题，则后续模块很容易将低质量模态与高质量模态等量对待，或者在模态冲突出现时错误地执行过度平滑，从而削弱模型对复杂异常场景的敏感性。

本文采用基于表示统计量的轻量化不确定性建模策略。其主要原因在于，异常检测任务通常缺乏可直接监督的“模态可靠性”标注，而经过前文编码得到的模态表示本身已经包含了模态质量变化的结果。因此，本文不额外引入高成本的不确定性监督，而是从模态表示的分布特征中提取一组具有明确含义的统计量，用于构造样本级状态描述。该设计既能够保持较低的参数开销，又具有较好的可解释性。

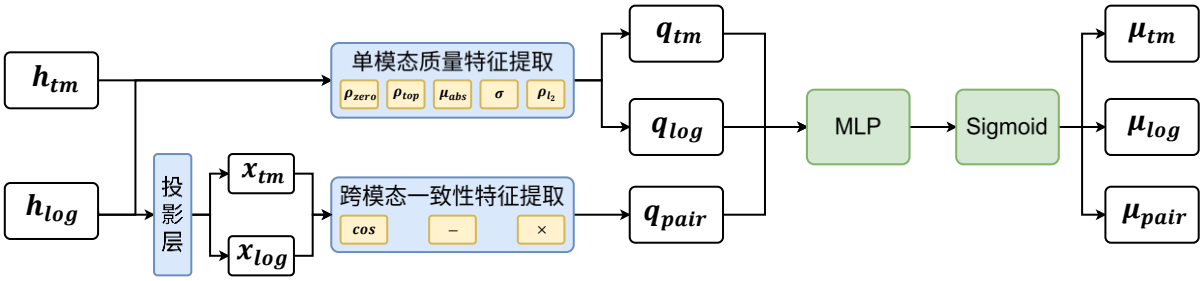

图 5-2 不确定性估计

在特征构造上，本文将不确定性信息划分为两类：单模态质量特征与跨模态一致性特征。其中，单模态质量特征 q_{tm} 与 q_{log} 直接基于前文编码得到的原始模态表示 h_{tm} 与 $h_{\log}$ 计算；跨模态一致性特征 q_{pair} 则基于映射到统一隐空间后的共享表示 x_{tm} 与 x_{log} 构造。这一设计具有明确动机。单模态质量评估更关注“某一路模态自身是否退化”，而稀疏性、能量分布和波动性等统计量在原表示空间中通常具有更直接的物理意义；跨模态关系评估则更关注“两路模态是否表达一致”，因此需要在维度和尺度可比的共享隐空间中进行比较。

换言之，原始模态表示更适合回答“该模态当前是否信息不足、是否被少数维度主导、整体激活是否异常偏弱”等质量问题，而共享隐空间表示更适合回答“两路模态在语义方向上是否一致、数值偏移是否明显、是否存在同步增强”等关系问题。这种“单模态用原空间、跨模态用共享空间”的分工，使不确定性估计既保留了各模态内部状态的可解释性，又保证了跨模态比较的合理性。若将这两类现象混为一谈，容易导致融合模块无法准确区分“该抑制某一路模态”还是“应保留跨模态差异作为异常线索”。

5.3.1 单模态质量特征提取

对于任一模态向量 $v \in R^d$，本文从稀疏性、主导维度占比、整体激活强度和波动性等角度提取单模态质量特征，以衡量当前模态表示是否稳定、是否具有足够判别信息。本文分别提取五个统计量：

$$\rho_{\text{zero}}(\mathbf{v}) = \frac{1}{d}\sum_{i=1}^{d} \mathbf{1}\,(v_i = 0)$$

$$\rho_{\text{top}}(\mathbf{v}) = \frac{\max_i |v_i|}{\sum_{j=1}^{d} |v_j| + \varepsilon}$$

$$\mu_{\text{abs}}(\mathbf{v}) = \frac{1}{d}\sum_{i=1}^{d} |v_i|$$

$$\sigma(\mathbf{v}) = \sqrt{\frac{1}{d}\sum_{i=1}^{d} \left(v_i - \text{mean}(\mathbf{v})\right)^2}$$

$$\rho_{l_2}(\mathbf{v}) = \frac{\|\mathbf{v}\|_2}{\sqrt{d}}$$

首先，ρ_{zero} 表示零值占比，用于衡量当前表示是否过于稀疏；若该值较高，通常意味着当前窗口内可供编码器利用的有效信息不足，例如日志事件数量过少、模板分布过于单一，或某些结构特征未被充分激活。**其次**，ρ_{top} 表示最大绝对激活维度在总体绝对能量中的占比，用于判断表示是否被少数维度过度主导；若该值过高，则说明模态信息分布不均，虽然局部存在响应，但整体表达可能缺乏稳定性和丰富性。**再次**，μ_{abs} 表示各维绝对值的平均水平，用于刻画模态整体激活强度；若该值持续偏低，则表明当前模态整体响应较弱，难以提供足够显著的判别信号。**第四**，σ 表示各维之间的标准差，用于反映表示的内部波动程度；若该值过低，往往说明表示过于平坦、区分性不足，而适度的波动通常意味着模态内部已经形成一定的结构差异。**最后**，ρ_{l_2} 表示归一化后的 L2 范数，用于衡量模态表示的总体能量强度。与 μ_{abs} 相比，ρ_{l_2} 更强调整体幅值而非平均激活水平，二者结合能够更完整地反映“该模态究竟是普遍偏弱，还是虽然均值不高但局部幅值仍然较强”。

综合来看，这五个统计量并不是彼此冗余的简单堆叠，而是从“稀疏性、主导性、

平均强度、波动性、总体能量”五个互补角度共同描述当前模态的健康状态。例如，当 ρ_{zero} 较高且 μ_{abs} 、ρ_{l_2} 较低时，通常可视为模态信息不足；当 ρ_{top} 较高时，则更可能意味着表示被少数维度支配，存在过度集中的风险；而当 σ 较低时，则表明当前模态虽未必完全失效，但内部层次较弱、判别结构不够充分。

据此，分别记 Trace-Metric 模态与日志模态的质量特征为：

$$\mathbf{q}_{tm} = \left[\rho_{\text{zero}}(\mathbf{x}_{tm}), \rho_{\text{top}}(\mathbf{x}_{tm}), \mu_{\text{abs}}(\mathbf{x}_{tm}), \sigma(\mathbf{x}_{tm}), \rho_{l_2}(\mathbf{x}_{tm})\right]$$

$$\mathbf{q}_{log} = \left[\rho_{\text{zero}}(\mathbf{x}_{\text{log}}), \rho_{\text{top}}(\mathbf{x}_{\text{log}}), \mu_{\text{abs}}(\mathbf{x}_{\text{log}}), \sigma(\mathbf{x}_{\text{log}}), \rho_{l_2}(\mathbf{x}_{\text{log}})\right]$$

因此，$\mathbf{q}_{tm}$ 与 $\mathbf{q}_{log}$ 的本质作用，就是分别回答“Trace-Metric 模态当前质量如何”与“日志模态当前质量如何”。

5.3.2 跨模态一致性特征提取

需要指出的是，单模态质量特征主要用于回答“某一路模态自身是否稳定”这一问题，但它们并不能刻画两路模态之间的相对关系。异常传播往往具有时序性和异步性，某些样本中并不是某一路模态单独失真，而是两路模态给出了不一致的信号。因此，仅依赖单模态统计特征仍不足以完整描述复杂异常场景。

$$\mathbf{q}_{pair} = \left[\cos(\mathbf{x}_{tm}, \mathbf{x}_{\text{log}}), \frac{1}{d}\|\mathbf{x}_{tm} - \mathbf{x}_{\text{log}}\|_1, \frac{1}{d}\sum_{i=1}^{d} x_{tm,i}\, x_{log,i}\right]$$

为此，本文进一步构造跨模态一致性特征 $\mathbf{q}_{pair}$，以刻画两路模态在共享隐空间中的关系。其中，**第一项，余弦相似度**用于衡量两路表示在语义方向上的一致性。若该值较高，说明两路模态在高维空间中指向相近的语义方向，即它们对当前样本的状态判断较为一致；若该值较低甚至接近负值，则表明两路模态对当前样本给出了明显不同的表达倾向。**第二项，平均绝对差**用于刻画两路表示在数值空间中的显式偏移程度。与余弦相似度主要强调方向关系不同，该量更加关注两路模态在幅值层面相差多大，因此能够补充描述“方向相近但数值偏移明显”或“方向不完全相反但整体差异较大”等情况。**第三项，逐维乘积均值**则用于衡量两路模态是否存在稳定的协同激活关系。若对应维度往往同步增强，该值通常较高；若一方增强而另一方不响应，或两路模态在多个维度上

呈现相互抵消状态，则该值会较低。

$\mathbf{q}_{pair}$ 之所以重要，是因为微服务异常检测中存在一类容易被忽略却非常关键的情形：并不是某一路模态自身已经完全退化，而是两路模态开始“说不一样的话”。例如，日志中已经出现异常模板，但指标与链路结构尚未同步变化；或者调用链中已经出现局部拥塞与时延扩散，而日志事件仍然相对稀少。此时，真正值得关注的信息不只是“哪个模态更强”或“哪个模态更弱”，而是“模态之间是否已经产生冲突”。因此，$\mathbf{q}_{pair}$ 实际上承担了捕捉跨模态异步传播、局部先兆和冲突线索的重要作用。

5.3.3 不确定性量生成

在得到 $\mathbf{q}_{tm}$、$\mathbf{q}_{\log}$ 和 $\mathbf{q}_{pair}$ 后，本文将其拼接形成一个 13 维样本级状态向量，其中 5 维来自 Trace-Metric 模态质量特征，5 维来自日志模态质量特征，3 维来自跨模态一致性特征。随后，将该 13 维向量输入一个轻量的多层感知机，通过“线性层 - ReLU - 线性层 - Sigmoid”的结构完成非线性映射，最终输出三类不确定性量。这样的设计一方面保留了输入特征的可解释性，另一方面又允许网络自动学习各统计量之间的组合关系，从而避免人为设定固定阈值所带来的刚性限制。

$$[u_{tm}, u_{\log}, u_{pair}] = \sigma\left(\mathrm{MLP}_u\left([\mathbf{q}_{tm}; \mathbf{q}_{\log}; \mathbf{q}_{pair}]\right)\right)$$

其中，u_{tm} 表示 Trace-Metric 模态不确定性，$u_{\log}$ 表示日志模态不确定性，u_pair 表示跨模态冲突不确定性。由于输出经过 Sigmoid 归一化，因此三者均位于 0 到 1 的区间内，可自然解释为连续的风险强度：u_{tm} 越大，说明 Trace-Metric 模态越不可靠；$u_{\log}$ 越大，说明日志模态越不可靠；u_{pair} 越大，则说明两路模态之间的冲突越明显。采用连续值而非离散标签的形式，还便于后续直接将其作为门控或缩放系数参与融合计算。

该模块的关键在于，它并不是简单地产生一个统一门控系数，而是显式区分“单模态是否可靠”和“模态之间是否冲突”这两类信息。因此，不确定性估计结果与仅采用单一门控权重的简单融合不同，这里得到的是一个更丰富的样本级状态表示，不仅能够用于调节融合强度，还能够为后续路由模块提供更加细粒度的决策依据。

5.4 不确定性感知路由

在获得不确定性表示之后，本文进一步设计不确定性感知路由模块，其目标是将样本级状态描述转化为对不同融合专家的权重分配。如果说不确定性估计模块回答的是“当前样本处于什么状态”，那么路由模块回答的则是“面对这种状态，应采用何种融合方式”。因此，该模块本质上承担的是**融合决策器**的角色，即在专家执行具体融合之前，先根据样本状态决定哪一类专家更适合参与当前样本的跨模态整合。

这一设计对于多源异构时序数据异常检测尤为关键。前述不确定性估计模块已经能够刻画“模态是否可靠”和“模态是否冲突”，但这些状态信息本身并不会自动转化为融合行为。若缺少路由机制，即便模型已经识别出某一样本存在显著冲突或单一路模态不稳定，最终仍可能只能采用统一的专家组合或固定聚合方式，从而使不确定性建模停留在“被感知”而未能真正“被利用”的层面。因此，路由模块实际上构成了“不确定性感知”与“专家执行”之间的关键桥梁。

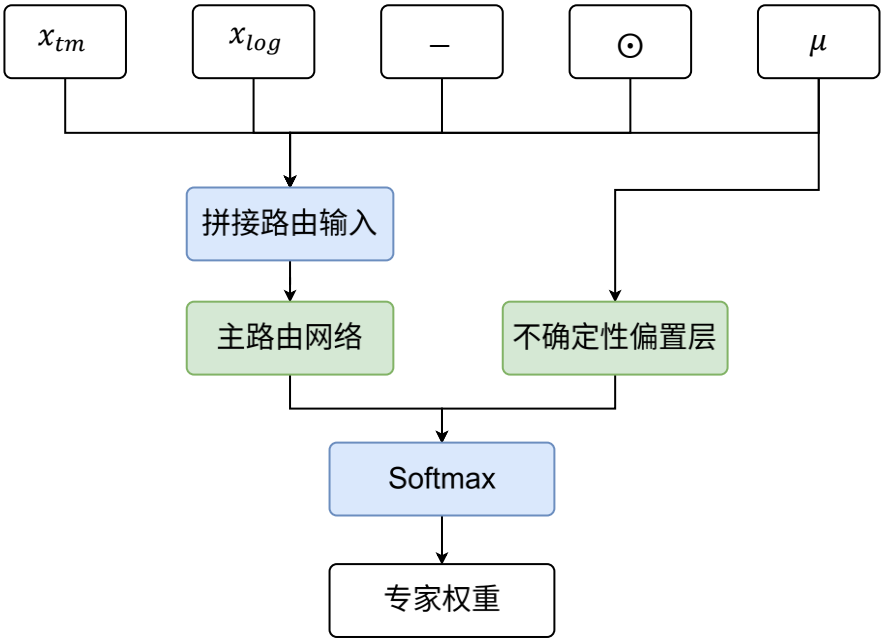

图 5-3 不确定性感知路由

5.4.1 路由输入向量

具体而言，本文将两路共享表示、跨模态差异项、跨模态协同项以及不确定性向量共同拼接，构造样本级路由输入向量。

$$\mathbf{r} = [\mathbf{x}_{tm}; \mathbf{x}_{\log}; |\mathbf{x}_{tm} - \mathbf{x}_{\log}|; \mathbf{x}_{tm} \odot \mathbf{x}_{\log}; u_{tm}; u_{\log}; u_{pair}]$$

首先，$\mathbf{x}_{tm}$ 与 $\mathbf{x}_{\log}$ 保留了两路模态在共享隐空间中的基础语义内容，是路由决策的语义基础。若缺少这两部分信息，路由器只能感知模态之间“差多少”或“是否可靠”，却无法判断当前样本本身属于何种语义上下文，从而难以形成与异常类型相关的专家选择模式。

其次，$|\mathbf{x}_{tm} - \mathbf{x}_{\log}|$ 被显式加入路由输入，用于刻画两路模态之间的差异程度。该项的作用在于使路由器能够直接观察“两个模态到底有多不一样”。如果不引入这一差异项，路由器对于模态冲突的感知只能依赖不确定性标量或隐式网络映射，难以充分保留跨模态不一致的结构信息。尤其在异常传播具有明显异步性的场景中，差异项能够帮助模型识别“某一模态已经出现变化，而另一模态尚未同步响应”的样本，从而为后续选择冲突感知专家提供直接依据。

然后，$\mathbf{x}_{tm} \odot \mathbf{x}_{\log}$ 则用于描述逐维协同激活关系，以反映两路模态是否在某些潜在维度上呈现同步增强。与差异项强调“不同”不同，乘积项强调的是“共同增强”。当两路模态在某些潜在维度上同时被显著激活时，该项能够有效突出模态协同模式；而当一方增强、另一方不响应甚至方向相反时，该项则会减弱。通过同时引入差异项与乘积项，路由器能够在“冲突关系”和“协同关系”两个维度上同时观察跨模态交互，这使其不再只是一个基于内容的简单门控网络，而是能够从更丰富的关系结构出发学习专家分配策略。

通过同时引入差异项与乘积项，路由器不再只能基于单一路模态内容作判断，而是能够同时从“冲突关系”和“协同关系”两个维度观察跨模态交互。

更进一步地，路由输入中还显式包含不确定性向量 $[u_{tm}; u_{\log}; u_{pair}]$。这意味着专家选择并非仅由原始跨模态语义关系决定，还会受到样本风险状态的直接影响。当 u_{tm} 或 $u_{\log}$ 较高时，路由器能够意识到某一路模态当前可靠性较低，从而降低对依赖强交互融合路径的偏好；当 u_{pair} 较高时，路由器则能够识别出当前样本更可能包含重要的模态冲突信息，因此更倾向于提高冲突感知专家或保守型专家的占比。也就是说，本文路由模块并不是一般意义上的内容路由，而是带有显式风险感知能力的状态条件路由。

5.4.2 专家权重分布

在得到路由输入之后，本文通过路由网络生成各专家的路由得分，并结合不确定性信息得到最终的专家权重分布。从结构上看，路由网络可以理解为一个轻量的前馈映射模块，其主要功能是根据样本内容学习“什么样的状态应更偏向哪一类专家”。与此同时，本文并未将不确定性仅作为普通输入交由多层感知机隐式建模，而是进一步通过线性映射将不确定性向量直接注入专家打分过程，使模态可靠性与模态冲突程度能够对专家权重形成显式偏置

$$\alpha = \mathrm{softmax}\left(\frac{\mathrm{MLP}_r(\mathbf{r}) + W_u[u_{tm}, u_{\log}, u_{pair}]}{\tau}\right)$$

其中，$\alpha = [\alpha_1, \alpha_2, \alpha_3, \alpha_4]$，满足各分量非负且总和为 1，$\tau$ 为温度系数。可知专家权重并非仅由原始跨模态特征决定，而是显式受不确定性影响。这样做的意义在于：一方面，$\mathrm{MLP}_r(\mathbf{r})$ 负责根据样本内容学习复杂的专家选择模式；另一方面，不确定性偏置项则从风险层面对专家分配进行直接修正，使模型在面对高冲突、高噪声或低可靠性的样本时能够更快地产生结构化偏置。

式中的温度系数 τ 用于控制路由分布的尖锐程度。当 τ 较小时，Softmax 输出更尖锐，模型更倾向于突出少数专家，适用于融合模式较为明确的样本；当 τ 较大时，路由分布更平滑，有助于在样本状态模糊或多种机制并存时保留专家组合，更适合状态复杂或模糊的样本。通过温度系数的调节，路由模块不仅能够输出“该选哪些专家”，还能够控制专家选择是更偏向单一路径还是更偏向组合式融合。

从决策行为上看，当模态一致且两路质量均较高时，路由器通常会更倾向于共享语义整合或高阶交互类型的专家，因为此时跨模态信息更适合被充分融合；而当模态冲突明显或单一路模态不稳定时，路由器则会提高冲突感知专家或保守残差专家的占比，以避免在不可靠条件下执行过度交互。由此，路由模块使不同样本能够对应不同的融合模式，而不再被迫共享统一的融合函数。

5.4.3 路由熵

为了进一步描述当前样本在专家空间中的决策确定性，本文还定义路由熵：

$$H_{\text{route}} = -\frac{1}{\log K}\sum_{k=1}^{K}\alpha_k \log(\alpha_k + \varepsilon)$$

其中，K 为专家数量。H_{route} 表示路由熵，用于描述当前样本在专家空间中的决策确定性。H_{route} 越高，说明路由分布相对平缓，多个专家的权重都不低，此时模型认为当前样本可能同时需要多种融合机制共同参与，因此在后续聚合阶段会保留更强的组合性；H_{route} 越低，则说明路由分布较为尖锐，样本更明确地对应某一类主导融合模式。

引入路由熵的意义不仅在于刻画专家选择结果，还在于描述这种选择本身是否明确。当路由分布本身仍较为分散时，模型应对融合结果的写回保持更高谨慎性；而当路由器已经形成较明确判断时，则可以允许更充分的信息注入。从解释角度看，α 与 H_{route} 还提供了对融合行为的可观测刻画。研究者可以据此分析某一类异常样本究竟更依赖共享语义整合、高阶交互还是冲突保留路径，从而将“模型为何做出该判别”部分映射回具体的融合机制，这对于异常检测系统的部署和运维分析具有现实意义。

总体而言，不确定性感知路由模块将“模态质量”、“跨模态冲突”和“语义交互关系”统一映射到专家权重空间，从而把样本状态真正转化为融合决策。它的核心价值并不只是给四个专家分配概率，更在于建立了一种从状态感知到专家选择的动态机制，使后续混合专家模块能够在具有明确条件约束的前提下执行跨模态融合。

5.5 混合专家融合模块

混合专家融合模块是本文方法的核心执行层。本文并行设计四类专家，使模型能够从层次语义建模、高阶交互建模、冲突感知建模和保守残差建模四个角度完成跨模态融合。每个专家共享输入 x_{tm} 与 $x_{\log}$，分别输出两路融合增量，再由路由器进行加权聚合。

5.5.1 层次记忆专家

层次记忆专家承担主干融合作用。该专家首先使用局部潜变量分别读取两路模态的关键信息，再利用共享全局潜变量完成统一汇聚。这种“模态内抽取—模态间整合”的路径能够同时保留局部语义与全局语义。设 L_{tm}、$L_{\log}$ 为两组可学习局部潜变量，G

为共享全局潜变量。首先，局部潜变量通过多头注意力分别读取两路模态信息：

$$\mathbf{Z}_{tm}^{loc} = \mathrm{LN}(\mathbf{L}_{tm} + \mathrm{MHA}(\mathbf{L}_{tm}, \mathbf{x}_{tm}, \mathbf{x}_{tm}))$$

$$\mathbf{Z}_{\log}^{loc} = \mathrm{LN}\big(\mathbf{L}_{\log} + \mathrm{MHA}(\mathbf{L}_{\log}, \mathbf{x}_{\log}, \mathbf{x}_{\log})\big)$$

随后，共享全局潜变量分别读取两路局部表示，并由模态可靠性调节更新强度：

$$R_{tm} = 1 - u_{tm}, \quad R_{\log} = 1 - u_{\log}$$

$$\mathbf{Z}^{g} \leftarrow \mathrm{LN}\big(\mathbf{Z}^{g} + R_{tm}\,\mathrm{MHA}(\mathbf{Z}^{g}, \mathbf{Z}_{tm}^{loc}, \mathbf{Z}_{tm}^{loc})\big)$$

$$\mathbf{Z}^{g} \leftarrow \mathrm{LN}\big(\mathbf{Z}^{g} + R_{\log}\,\mathrm{MHA}(\mathbf{Z}^{g}, \mathbf{Z}_{\log}^{loc}, \mathbf{Z}_{\log}^{loc})\big)$$

再经过若干层全局自注意力后，对全局潜变量做平均池化得到共享融合摘要：

$$\mathbf{z}^{g} = \mathrm{MeanPool}(\mathbf{Z}^{g})$$

最后输出两路融合增量：

$$\Delta_{tm}^{(1)} = W_{tm}^{o}\mathbf{z}^{g}, \quad \Delta_{\log}^{(1)} = W_{\log}^{o}\mathbf{z}^{g}$$

该专家能够同时表达局部语义和全局语义，是整个融合模块的主干路径。

5.5.2 双线性交互专家

双线性交互专家用于建模两种模态之间的高阶乘性关系。首先，将两路表示映射到低秩因子空间：

$$\mathbf{b}_{tm} = W_{tm}^{b}\mathbf{x}_{tm}, \quad \mathbf{b}_{\log} = W_{\log}^{b}\mathbf{x}_{\log}$$

然后计算低秩双线性交互：

$$\mathbf{p}_{bi} = \mathrm{LN}(\mathbf{b}_{tm} \odot \mathbf{b}_{\log})$$

最终，通过前馈网络输出两路增量：

$$[\Delta_{tm}^{(2)}, \Delta_{\log}^{(2)}] = \mathrm{MLP}_{b}([\mathbf{x}_{tm}; \mathbf{x}_{\log}; \mathbf{p}_{bi}])$$

该专家能够突出两个模态协同增强的模式，对于“两个模态同时异常才具有强判别力”的场景具有更强表达能力。

5.5.3 冲突感知专家

冲突感知专家专门用于建模模态差异与互补关系。其输入为两路表示、差异项和乘

积项：

$$\mathbf{c} = [\mathbf{x}_{tm}; \mathbf{x}_{\log}; |\mathbf{x}_{tm} - \mathbf{x}_{\log}|; \mathbf{x}_{tm} \odot \mathbf{x}_{\log}]$$

随后通过前馈网络生成两路融合增量：

$$[\Delta_{tm}^{(3)}, \Delta_{\log}^{(3)}] = \mathrm{MLP}_c(\mathbf{c})$$

该专家的核心思想是：模态不一致并不总是噪声，在异常检测任务中，冲突本身往往具有重要判别价值。因此，该专家能够保留和强化“模态不同步”“模态不一致”等异常线索。

5.5.4 保守残差专家

保守残差专家主要用于高不确定性样本的稳定融合。其目标不是进行强交互，而是在保留原始模态信息的基础上做受控的跨模态注入。首先计算门控向量：

$$[g_{tm}, g_{\log}] = \sigma\big(\mathrm{MLP}_s([\mathbf{x}_{tm}; \mathbf{x}_{\log}; |\mathbf{x}_{tm} - \mathbf{x}_{\log}|; \mathbf{x}_{tm} \odot \mathbf{x}_{\log}])\big)$$

然后生成两路保守型更新：

$$\Delta_{tm}^{(4)} = g_{tm} \odot \tanh\big(W_{\log \to tm}\mathbf{x}_{\log}\big)$$

$$\Delta_{\log}^{(4)} = g_{\log} \odot \tanh\big(W_{tm \to \log}\mathbf{x}_{tm}\big)$$

该专家在模态不稳定时能够抑制过度融合，从而降低噪声传播风险。

5.5.5 专家聚合与最终输出

在得到四个专家的输出后，利用在 5.4.2 得出的路由权重对其进行加权聚合：

$$\Delta_{tm} = \sum_{k=1}^{4} \alpha_k \, \Delta_{tm}^{(k)}$$

$$\Delta_{\log} = \sum_{k=1}^{4} \alpha_k \, \Delta_{\log}^{(k)}$$

为了进一步控制融合结果的写回强度，本文引入输出门控机制。以 Trace-Metric 分支为例，其门控定义为：

$$\beta_{tm} = \sigma\big(\mathrm{MLP}_o([\mathbf{x}_{tm}; \Delta_{tm}; u_{tm}; u_{pair}; H_{\mathrm{route}}])\big)$$

$$\beta_{\log} = \sigma\big(\mathrm{MLP}_o([\mathbf{x}_{\log}; \Delta_{\log}; u_{\log}; u_{pair}; H_{\mathrm{route}}])\big)$$

最终两路融合表示为：

$$\mathbf{h}_{tm\to\log} = \mathrm{LN}\left(\mathbf{x}_{tm} + (1 - u_{tm})\,\beta_{tm} \odot \Delta_{tm}\right)$$

$$\mathbf{h}_{\log\to tm} = \mathrm{LN}\left(\mathbf{x}_{\log} + (1 - u_{\log})\,\beta_{\log} \odot \Delta_{\log}\right)$$

当某一路模态不确定性较高时，其融合增量会被自动抑制，从而避免低质量模态对最终表示造成过大干扰。得到 $\mathbf{h}_{tm\to\log}$ 与 $\mathbf{h}_{\log\to tm}$ 后，即可用于后续分类与训练目标计算。

5.6 本章小结

本章围绕多源异构时序数据异常检测中的动态融合问题，提出了基于不确定性感知混合专家的层次化动态融合方法。该方法首先从单模态质量和跨模态一致性两个角度估计样本级不确定性，用于刻画不同模态当前表示的可靠程度以及模态之间的冲突关系；随后将不确定性信息引入路由机制，动态生成不同融合专家的权重分布，使模型能够根据具体样本状态选择更加合适的融合路径；最后通过层次记忆专家、双线性交互专家、冲突感知专家和保守残差专家等多个具有不同归纳偏置的专家模块完成跨模态信息整合，并利用输出门控控制融合增量的写回强度。

总体来看，本章方法突破了传统固定融合方式对所有样本采用同一融合策略的局限，使模型能够在模态质量波动、异常信号不同步以及跨模态信息冲突等复杂场景下进行更加灵活的融合决策。不确定性估计提升了融合过程的可靠性，动态路由增强了模型的样本级适应能力，混合专家结构则提高了融合表示的表达能力。通过上述设计，本文进一步强化了第四章所获得的多模态表示，为第六章实验验证中的整体性能提升和消融分析提供了方法基础。

第六章　实验与结果分析

前文分别从总体框架、特征增强与提取以及层次化动态融合三个方面对本文提出的多源异构时序数据异常检测方法进行了详细阐述。为了验证所提方法在微服务异常检测任务中的有效性，本章围绕实验数据、评价指标、对比方法和实验结果展开系统分析。本章首先介绍实验所使用的数据集、预处理方式、评价指标和实验环境；随后通过总体对比实验验证本文方法相较于代表性基线模型的性能优势；进一步通过消融实验分析特征增强与提取模块、不确定性感知动态融合模块对模型性能的具体贡献；最后通过模态敏感性实验考察日志、调用链追踪和指标三类模态在异常检测中的相对作用，从而全面验证本文方法设计的合理性与有效性。

6.1　实验的目的与内容

为了系统验证本文所提出异常检测模型的有效性，本文围绕模型整体性能、核心创新模块贡献以及不同模态对最终判别结果的影响三个层面开展实验分析。实验设计遵循“先验证整体有效性，再分析模块贡献，最后考察模态依赖性”的思路，从而使实验结论能够与前文提出的整体框架、特征增强与提取方法、协同训练策略以及层次化动态融合方法形成闭环对应。

总体而言，本文实验主要回答以下四个问题。

第一，本文所提模型相较于现有代表性方法是否能够在微服务异常检测任务上取得更优的整体性能；

第二，本文提出的**特征增强与特征提取**是否对模型性能具有稳定且显著的提升作用；

第三，本文提出的**基于不确定性感知混合专家的层次化动态融合方法**是否优于传统静态融合或简化融合方式；

第四，当去除日志、调用链追踪或指标三类模态中的任意一种时，模型性能将发生怎样的变化，从而反映各模态在整体框架中的相对贡献。

基于上述目标，本文设置如下四组实验：

（1）总体对比实验

通过与若干具有代表性的基线方法进行比较，验证本文完整模型在整体性能上的优势。

（2）消融实验 1——特征增强与提取的影响

围绕第四章提出的特征增强与特征提取展开消融，分析不同子模块对最终性能的贡献。

（3）消融实验 2——动态融合方法的影响

围绕第五章提出的动态融合模块展开消融，验证不确定性估计和动态路由设计的有效性。

（4）模态敏感性实验

通过分别去除日志、调用链追踪和指标三类模态中的某一种，分析模型对不同模态信息的依赖程度以及各模态在异常检测任务中的贡献差异。

6.2 实验设置

6.2.1 数据集与预处理设置

本文在两个微服务异常检测数据集上开展实验。

为全面验证所提出多源异构时序数据异常检测框架的有效性，本文从 Generic AIOps Atlas（GAIA）数据集[63]中选取两个相互独立的微服务 mobservice1 和 mobservice2，分别构建实验数据集 D1 和 D2。两个数据集均包含指标（metric）、日志（log）和调用链（trace）三种类型的时序数据，保留了微服务运行过程中的多模态观测信息及异常行为特征，能够较为真实地反映系统在正常与异常状态下的动态变化过程。基于这两个独立微服务构建实验数据集，有助于从不同服务对象的角度评估模型的检测精度、鲁棒性及泛化能力。

该数据集来源于 Cloud Wise 内部的业务模拟系统 Micro SS，系统由 10 个实例组成，能够较为真实地模拟分布式系统的运行状态及故障模式。在连续两周的运行过程中，GAIA 共采集了超过 70 万条监控指标、8700 万条日志以及 2800 万条调用链跟踪记录，较为完整地覆盖了微服务系统运行过程中的多源异构观测信息。与此同时，GAIA 通过控制用户行为并模拟系统误操作，注入了二维码生成失败、系统卡顿、文件无法访问、权限拒绝等多种典型异常场景，并提供了较为完整的异常记录，为异常检测与故障

分析研究提供了可靠的数据基础。由于该数据集兼具真实性、复杂性和多模态特征，已广泛应用于 AIOps 领域的异常检测、日志分析和根因定位等研究任务。

6.2.2 评价指标

考虑到微服务异常检测任务不仅需要衡量整体分类正确率，还需要重点关注异常样本的识别能力，本文采用 Precision、Recall、F1-score 和 AUC 作为主要评价指标。其中，Precision 用于反映被判为异常样本中真正异常样本的比例，Recall 用于反映真实异常样本被识别出的比例，F1-score 用于综合评价 Precision 与 Recall 的平衡性；AUC（Area Under the ROC Curve）用于衡量模型在不同判别阈值下区分异常样本与正常样本的整体能力，能够较好地反映模型的排序性能和综合判别能力。

设真正例、假正例、真负例和假负例分别记为 TP、FP、TN和FN，则各评价指标可表示为

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{FP + TN}$$

$$AUC = \int_0^1 TPR(FPR)d(FPR)$$

其中，TPR 表示真正率，FPR 表示假正率，AUC 表示 ROC 曲线下的面积。AUC 的取值越大，说明模型在不同阈值条件下区分异常样本与正常样本的能力越强。

上述四项指标能够从不同角度反映模型性能。其中，若数据集存在类别不平衡现象，则 Recall 和 F1-score 往往更能体现模型对异常样本的识别能力，因此在实验分析中，本文也将重点关注这些指标的变化趋势。

6.2.3 实验环境设置

为保证实验结论的可信性，本文对所有实验采用统一的训练与测试流程。完整模型及其各类消融变体均在相同的实验环境下训练，并尽可能保持训练轮数、优化器设置、学习率、批次大小以及随机种子等条件一致。对比方法若存在公开推荐参数，则优先使

用其推荐设置；若无统一推荐参数，则通过验证集选择较优配置，以减少由于超参数差异带来的额外影响。

表 6-1 实验环境配置

开发环境	Python 3.9.6
深度学习框架	PyTorch 2.8.0
数值计算库	NumPy 1.26.4
日志解析	Drain

表 6-2 实验主要超参设置

优化器	Adam	主训练使用
批处理大小	Batch size	32
主训练学习率	Learning rate	1e-3
主训练轮数	Epoch	5
窗口参数	Window/Slide	60 s / 30 s
数据划分	Train/Val/Test	7:1:2

6.3 总体对比实验

6.3.1 实验设置

总体对比实验的目的在于验证本文完整模型在整体异常检测任务上的有效性。为此，在实验评估中，将本文提出的方案与两个基于单一数据源的方法和一个基于多源异构时序数据的方法进行比较：

（1）AnoFusion[33]：一种**面向微服务系统的多模态故障检测方法**。该方法结合指标（Metrics）、日志（Logs）和调用链（Traces）三种异构模态数据的无监督故障检测框架。核心思想是利用**图神经网络**对多模态数据进行建模与时序建模，将每一时刻的多模态监控数据构建为**异构图**，采用 **GTN** 对多模态节点间关系进行建模，捕获模态间复杂依赖。

（2）SCWarn[59]：一个用于识别 **软件变更引发故障** 的自动化检测系统。基于 **多模态 LSTM** 构建时间序列模型，融合业务指标、机器指标与结构化日志；引入 **异常评分机制**，基于预测残差进行故障判定；

（3）AMulSys[34]：一种面向微服务系统的多模态异常检测方法。该方法联合调用链（Traces）、日志（Logs）和指标（Metrics）三类监控数据，针对正常样本与异常样本分布不平衡的问题，引入类别先验引导的多模态 Mixup 数据增强策略，并结合难样本加权与多层次对比学习优化跨模态表示，从而提升微服务异常检测的准确性与鲁棒性。

在本组实验中，本文将所提出的完整模型与上述基线方法在相同数据集和相同评价指标下进行比较，并分别统计各方法在两个数据集上的 Precision、 Recall 、 F1-score 和 AUC。为了使比较结果更加直观，可进一步给出平均指标柱状图或折线图，对不同方法在多个指标上的表现进行可视化展示。

6.3.2 结果与分析

表 6-3 D1 和 D2 数据集上的表现对比

数据集	模型	Precision	Recall	F1-score	AUC
D1	AnoFusion	0.1418	***0.9138***	0.2455	0.5398
	SCWarn	0.2297	0.3372	0.2732	0.6195
	AMulSys	***1.0000***	0.7792	0.8759	0.9030
	M3FusionAD（本文）	0.9972	0.8627	***0.9251***	***0.9229***
D2	AnoFusion	0.1275	***0.9856***	0.2258	0.5040
	SCWarn	0.1355	0.6967	0.2269	0.4676
	AMulSys	***1.0000***	0.7701	0.8701	0.8870
	M3FusionAD（本文）	0.9973	0.8474	***0.9163***	***0.9177***

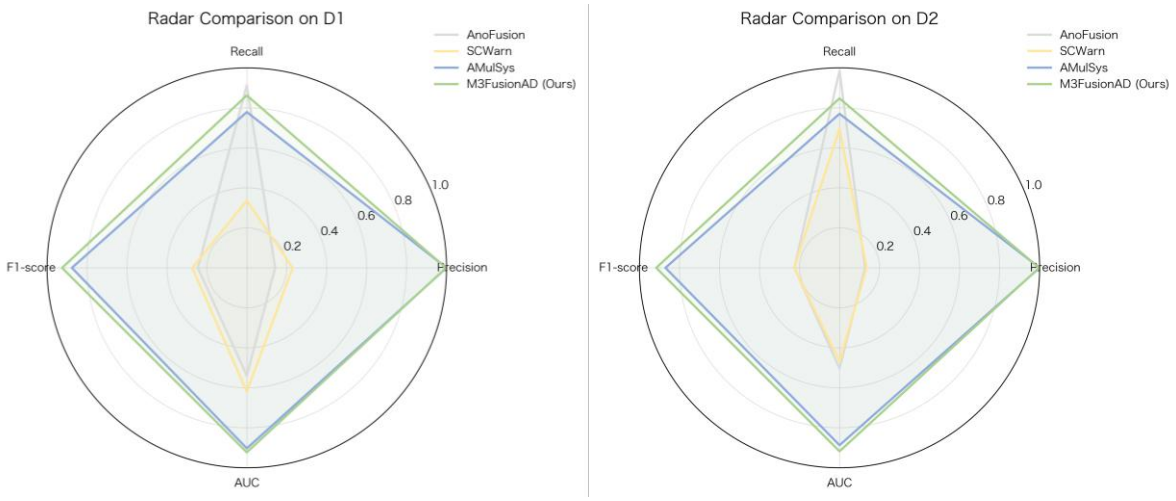

图 6-1 对比实验结果雷达图

表 6-3 和图 6-1 所示结果表明，本文提出的 M3FusionAD 模型在 D1 和 D2 两个数据集上均取得了最优的 F1-score 和 AUC，整体性能稳定优于 AnoFusion、SCWarn 和 AMulSys 等基线方法，验证了本文面向日志、调用链追踪和指标三类异构监控数据所构建的统一异常检测框架的有效性。与 AnoFusion 和 SCWarn 相比，M3FusionAD 不仅显著提升了 F1-score 和 AUC，而且避免了“以较低 Precision 换取较高 Recall”的现象；与当前表现最强的基线模型 AMulSys 相比，本文方法在保持接近 1 的高 Precision 的同时，进一步提升了异常样本识别能力，表现出更优的精确率与召回率平衡能力。

具体来看，在 D1 数据集上，M3FusionAD 的 Recall、F1-score 和 AUC 分别达到 0.8627、0.9251 和 0.9229，相较于最强基线 AMulSys 的 0.7792、0.8759 和 0.9030，分别实现了 0.0835、0.0492 和 0.0199 的绝对提升，对应相对提升为 10.72%、5.62% 和 2.20%。在 D2 数据集上，M3FusionAD 的 Recall、F1-score 和 AUC 分别达到 0.8474、0.9163 和 0.9177，较 AMulSys 的 0.7701、0.8701 和 0.8870 分别提升 0.0773、0.0462 和 0.0307，相对提升达到 10.04%、5.31% 和 3.46%。可以看出，本文方法在两个数据集上的性能增益具有较强一致性，其中 Recall 的提升尤为明显，说明模型对异常样本的覆盖能力得到了显著增强，这对于微服务异常检测任务具有重要意义，因为漏检异常往往会直接影响后续故障定位和系统恢复。

这一结果得益于本文方法在两个层面的协同设计。其一，第四章提出的差异化特征增强与提取机制针对日志语义、Trace 结构和指标时序特性分别进行建模，使模型在输

入阶段就能够保留更强的异常判别信息，避免了不同模态直接拼接所带来的结构信息稀释问题。其二，第五章提出的基于不确定性感知混合专家的层次化动态融合方法，能够根据样本中不同模态的质量差异和冲突程度，自适应调整融合策略，从而在多源异构信息之间建立更稳定的协同关系。特别是与 AnoFusion 和 SCWarn 这类浅层融合或统一建模方法相比，M3FusionAD 通过“模态内差异化建模 + 模态间动态融合”的双阶段策略，更有效地缓解了噪声传播和模态冲突问题，因此在保证 Precision 几乎不下降的前提下，取得了更高的 Recall 和 F1-score。综合来看，总体对比实验验证了本文所提出异常检测框架在准确性、鲁棒性和泛化能力方面的综合优势。

6.4 消融实验 1——特征增强与提取的影响

6.4.1 实验设置

创新点 1 主要对应第四章提出的特征增强、特征提取与图构建逻辑。为了验证该创新点对模型性能的贡献，本文在完整模型基础上构造若干消融变体，并保持其余训练设置不变。具体而言，可设置如下四类消融方式：

表 6-4 消融实验设置

w/o Log-Enhance	去除日志模态的样本级增强与特征提取，仅保留基础日志图输入
w/o Trace-Enhance	去除调用链模态的样本级增强与特征提取，仅保留基础调用链结构信息
w/o All-Enhance	去除三个模态的样本级增强与特征提取，仅保留基础信息
Full Model	完整模型

6.4.2 结果与分析

表 6-5 消融实验表现对比

数据集	模型	Precision	Recall	F1-score	AUC
D1	w/o Log-Enhance	0.9956	0.8261	0.9030	0.9208
	w/o Trace-Enhance	0.9344	0.8261	0.8769	0.9067

	w/o All-Enhance	***0.9975***	0.8238	0.9024	0.9281
	Full Model	0.9972	***0.8627***	***0.9251***	***0.9229***
D2	w/o Log-Enhance	0.9920	0.7654	0.8641	0.9022
	w/o Trace-Enhance	0.9920	0.7654	0.8641	0.8959
	w/o All-Enhance	***1.0000***	0.7897	0.8825	0.9141
	Full Model	0.9973	***0.8474***	***0.9163***	***0.9177***

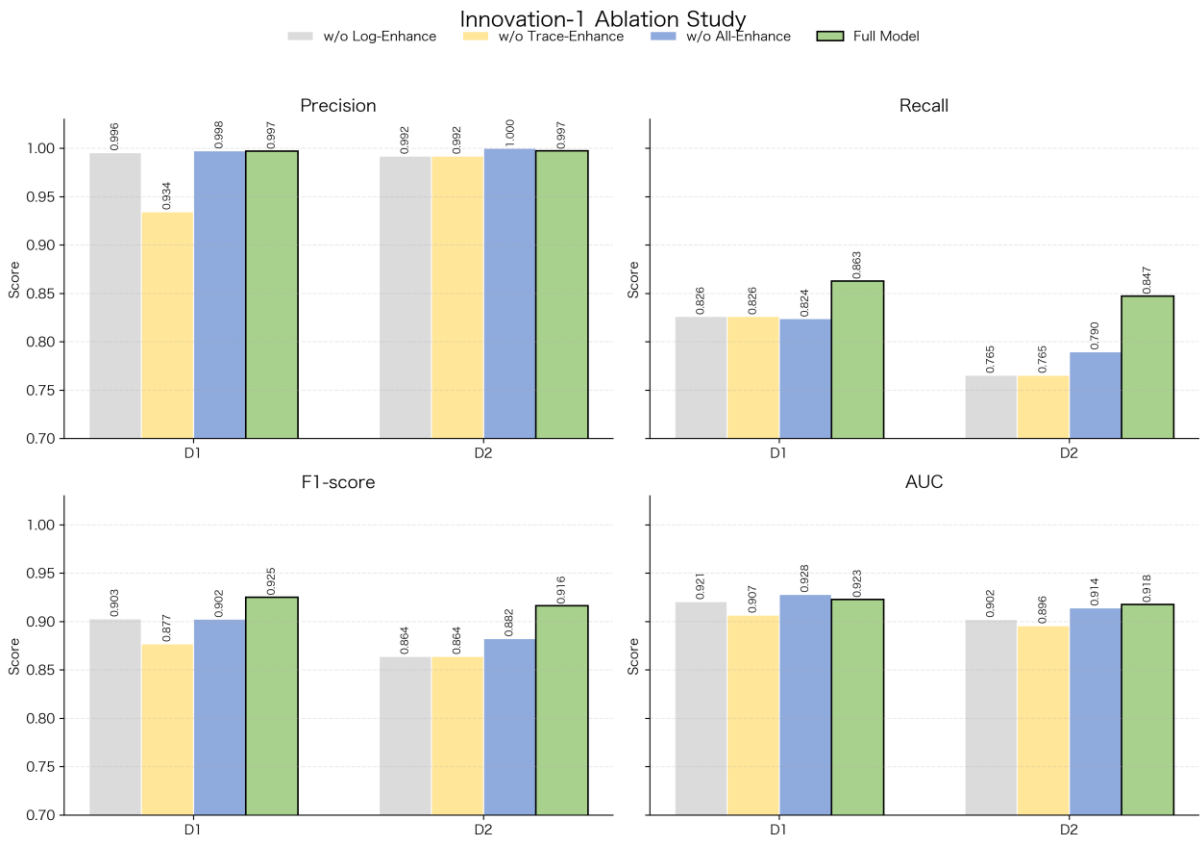

图 6-2 消融实验对比结果柱状图

表 6-5 和图 6-2 所示结果表明，引入第四章提出的样本级增强、特征提取与图构建机制后，模型在 D1 和 D2 数据集上的检测性能均得到稳定提升，说明差异化特征建模对于多源异构时序数据异常检测具有重要作用。与去除不同增强模块的消融变体相比，Full Model 在两个数据集上都取得了最高的 F1-score，分别达到 0.9251 和 0.9163，表明特征增强与提取模块并非局部改进，而是对整体异常检测框架的判别能力都起到了实质性支撑作用。

从具体提升幅度来看，在 D1 数据集上，Full Model 相比于 w/o Log-Enhance、w/o

Trace-Enhance 和 w/o All-Enhance 的 F1-score 分别提升了 0.0221、0.0482 和 0.0227，对应相对提升为 2.45%、5.50% 和 2.52%；Recall 分别提升了 0.0366、0.0366 和 0.0389，说明完整模型能够更充分地覆盖异常样本。其中，去除 Trace-Enhance 后模型性能下降最为明显，F1-score 从 0.9251 降至 0.8769，表明在 D1 中，调用链模态的样本级增强与结构特征提取对于异常模式识别具有更关键的作用。这说明该数据集中的异常更容易通过服务调用路径、链路传播关系及其与指标状态之间的结构耦合体现出来，一旦缺失 Trace 侧的差异化建模，模型对跨语句、跨服务的异常关联捕捉能力就会明显减弱。

在 D2 数据集上，Full Model 相比 w/o Log-Enhance、w/o Trace-Enhance 和 w/o All-Enhance 的 F1-score 分别提升 0.0522、0.0522 和 0.0338，相对提升达到 6.04%、6.04% 和 3.83%；Recall 分别提升 0.0820、0.0820 和 0.0577，性能增益比 D1 更加明显。值得注意的是，w/o Log-Enhance 与 w/o Trace-Enhance 在 D2 上的 Precision、Recall 和 F1-score 完全一致，说明日志增强和调用链增强在该数据集中的贡献程度较为接近，且都主要体现在召回能力的提升上。这一现象表明，不同数据集中的异常表现形式存在差异：在某些场景下，日志语义信息与调用链结构信息具有相近的重要性，因此只有同时保留针对不同模态的增强机制，模型才能形成更完整的异常表征。

另一方面，w/o All-Enhance 在 D1 上的 AUC 为 0.9281，略高于 Full Model 的 0.9229，而在 D2 上 AUC 也仅比 Full Model 低 0.0036。这说明特征增强与提取模块带来的收益并不完全体现在全阈值范围内的排序能力上，而更多体现为最终分类决策层面的优化，尤其是对 Recall 和 F1-score 的提升。换言之，第四章提出的样本级增强与特征提取机制主要通过强化模态内关键异常特征、抑制细粒度噪声并改善图构建质量，帮助模型学习到更利于异常判别的联合表示，从而在保持高 Precision 的同时提升对复杂异常的识别完整性。综合来看，本组实验验证了差异化特征增强与提取机制是本文模型取得优异性能的重要基础。

6.5 消融实验 2——动态融合方法的影响

6.5.1 实验设置

创新点 2 主要对应第五章提出的基于不确定性感知混合专家的层次化动态融合方法。为了验证融合模块中各关键组成部分的必要性，本文在完整模型基础上进一步构造

以下消融变体：

表 6-6 消融实验设置

w/o Uncertainty	去除不确定性估计模块，使融合过程不再显式感知模态质量和跨模态冲突信息。
w/o Router	去除不确定性感知动态路由，采用固定或平均方式聚合各融合专家输出
w/o Uncertainty Moe	去除整个不确定性感知混合专家，仅采用 cross attention 的方式融合
Full Model	完整模型

通过上述消融设计，可以分别考察融合模块在三个层面的贡献，从而更加系统地验证第五章方法设计的合理性。

6.5.2 结果与分析

表 6-7 消融实验表现对比

数据集	模型	Precision	Recall	F1-score	AUC
D1	w/o Uncertainty	0.1596	***1.0000***	0.2753	0.9169
	w/o Router	***1.0000***	0.8261	0.9048	***0.9261***
	w/o Uncertainty Moe	0.9984	0.8320	0.9076	0.9139
	Full Model	0.9972	0.8627	***0.9251***	0.9229
D2	w/o Uncertainty	0.9920	0.7654	0.8641	0.9067
	w/o Router	0.9960	0.7654	0.8656	0.9013
	w/o Uncertainty Moe	***1.0000***	0.7963	0.8866	0.9155
	Full Model	0.9973	***0.8474***	***0.9163***	***0.9177***

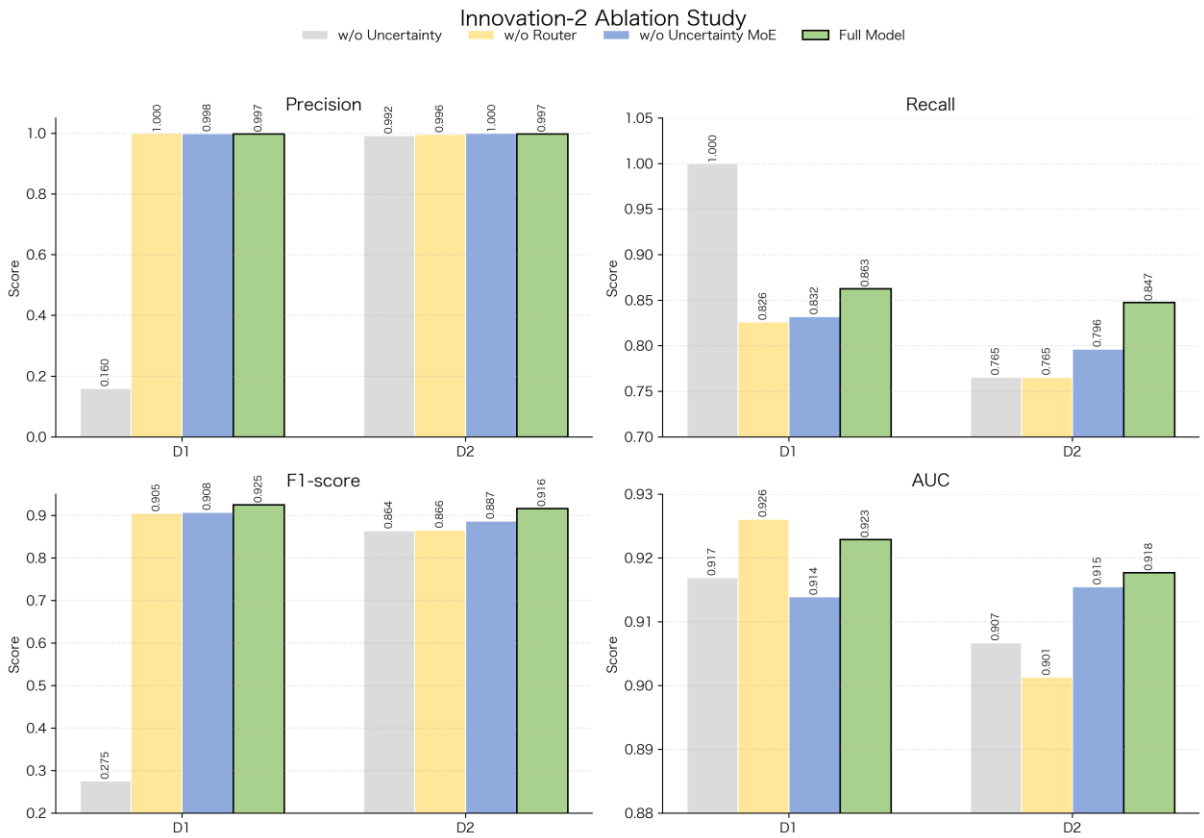

图 6-3 消融实验对比结果柱状图

表 6-7 和图 6-3 所示结果表明，第五章提出的基于不确定性感知混合专家的层次化动态融合方法对模型性能具有关键影响。Full Model 在 D1 和 D2 两个数据集上均取得最高的 F1-score，分别为 0.9251 和 0.9163，显著优于去除不确定性估计、去除动态路由以及去除整个不确定性感知混合专家结构的各类消融变体。这说明在多源异构监控数据场景下，融合阶段并非简单的信息拼接过程，而是直接决定最终异常判别质量的核心环节；只有显式建模模态质量差异和跨模态冲突，模型才能在复杂样本条件下形成稳定而有效的联合表示。

从 D1 数据集的结果来看，不确定性估计模块的作用最为突出。去除该模块后，w/o Uncertainty 的 Recall 虽达到 1.0000，但 Precision 仅为 0.1596，F1-score 急剧下降至 0.2753，较 Full Model 下降了 0.6498，AUC 仍保持在 0.9169。这种“AUC 仍较高但 F1-score 严重崩塌”的现象说明，去除不确定性估计后，模型并未完全丧失对异常样本的排序能力，但在固定阈值下的决策边界发生了明显偏移，表现为对正类样本的过度预测。换言之，不确定性模块的价值不仅在于提高融合表示的质量，更在于抑制低质量模态和冲突信息对最终决策的干扰，改善模型的分类边界校准能力。相比之下，w/o Router

和 w/o Uncertainty Moe 的 F1-score 分别为 0.9048 和 0.9076，较 Full Model 下降 0.0203 和 0.0175，说明即便保留部分融合结构，若缺少样本级动态路由或专家分工机制，模型对复杂模态关系的适应能力仍会受到限制。

在 D2 数据集上，Full Model 相比 w/o Uncertainty、w/o Router 和 w/o Uncertainty Moe 的 F1-score 分别提升 0.0522、0.0507 和 0.0297，相对提升达到 6.04%、5.86% 和 3.35%；Recall 分别提升 0.0820、0.0820 和 0.0511，说明完整融合机制在 D2 上同样能够显著改善异常样本覆盖能力。值得注意的是，w/o Uncertainty Moe 在 D2 上仍取得 0.8866 的 F1-score，明显优于 w/o Uncertainty 和 w/o Router，这表明仅依靠 cross attention 仍可完成基本的跨模态交互，但其对模态可靠性差异和冲突信息的建模能力有限，因此难以达到完整模型的性能水平。与此同时，w/o Router 在 D1 上的 AUC 略高于 Full Model，但 F1-score 仍然偏低，这进一步说明动态路由的主要贡献并不在于单纯提升排序性能，而在于使模型能够根据不同样本自适应选择更合适的融合路径，从而提升最终分类决策的稳定性和准确性。

综合来看，第五章提出的层次化动态融合方法通过“不确定性估计 + 动态路由 + 混合专家聚合”的协同设计，有效缓解了固定融合方式在模态质量波动和跨模态冲突场景下的局限。不确定性估计负责提升融合可靠性和边界校准能力，动态路由负责增强样本级适应性，混合专家结构则提升了融合表示的表达能力。三者共同作用后，模型才能在复杂微服务异常场景下取得最优的综合检测性能。

6.6 模态敏感性实验

6.6.1 实验设置

模态敏感性实验的目标在于分析日志、调用链追踪和指标三类模态在整体模型中的相对贡献。为此，本文在完整模型基础上分别去除一种模态，构建如下实验变体：

（1）w/o Log：去除日志模态，仅保留调用链追踪与指标相关输入。

（2）w/o Trace：去除调用链追踪模态，仅保留日志与指标相关输入。

（3）w/o Metric：去除指标模态，仅保留日志与调用链追踪相关输入。

（4）Full Model：保留三类模态的完整模型。

在具体实现中，当某一模态被移除时，其对应分支不再参与输入构建或融合计算，

其余模块保持与完整模型一致。通过比较不同变体的性能变化，可以进一步识别哪一种模态对整体异常检测最为关键，以及不同模态之间是否存在明显的互补性。

6.6.2 结果与分析

表 6-8 消融实验表现对比

数据集	模型	Precision	Recall	F1-score	AUC
D1	w/o Log	0.1596	1.0000	0.2753	0.5312
	w/o Trace	0.1596	1.0000	0.2753	0.9106
	w/o Metric	0.1596	***1.0000***	0.2753	0.9175
	Full Model	***0.9972***	0.8627	***0.9251***	***0.9229***
D2	w/o Log	0.1874	***1.0000***	0.3156	0.4918
	w/o Trace	0.9960	0.7654	0.8656	0.8842
	w/o Metric	0.9920	0.7654	0.8641	0.9003
	Full Model	***0.9973***	0.8474	***0.9163***	***0.9177***

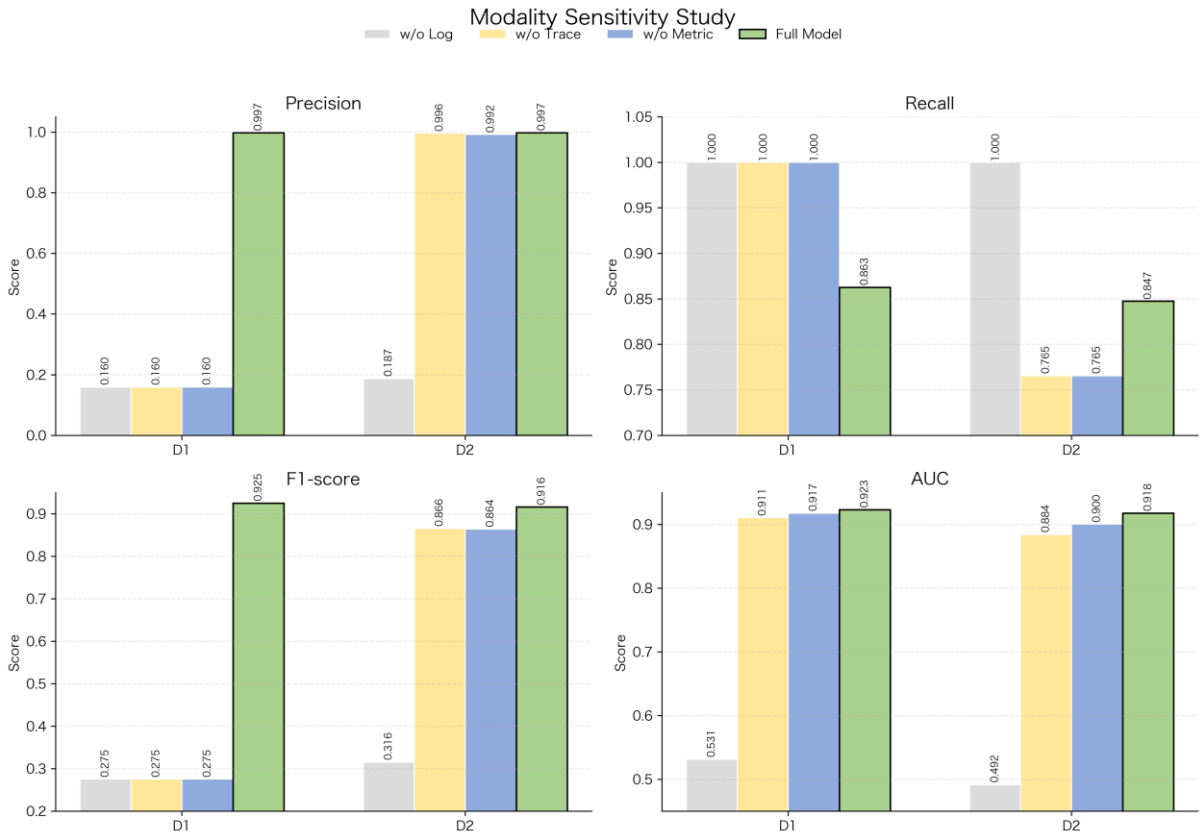

图 6-4 消融实验对比结果柱状图

表 6-8 和图 6-4 所示结果表明，日志、调用链追踪和指标三类模态对微服务异常检测都具有重要贡献，但其作用强度和功能侧重点存在明显差异。Full Model 在 D1 和 D2 上的 F1-score 分别达到 0.9251 和 0.9163，均显著优于去除任一模态后的变体，说明多模态联合建模能够更全面地刻画系统异常状态，三类模态之间具有明显的互补性。具体而言，日志模态主要提供语义异常和上下文事件信息，调用链追踪模态主要描述异常传播路径与服务依赖结构，指标模态则反映系统运行状态和时序波动特征，三者从不同角度共同支撑异常判别。

在本文的实验设置下，三类模态中日志模态的重要性最为突出。当去除日志模态后，模型在 D1 和 D2 上的 F1-score 分别降至 0.2753 和 0.3156，较 Full Model 分别下降 0.6498 和 0.6007；AUC 也分别下降到 0.5312 和 0.4918，几乎退化到接近随机判别水平。这说明日志中蕴含的错误上下文、异常事件模板和语义漂移信息，是模型识别异常最直接、最核心的依据。一旦缺失日志模态，其余模态即便仍能提供部分结构和状态信息，也难以独立支撑稳定的异常判别。特别是在 D2 上，w/o Log 的 Precision 仅为 0.1874，而 Recall 却达到 1.0000，反映出模型在缺乏语义锚点时极易发生正类过预测现象，进一步说明日志模态对于判别边界稳定性具有决定性作用。

相比之下，去除调用链追踪模态或指标模态后，模型性能虽有下降，但退化幅度显著小于去除日志模态。在 D2 数据集上，w/o Trace 和 w/o Metric 的 F1-score 分别为 0.8656 和 0.8641，仅较 Full Model 分别下降 0.0507 和 0.0522；AUC 分别为 0.8842 和 0.9003，说明调用链追踪和指标模态更多起到增强判别边界、补充异常上下文和提升模型鲁棒性的作用，而不是单独决定模型性能的主导因素。二者之间也存在功能差异：去除指标模态后 AUC 仍高于去除调用链追踪模态，说明指标信息对维持整体排序能力和捕捉性能退化类异常更为重要；而去除调用链追踪模态后 Precision 略高，说明调用链信息更偏向于帮助模型构造特定异常场景下的判别边界，尤其是在异常传播关系较为明显的情况下具有不可替代的补充价值。

需要特别讨论的是 D1 数据集上的现象。在该数据集上，w/o Log、w/o Trace 和 w/o Metric 三个变体的 Precision、Recall 和 F1-score 完全相同，均表现为 Precision 极低且 Recall=1.0000。这并不意味着三种模态移除后的实际影响完全一致，而是说明在当前阈值下模型均出现了明显的正类偏置，导致离散分类指标退化为相同数值。在这种情况

下，AUC 更能反映不同模态移除后模型保留的潜在判别能力。可以看到，w/o Trace 和 w/o Metric 在 D1 上的 AUC 仍分别达到 0.9106 和 0.9175，显著高于 w/o Log 的 0.5312，说明即使在固定阈值下三者的分类结果一致，模型在去除不同模态后保留的排序能力依然存在显著差异。换言之，日志模态决定了模型是否还能保持基本的异常识别能力，而调用链追踪和指标模态更多影响的是融合结果的稳定性、分类边界的校准以及对复杂异常场景的补充刻画。综合来看，本组实验进一步验证了三类模态在本文框架中的功能分工与协同价值，也从实验层面支撑了多源异构联合建模策略的合理性。

6.7 分类头结构敏感性实验

6.7.1 实验设置

前文实验主要围绕特征增强与提取模块、图表示学习模块以及不确定性感知动态融合模块展开，验证了本文方法在多源异构时序数据异常检测任务中的整体有效性。除上述关键模块外，最终分类头同样会影响模型的异常判别结果。分类头位于模型输出端，直接接收融合后的高层表示并输出异常概率，其结构复杂度会影响分类边界的表达能力。若分类头过于简单，可能无法充分刻画正常样本与异常样本之间的非线性边界；若分类头过于复杂，则可能在异常样本数量有限、类别分布不均衡以及模态噪声较强的场景下引入额外过拟合风险。因此，有必要进一步分析不同分类头结构对整体检测性能的影响。

为此，本文在保持主干模型结构不变的条件下，仅替换最终分类头，构造分类头结构敏感性实验。实验中固定使用第四章提出的特征增强与提取机制、双图表示学习结构以及第五章提出的不确定性感知混合专家动态融合方法，保持数据划分、训练参数、损失函数和评价指标一致，仅改变分类头类型。通过这种控制变量方式，可以较为直接地观察最终分类头结构对模型性能的影响。

本文对比以下三类分类头：

（1）Linear Head。该分类头仅包含一个单层线性映射，将融合后的联合表示直接映射为异常预测 logit。该结构参数量最少，表达能力相对有限，主要用于验证经过前序表示学习与动态融合后，模型输出表示是否已经具备较强的线性可分性。

（2）MLP Head。该分类头由两层全连接网络构成，中间包含 ReLU 激活函数和 Dropout 正则化。相比 Linear Head，MLP Head 具备更强的非线性建模能力，能够进一

步拟合正常样本与异常样本之间更复杂的判别边界。本文默认采用该分类头作为最终异常判别模块。

（3）Interaction MLP Head。该分类头在输入阶段显式构造跨模态交互特征。具体而言，首先将融合后的 Trace-Metric 表示和日志表示拆分，然后拼接两路表示、两路表示差值的绝对值以及逐元素乘积，最后输入 MLP 完成异常判别。该结构用于分析显式跨模态交互信息是否能够进一步提升最终分类性能。

三类分类头的实验设置如表 6-9 所示。

表 6-9 消融实验设置

分类头	结构说明	实验目的
Linear Head	单层线性映射	验证融合表示的线性可分性
MLP Head	两层全连接网络 + ReLU + Dropout	建模非线性异常判别边界
Interaction MLP Head	拼接原始表示、差值绝对值和逐元素乘积后输入 MLP	验证显式跨模态交互特征的影响

6.7.2 结果与分析

不同分类头在 D1 和 D2 数据集上的实验结果如表 6-10 所示。需要说明的是，本组实验固定主干模型为 HiR-MoE 融合结构，并保持特征增强、图表示学习、训练轮数、数据划分方式和其他超参数不变，仅替换最终分类头结构。因此，实验结果能够较为直接地反映分类头结构对最终异常检测性能的影响。

表 6-10 不同分类头性能对比

数据集	模型	Precision	Recall	F1-score	AUC
D1	Linear Head	0.9972	0.8627	0.9251	0.9232
	MLP Head	0.9972	0.8627	***0.9251***	0.9280
	Interaction MLP Head	0.1800	1.0000	0.3051	0.9282
D2	Linear Head	0.9973	0.8474	0.9163	0.9208
	MLP Head	0.9973	0.8474	***0.9163***	0.9339
	Interaction MLP Head	0.1905	1.0000	0.3200	0.9139

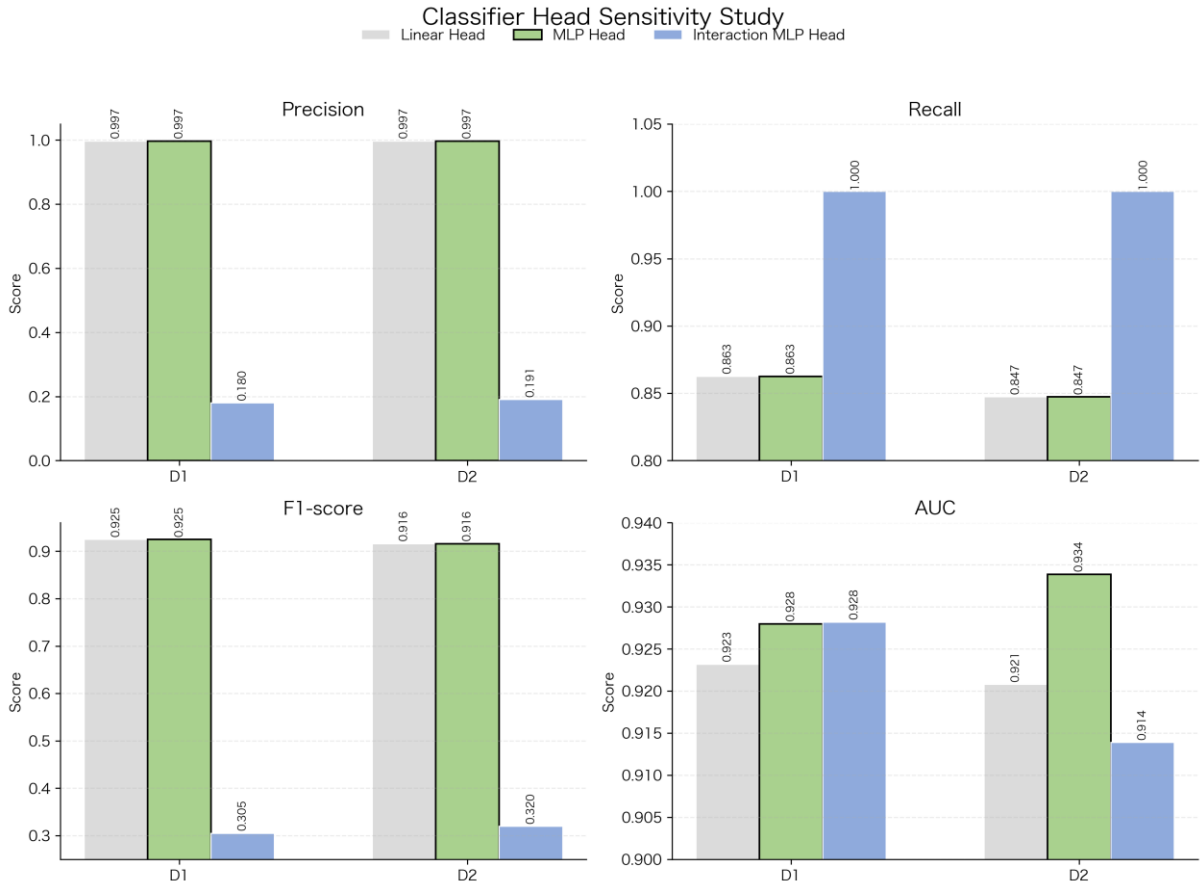

图 6-5 消融实验对比结果柱状图

从 D1 数据集的结果可以看出，Linear Head 与 MLP Head 在 Precision、Recall 和 F1-score 上完全一致，二者均取得 0.9972 的 Precision、0.8627 的 Recall 和 0.9251 的 F1-score，说明在当前测试集阈值决策下，两类分类头给出了相同的离散分类结果。两者的差异主要体现在 AUC 上，其中 MLP Head 的 AUC 为 0.9280，高于 Linear Head 的 0.9232。这表明，虽然二者在最终二分类标签上表现一致，但 **MLP Head 输出的异常分数具有更好的排序能力**，能够在不同阈值条件下更稳定地区分正常样本与异常样本。

这一结果说明，经过前序特征增强、图表示学习和不确定性感知动态融合后，模型已经学习到了较强的异常判别表示。即使使用结构最简单的线性分类头，也能够获得较高的 F1-score，说明融合后的高层表示已经具备较好的线性可分性。与此同时，MLP Head 在 AUC 上进一步提升，说明适度引入非线性变换有助于优化异常分数分布，使异常样本整体上更靠近高风险区域、正常样本更靠近低风险区域。因此，MLP Head 虽然没有改变当前阈值下的离散分类结果，但提升了模型在不同判别阈值下的综合排序能力。

Interaction MLP Head 在 D1 数据集上呈现出另一种现象。该分类头的 AUC 为 0.9282，与 MLP Head 接近，说明其输出分数在整体排序层面仍然包含一定有效信息；但其 Precision 仅为 0.1800，F1-score 下降至 0.3051，而 Recall 达到 1.0000。从混淆矩阵可以看出，该分类头在当前阈值下几乎将所有样本都判定为异常，虽然没有漏检异常样本，但产生了大量假正例。这表明，Interaction MLP Head 的问题并不主要体现在异常排序能力完全失效，而是体现在输出分数的阈值校准较差，导致最终离散决策明显偏向异常类别。

在 D2 数据集上，实验结果与 D1 基本一致。Linear Head 与 MLP Head 仍然取得完全相同的 Precision、Recall 和 F1-score，其中 Precision 为 0.9973，Recall 为 0.8474，F1-score 为 0.9163。二者差异同样主要体现在 AUC 上，MLP Head 的 AUC 达到 0.9339，明显高于 Linear Head 的 0.9208。这进一步说明，MLP Head 能够在不增加误报数量的情况下，提升异常概率输出的排序质量，使模型在阈值变化时具备更好的综合判别能力。

相比之下，Interaction MLP Head 在 D2 数据集上同样表现出较强的不稳定性。其 Recall 仍然达到 1.0000，但 Precision 下降至 0.1905，F1-score 仅为 0.3200。该结果说明，显式引入跨模态差值和逐元素乘积特征后，分类头对异常信号更加敏感，但这种敏感性并没有稳定转化为更好的综合检测性能。对于微服务监控数据而言，不同模态之间天然存在采样粒度差异、时间延迟和噪声波动，Trace-Metric 表示与日志表示之间的差异并不总是对应真实异常。当分类头过度放大这类显式交互特征时，正常样本中的模态不一致也可能被误判为异常，从而导致假正例数量显著增加。

综合两个数据集的结果可以发现，分类头结构对模型输出分数和最终检测结果均具有一定影响，但影响方式并不相同。Linear Head 结构简单，但已经能够取得较高 F1-score，说明本文主干模型学习到的融合表示具有较强判别能力；MLP Head 在保持与 Linear Head 相同离散分类性能的同时，进一步提升了 AUC，说明适度非线性分类头有助于改善异常分数排序；Interaction MLP Head 虽然在 AUC 上并未明显退化，但在当前阈值下出现严重的异常类别偏置，导致 Precision 和 F1-score 明显下降。

因此，本组实验表明，最终分类头并非越复杂越好。对于本文所研究的多源异构时序数据异常检测任务，过度显式的交互式分类头可能放大模态噪声和正常样本中的跨模

态差异，反而降低最终判别稳定性。相比之下，MLP Head 在表达能力、排序性能和决策稳定性之间取得了更好的平衡。结合 D1 和 D2 两个数据集的实验结果，本文选择 MLP Head 作为默认分类头是合理的：一方面，它能够保持与线性分类头相同的高 Precision 和 F1-score；另一方面，它在两个数据集上均取得更高的 AUC，说明其异常分数输出具有更好的整体区分能力。

更进一步地，该实验也从侧面验证了**本文主干框架的有效性**。Linear Head 已经能够取得较强性能，说明模型性能提升并不是依赖复杂分类器在最后阶段进行过拟合，而是主要来自前序特征增强、图结构表示学习和不确定性感知动态融合所形成的高质量异常表示。MLP Head 的作用更多体现在对最终判别边界和异常分数排序的细化，而不是替代前序模块完成主要特征学习。

6.8 本章小结

本章围绕本文提出的面向多源异构时序数据的微服务异常检测方法，系统开展了总体对比实验以及三组专项实验，并从**整体性能、关键模块贡献和模态依赖性**三个层面对模型有效性进行了验证。

总体对比实验表明，M3FusionAD 在 D1 和 D2 两个数据集上均取得了最优的 F1-score 和 AUC，同时保持了接近 1 的高 Precision，说明所提出方法能够在不显著增加误报的前提下有效提升异常识别能力，体现出较强的综合检测性能。

围绕创新点 1 的消融实验进一步表明，第四章提出的特征增强、特征提取与图构建机制能够显著提升模型对异常样本的覆盖能力，其中调用链模态增强在 D1 上贡献更为突出，而整体增强模块的引入有助于提升最终分类性能与模型鲁棒性。围绕创新点 2 的消融实验则验证了第五章所提出的不确定性感知混合专家层次化动态融合方法的必要性：不确定性估计有助于提升融合结果的可靠性与决策边界校准能力，动态路由增强了模型对不同样本融合需求的自适应能力，而二者结合后能够实现更优的异常检测效果。模态敏感性实验进一步说明，日志模态是决定模型性能上限的核心信息来源，调用链追踪模态和指标模态则分别从服务传播结构和系统状态变化两个角度提供重要补充，三类模态之间具有明显的互补关系。

综合来看，本章实验结果较为一致地验证了本文方法设计的合理性，即通过对指标、

日志和调用链追踪三类异构监控数据进行联合建模，并结合样本级增强与不确定性感知动态融合机制，能够有效提升模型在复杂微服务异常场景下的检测准确性、鲁棒性和适应能力。

总结与展望

本文面向微服务系统中的多源异构时序数据异常检测问题，围绕指标、日志和调用链追踪三类核心监控数据，系统研究了异常检测模型的统一建模、特征表示与动态融合方法。针对现有研究中单模态方法难以全面刻画系统异常、多模态方法在样本级表示增强与融合适应性方面不足的问题，本文提出了一套面向多源异构监控数据的异常检测框架，并从特征增强、图结构建模和不确定性感知融合等多个方面进行了较为系统的分析与优化。实验结果表明，本文方法在两个数据集上均取得了较优的检测性能，同时各类消融实验也验证了所提关键模块的有效性与必要性。

论文总结

本文主要工作内容如下：

（1）本文针对微服务系统中指标、日志和调用链追踪三类监控数据的异构性，构建了一个统一的多模态异常检测框架。该框架能够在同一建模体系下处理数值时序、语义事件流和服务传播结构，为后续特征提取与融合分析提供了统一基础。

（2）本文围绕多模态样本级表示学习问题，设计了结合特征增强、特征提取与图构建的建模方法。针对日志模态、调用链模态和指标模态分别设计了相应的样本级增强与表示提取机制，并进一步构建 Trace-Metric 图与日志异构图，以提升模型对局部异常信号和结构依赖关系的表达能力。

（3）本文提出了一种基于不确定性感知混合专家的层次化动态融合方法。该方法通过显式估计模态质量和跨模态冲突信息，引入不确定性感知、动态路由和专家聚合机制，使模型能够根据不同样本的状态自适应地调整融合策略，从而提升多模态异常检测的稳定性与适应能力。

（4）本文通过总体对比实验、两组创新点消融实验以及模态敏感性实验，对所提出方法的有效性进行了系统验证。实验结果表明，完整模型在两个数据集上均取得了最优的 F1-score 和 AUC，并在保持极高 Precision 的同时显著提升了 Recall，说明本文方法能够更有效地识别异常样本并保持较优的综合检测性能。进一步分析表明，特征增强与图构建机制提升了模型对异常样本的覆盖能力，不确定性感知与动态路由机制增强了融合结果的可靠性与样本级适应能力；同时，日志模态是影响模型性能的关键因素，而

调用链追踪模态和指标模态分别从服务传播结构和系统状态变化两个角度提供重要补充，三类模态之间具有明显的互补关系。

综合来看，本文从统一框架设计、样本级特征表示、图结构建模和动态融合机制四个层面，构建了一套较为完整的微服务异常检测方法体系，并通过系统实验验证了该方法在复杂多源异构时序数据场景下的有效性与可行性。

未来展望

本文面向多源异构时序数据的微服务异常检测问题，搭建了统一的异常检测框架，并围绕样本级增强、图结构表示和不确定性感知动态融合开展了较为系统的研究。然而，当前工作仍有进一步优化和拓展的空间，本文对未来研究方向展望如下：

（1）探索更加高效的在线异常检测方法。当前研究主要基于离线实验设置开展验证，未来可进一步面向真实生产环境研究低时延、可持续更新的在线异常检测机制，以增强模型在实时运维场景中的应用价值。

（2）研究弱监督、自监督或无监督条件下的异常检测方法。微服务异常检测通常面临标注样本稀缺、异常类型多样和类别分布不平衡等问题，未来可进一步降低模型对人工标签的依赖，提高模型在低标注甚至无标注场景下的泛化能力。

（3）提升模型的可解释性与根因分析能力。当前方法主要聚焦于异常检测本身，未来可进一步结合模态贡献分析、服务级异常定位和跨模态证据关联机制，使模型不仅能够检测异常，还能够为故障诊断与根因定位提供更直接的支撑。

（4）探索更丰富的多模态融合信息来源。除指标、日志和调用链追踪外，微服务系统中还存在部署拓扑、配置变更、事件告警和资源调度等辅助信息，未来可尝试将更多运维上下文纳入统一框架，以进一步提升模型对复杂场景异常的感知能力。

（5）开展更广泛的跨系统与跨数据集验证。不同微服务系统在服务规模、调用结构、日志风格和指标分布上存在较大差异，未来可进一步在更多真实工业场景中验证所提方法的迁移性与泛化能力，并研究面向跨域场景的自适应异常检测方法。

参考文献

[1] Schmidl S., Wenig P., Papenbrock T. Anomaly Detection in Time Series: A Comprehensive Evaluation[J]. Proceedings of the VLDB Endowment, 2022,15(9): 1779-1797

[2] Bogatinovski J., Nedelkoski S. Multi-Source Anomaly Detection in Distributed IT Systems[M]. Hacid H., Outay F., Paik H., et al. Service-Oriented Computing – ICSOC 2020 Workshops: Vol. 12632. Cham: Springer International Publishing, 2021: 201-213

[3] Nedelkoski S., Bogatinovski J., Mandapati A. K., et al. Multi-Source Distributed System Data for AI-Powered Analytics[M]. Brogi A., Zimmermann W., Kritikos K. Service-Oriented and Cloud Computing: Vol. 12054. Cham: Springer International Publishing, 2020: 161-176

[4] Siffer A., Fouque P.-A., Termier A., et al. Anomaly Detection in Streams with Extreme Value Theory[A]. Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining[C]. New York, NY, USA: Association for Computing Machinery, 2017: 1067-1075

[5] Landauer M., Onder S., Skopik F., et al. Deep Learning for Anomaly Detection in Log Data: A Survey[J]. Machine Learning with Applications, 2023,12: 100470

[6] Sun Y., Shao M., Nie X., et al. A Comprehensive Benchmark and Empirical Study of Trace Anomaly Detection[J]. IEEE Transactions on Services Computing, 2025,18(6): 3364-3377

[7] Zamanzadeh Darban Z., Webb G. I., Pan S., et al. Deep Learning for Time Series Anomaly Detection: A Survey[J]. ACM Computing Surveys, 2025,57(1): 1-42

[8] Wu W., He L., Lin W., et al. Developing an Unsupervised Real-Time Anomaly Detection Scheme for Time Series with Multi-Seasonality[J]. IEEE Transactions on Knowledge and Data Engineering, 2022,34(9): 4147-4160

[9] Wu H., Hu T., Liu Y., et al. TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis[EB]. arXiv, 2023

[10] Deng A., Hooi B. Graph Neural Network-Based Anomaly Detection in Multivariate Time Series[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021,35(5):

4027-4035

[11] Gao R., He W., Yan L., et al. Hybrid Graph Transformer Networks for Multivariate Time Series Anomaly Detection[J]. The Journal of Supercomputing, 2024,80(1): 642-669

[12] Zhang Y., Wang J., Chen Y., et al. Adaptive Memory Networks with Self-Supervised Learning for Unsupervised Anomaly Detection[J]. IEEE Transactions on Knowledge and Data Engineering, 2023,35(12): 12068-12080

[13] Li L., Yan J., Wen Q., et al. Learning Robust Deep State Space for Unsupervised Anomaly Detection in Contaminated Time-Series[J]. IEEE Transactions on Knowledge and Data Engineering, 2022: 1-1

[14] Tuli S., Casale G. TranAD: Deep Transformer Networks for Anomaly Detection in Multivariate Time Series Data[A]. VLDB[C]. arXiv, 2022

[15] Li Y., Peng X., Zhang J., et al. DCT-GAN: Dilated Convolutional Transformer-Based GAN for Time Series Anomaly Detection[J]. IEEE Transactions on Knowledge and Data Engineering, 2023,35(4): 3632-3644

[16] Darban Z. Z., Webb G. I., Pan S., et al. CARLA: Self-Supervised Contrastive Representation Learning for Time Series Anomaly Detection[J]. Pattern Recognition, 2025,157: 110874

[17] Yue Z., Wang Y., Duan J., et al. TS2Vec: Towards Universal Representation of Time Series[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2022,36(8): 8980-8987

[18] Zhao H., Wang Y., Duan J., et al. Multivariate Time-Series Anomaly Detection via Graph Attention Network[A]. 2020 IEEE International Conference on Data Mining (ICDM)[C]. Sorrento, Italy: IEEE, 2020: 841-850

[19] Han S., Woo S. S. Learning Sparse Latent Graph Representations for Anomaly Detection in Multivariate Time Series[A]. Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining[C]. Washington DC USA: ACM, 2022: 2977-2986

[20] Meng W., Liu Y., Zhu Y., et al. LogAnomaly: Unsupervised Detection of Sequential and Quantitative Anomalies in Unstructured Logs[A]. Proceedings of the Twenty-Eighth

International Joint Conference on Artificial Intelligence[C]. Macao, China: International Joint Conferences on Artificial Intelligence Organization, 2019: 4739-4745

[21] Guo H., Yang J., Liu J., et al. LogFormer: A Pre-Train and Tuning Pipeline for Log Anomaly Detection[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2024,38(1): 135-143

[22] Li Z., Shi J., Van Leeuwen M. Graph Neural Networks Based Log Anomaly Detection and Explanation[A]. Proceedings of the 2024 IEEE/ACM 46th International Conference on Software Engineering: Companion Proceedings[C]. Lisbon Portugal: ACM, 2024: 306-307

[23] P. Liu et al., Unsupervised Detection of Microservice Trace Anomalies through Service-Level Deep Bayesian Networks

[24] S. Nedelkoski, J. Cardoso, O. Kao, Anomaly Detection From System Tracing Data Using Multimodal Deep Learning

[25] Z. Xie et al., Unsupervised Anomaly Detection on Microservice Traces through Graph VAE

[26] Z. Xie et al., From Point-Wise to Group-Wise: A Fast and Accurate Microservice Trace Anomaly Detection Approach

[27] K. Zhang et al., PUTraceAD: Trace Anomaly Detection with Partial Labels Based on GNN and PU Learning

[28] C. Zhang et al., TraceCRL: Contrastive Representation Learning for Microservice Trace Analysis

[29] Y. Sun et al., A Comprehensive Benchmark and Empirical Study of Trace Anomaly Detection

[30] Zhang C., Peng X., Sha C., et al. DeepTraLog: Trace-Log Combined Microservice Anomaly Detection through Graph-Based Deep Learning[A]. Proceedings of the 44th International Conference on Software Engineering[C]. Pittsburgh Pennsylvania: ACM, 2022: 623-634

[31] Liu X., Liu Y., Wei M., et al. LMGD: Log-Metric Combined Microservice Anomaly

Detection through Graph-Based Deep Learning[J]. IEEE Access, 2024: 1-1

[32] Ren R., Wang Y., Liu F., et al. Triple:The Interpretable Deep Learning Anomaly Detection Framework Based on Trace-Metric-Log of Microservice[A]. 2023 IEEE/ACM 31st International Symposium on Quality of Service (IWQoS)[C]. Orlando, FL, USA: IEEE, 2023: 1-10

[33] Zhao C., Ma M., Zhong Z., et al. Robust Multimodal Failure Detection for Microservice Systems[A]. Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining[C]. Long Beach CA USA: ACM, 2023: 5639-5649

[34] Wang P., Zhang X., Cao Z. Anomaly Detection for Microservice System via Augmented Multimodal Data and Hybrid Graph Representations[J]. Information Fusion, 2025,118: 103017

[35] Jin M., Koh H. Y., Wen Q., et al. A Survey on Graph Neural Networks for Time Series: Forecasting, Classification, Imputation, and Anomaly Detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024,46(12): 10466-10485

[36] Zhang S., Tong H., Xu J., et al. Graph Convolutional Networks: A Comprehensive Review[J]. Computational Social Networks, 2019,6(1): 11

[37] Li Y, Tarlow D, Brockschmidt M, et al. Gated graph sequence neural networks[J]. arXiv preprint arXiv:1511.05493, 2015.

[38] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[J]. arXiv preprint arXiv:1710.10903, 2017.

[39] Zhang C, Song D, Huang C, et al. Heterogeneous graph neural network[C]//Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining. 2019: 793-803.

[40] Hu Z, Dong Y, Wang K, et al. Heterogeneous graph transformer[C]//Proceedings of the web conference 2020. 2020: 2704-2710.

[41] Arevalo J, Solorio T, Montes-y-Gómez M, et al. Gated multimodal units for information fusion[J]. arXiv preprint arXiv:1702.01992, 2017.

[42] Li Z, Liu F, Yang W, et al. A survey of convolutional neural networks: analysis,

applications, and prospects[J]. IEEE transactions on neural networks and learning systems, 2021, 33(12): 6999-7019.

[43] Medsker L R, Jain L. Recurrent neural networks[J]. Design and applications, 2001, 5(64-67): 2.

[44] DiPietro R, Hager G D. Deep learning: RNNs and LSTM[M]//Handbook of medical image computing and computer assisted intervention. Academic Press, 2020: 503-519.

[45] Shiri F M, Perumal T, Mustapha N, et al. A comprehensive overview and comparative analysis on deep learning models: CNN, RNN, LSTM, GRU[J]. arXiv preprint arXiv:2305.17473, 2023.

[46] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[47] Luo J H, Wu J. Neural network pruning with residual-connections and limited-data[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 1458-1467.

[48] He P., Zhu J., Zheng Z., et al. Drain: An Online Log Parsing Approach with Fixed Depth Tree[A]. 2017 IEEE International Conference on Web Services (ICWS)[C]. Honolulu, HI, USA: IEEE, 2017: 33-40

[49] Yadav R. B., Kumar P. S., Dhavale S. V. A Survey on Log Anomaly Detection Using Deep Learning[A]. 2020 8th International Conference on Reliability, Infocom Technologies and Optimization (Trends and Future Directions) (ICRITO)[C]. Noida, India: IEEE, 2020: 1215-1220

[50] Luong M T, Pham H, Manning C D. Effective approaches to attention-based neural machine translation[C]//Proceedings of the 2015 conference on empirical methods in natural language processing. 2015: 1412-1421.

[51] Bresson X, Laurent T. Residual gated graph convnets[J]. arXiv preprint arXiv:1711.07553, 2017.

[52] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018:

3-19.

[53] Yu F., Koltun V. Multi-Scale Context Aggregation by Dilated Convolutions[EB]. arXiv, 2016

[54] Schuster M., Paliwal K. K. Bidirectional Recurrent Neural Networks[J]. IEEE Transactions on Signal Processing, 1997,45(11): 2673-2681

[55] Cho K., Merrienboer B. van, Gulcehre C., et al. Learning Phrase Representations Using RNN Encoder-Decoder for Statistical Machine Translation[EB]. arXiv, 2014

[56] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International conference on machine learning. pmlr, 2015: 448-456.

[57] Wang H, Mo Y, Xiang K, et al. Csformer: Combining channel independence and mixing for robust multivariate time series forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(20): 21090-21098.

[58] Szegedy C., Wei Liu, Yangqing Jia, et al. Going Deeper with Convolutions[A]. 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)[C]. Boston, MA, USA: IEEE, 2015: 1-9

[59] Zhao N., Chen J., Yu Z., et al. Identifying Bad Software Changes via Multimodal Anomaly Detection for Online Service Systems[A]. Proceedings of the 29th ACM Joint Meeting on European Software Engineering Conference and Symposium on the Foundations of Software Engineering[C]. Athens Greece: ACM, 2021: 527-539

[60] Liu H., Huang X., Jia M., et al. UAC-AD: Unsupervised Adversarial Contrastive Learning for Anomaly Detection on Multi-Modal Data in Microservice Systems[J]. IEEE Transactions on Services Computing, 2024,17(6): 3887-3900

[61] Yin T., Zhang Z., Hou S., et al. MSAnomaly: Time Series Anomaly Detection with Multi-Scale Augmentation and Fusion[A]. Sheng Q. Z., Dobbie G., Jiang J., et al. Advanced Data Mining and Applications[C]. Singapore: Springer Nature, 2025: 356-371

[62] Xu J., Yang R., Huo Y., et al. DivLog: Log Parsing with Prompt Enhanced in-Context Learning[A]. Proceedings of the IEEE/ACM 46th International Conference on Software

Engineering[C]. Lisbon Portugal: ACM, 2024: 1-12

[63] Notaro P., Cardoso J., Gerndt M. A Survey of AIOps Methods for Failure Management[J]. ACM Transactions on Intelligent Systems and Technology, 2021,12(6): 1-45

[64] Devlin J., Chang M.-W., Lee K., et al. BERT: Pre-Training of Deep Bidirectional Transformers for Language Understanding[J]

[65] Gao X., Zhai J., Ma S., et al. CILIATE: Towards Fairer Class-Based Incremental Learning by Dataset and Training Refinement[A]. Proceedings of the 32nd ACM SIGSOFT International Symposium on Software Testing and Analysis[C]. Seattle WA USA: ACM, 2023: 475-487

[66] Dong C., Zhang C., Lu Z., et al. CETAnalytics: Comprehensive Effective Traffic Information Analytics for Encrypted Traffic Classification[J]. Computer Networks, 2020,176: 107258

[67] Li Y., Peng X., Zhang J., et al. DCT-GAN: Dilated Convolutional Transformer-Based GAN for Time Series Anomaly Detection[J]. IEEE Transactions on Knowledge and Data Engineering, 2023,35(4): 3632-3644

[68] Wu W., He L., Lin W., et al. Developing an Unsupervised Real-Time Anomaly Detection Scheme for Time Series with Multi-Seasonality[J]. IEEE Transactions on Knowledge and Data Engineering, 2022,34(9): 4147-4160

[69] Diao Z., Xie G., Wang X., et al. EC-GCN: A Encrypted Traffic Classification Framework Based on Multi-Scale Graph Convolution Networks[J]. Computer Networks, 2023,224: 109614

[70] Gao R., He W., Yan L., et al. Hybrid Graph Transformer Networks for Multivariate Time Series Anomaly Detection[J]. The Journal of Supercomputing, 2024,80(1): 642-669

[71] Guo H., Yuan S., Wu X. LogBERT: Log Anomaly Detection via BERT[A]. 2021 International Joint Conference on Neural Networks (IJCNN)[C]. Shenzhen, China: IEEE, 2021: 1-8

[72] Almodovar C., Sabrina F., Karimi S., et al. LogFiT: Log Anomaly Detection Using Fine-Tuned Language Models[J]. IEEE Transactions on Network and Service Management,

2024,21(2): 1715-1723

[73] Meng W., Liu Y., Zaiter F., et al. LogParse: Making Log Parsing Adaptive through Word Classification[A]. 2020 29th International Conference on Computer Communications and Networks (ICCCN)[C]. Honolulu, HI, USA: IEEE, 2020: 1-9

[74] Shenglin Zhang, Weibin Meng, Jiahao Bu, et al. Syslog Processing for Switch Failure Diagnosis and Prediction in Datacenter Networks[A]. 2017 IEEE/ACM 25th International Symposium on Quality of Service (IWQoS)[C]. Vilanova i la Geltrú, Spain: IEEE, 2017: 1-10

[75] Zhang T., Qiu H., Castellano G., et al. System Log Parsing: A Survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2023: 1-20

致谢

三年的硕士研究生生活即将画上句号。值此论文完成之际，回望自己二十余年的求学之路，尤其是在北京航空航天大学学习、成长与沉淀的这段时光，心中充满了感慨与感激。一路走来，我从懵懂走向坚定，从探索走向成熟，这段宝贵的经历不仅让我在学业与科研上不断成长，也让我在为人处世与面对困难时更加从容。论文的完成，凝结着我个人的努力，更离不开诸位老师、同学、朋友和家人的关心、帮助与支持。在此，谨向所有给予我指导、陪伴与鼓励的人致以最诚挚的谢意。

首先，我要感谢我的导师高小鹏教授，以及指导我科研和学习的姜博教授。在我的研究生阶段，无论是课题推进、技术细节打磨，还是论文撰写与思路梳理，姜博老师都给予了我大量耐心、细致而具体的指导。在我遇到困惑和瓶颈时，姜博老师总能给予我及时的建议与启发，帮助我理清思路、坚定方向。可以说，我能够顺利完成本论文，离不开姜老师在整个过程中付出的时间与心力。姜博老师认真负责的指导态度、踏实严谨的科研作风以及对学生的关心与帮助，都让我受益匪浅，也将成为我今后学习和工作中不断学习的榜样。

其次，感谢北京航空航天大学计算机学院的各位老师。感谢你们在研究生阶段给予我的培养与教诲，使我在专业知识、科研方法和工程实践等方面都得到了系统的训练和提升。感谢课题组的老师和同学们在科研讨论、项目合作和日常交流中给予我的帮助，与大家共同学习、共同进步的经历，是我研究生生活中非常珍贵的一部分。

感谢我的同门、朋友和舍友们。感谢你们在这段求学时光中的陪伴与支持，在我面对压力、焦虑与挑战时，给予我鼓励、理解和温暖。正是有你们的陪伴，那些忙碌而充实的日子才不显得孤单，那些艰难而疲惫的时刻也因此多了许多坚持下去的力量。

最后，我要特别感谢我的家人。感谢你们一直以来对我的理解、包容与支持。无论我身处顺境还是低谷，你们始终给予我最无私的关爱与最坚定的陪伴。你们是我不断前行的底气，也是我面对困难时最坚强的后盾。正因为有家人的支持，我才能安心求学、坚定前行，并顺利完成研究生阶段的学业。

行文至此，心中唯有感恩。谨以此文，向所有关心、帮助和支持过我的师长、同学、朋友与家人，致以最诚挚的感谢。